SEED1 - Curs 1
Introducere in data science

Instructor: Conf. Dr. Teodor-Ștefan Bîldea

SIIPA, Semestrul I



Despre mine



Educație

- **Computational Biomedicine Laboratory,** University of Houston — Houston, **Texas,SUA**
  Bursa de cercetare post-doctorala — 2005 – 2006
- **Department of Mathematics,** University of Iowa — Iowa City, **Iowa, SUA**
  Doctorat Matematica, Media 4.0/4.0 — 2005
- **Facultatea de Matematica,** Universitatea Transilvania — Brasov, **Romania**
  Master Probabilitati, Statistica si Fiabilitatea Sistemelor, Media 9.8/10 — Mai 1998
  Licentiat in Matematica si Informatica, Media 9.7/10 — Mai 1997

Publicații

Bîldea, T. Ş., Gorin, T. "Towards capturing ancillary revenue via unbundling and cross-selling". *J Revenue Pricing Manag* **17,** 102–114 (2018)

Santamaria-Pang, A., Bîldea, T. Ş., Tan, S., & Kakadiaris, I. A. "Denoising for 3-d photon-limited imaging data using nonseparable filterbanks". *IEEE transactions on image processing : a publication of the IEEE Signal Processing Society*, **17(12)**, 2312–2323 (2008).

Bîldea, T. Ş. "The Laplacian subalgebra of $\mathcal{L}(\mathbb{F}_N)^{\overline{\otimes}_k}$ is a strongly singular MASA." *Proceedings of the American Mathematical Society* **135**, no. 3 :823-31, (2007)

Santamaria-Pang, A., Bîldea, T. Ş., I. Konstantinidis and I. A. Kakadiaris, "Adaptive Frames-Based Denoising of Confocal Microscopy Data," *2006 IEEE International Conference on Acoustics Speech and Signal Processing Proceedings*, Toulouse, pp. II-II. (2006)

Bîldea, T. Ş.. "Generalized amalgamated free product of C*-algebras" - *J. Operator Theory* **56:1**, 143–165 (2006).

Bildea, T. Ş. "On the Laplacian subalgebra of some tensors of group von Neumann algebras". *Contemp. Math.* **414**, 265–271(2006)

Bîldea, T. Ş., D. E. Dutkay and G. Picioroaga, "MRA super-wavelets", *New York J. Math.*, **11,** 1–19 (2005)

Cursuri predate la Univ. Transilvania

- Tehnici și Procese de Data Mining 2016-2017, 2017-2018
- Știința Explorării și Exploatării Datelor 2019-
- Aplicații ale Inteligenței Artificiale în Economie 2019-

De la matematică la data science

M.Sc. Statistics, 1997

Ph.D. Mathematics, 2005

Post Doc, Data Science, 2006

Pricing Data Scientist 2007
Price optimization airlines, car rental, industry verticals

Senior Pricing Analyst, 2008
Car insurance – risk modeling

Senior Data Scientist 2009
Corn DNA data mining

EU, Lead Data Scientist 2009
Sales Opportunity Detection
Smart CPQ, Value monitorization

Co-Founder, 2016-2021

Founder, 2017

Conferentiar, 2020
Cursuri applicative de Data Science/ML/AI

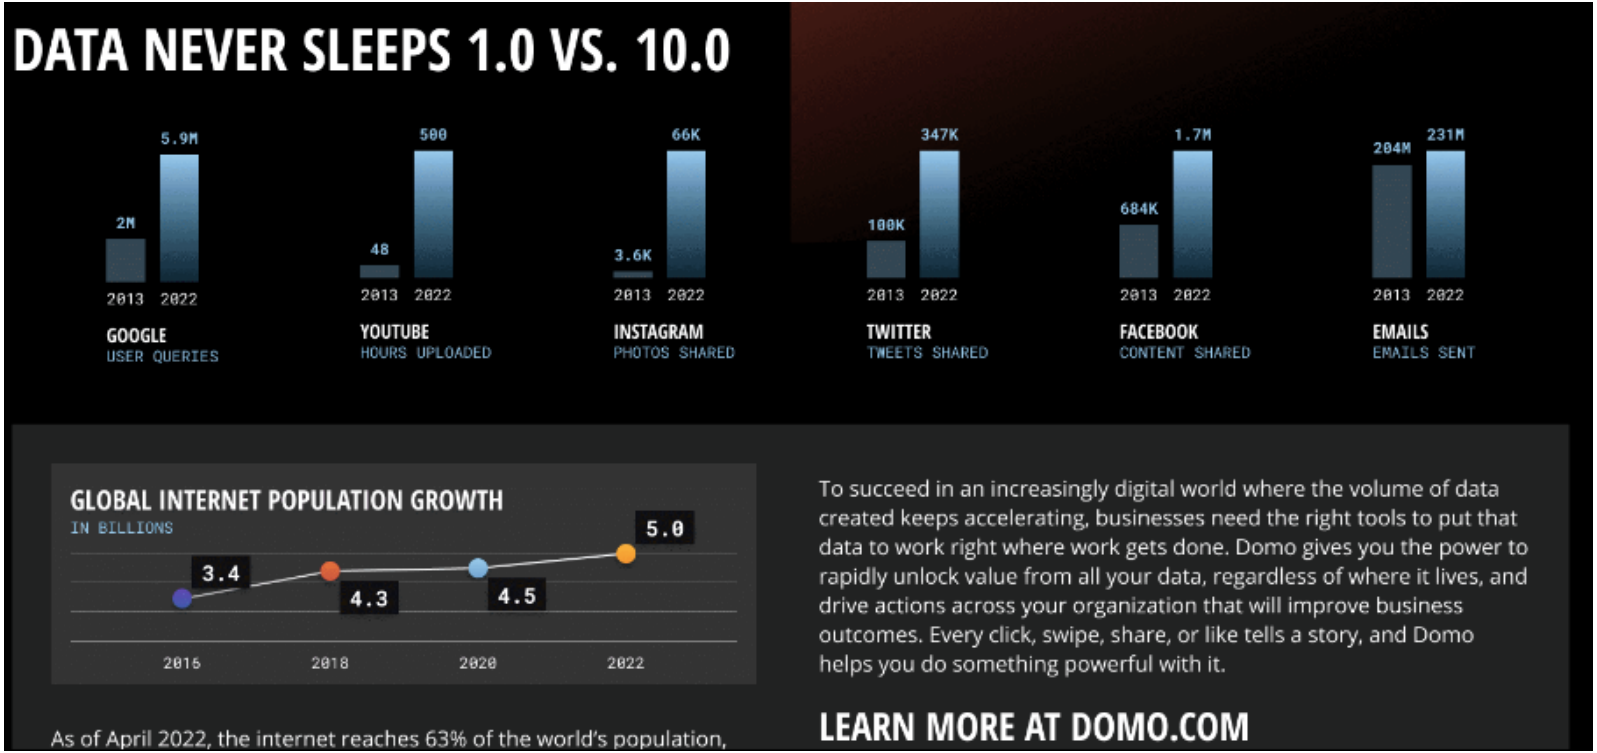
“Computers have promised us a fountain of wisdom but delivered a flood of data”

William J. Frawley, Gregory Piatetsky-Shapiro, and Christopher J. Matheus



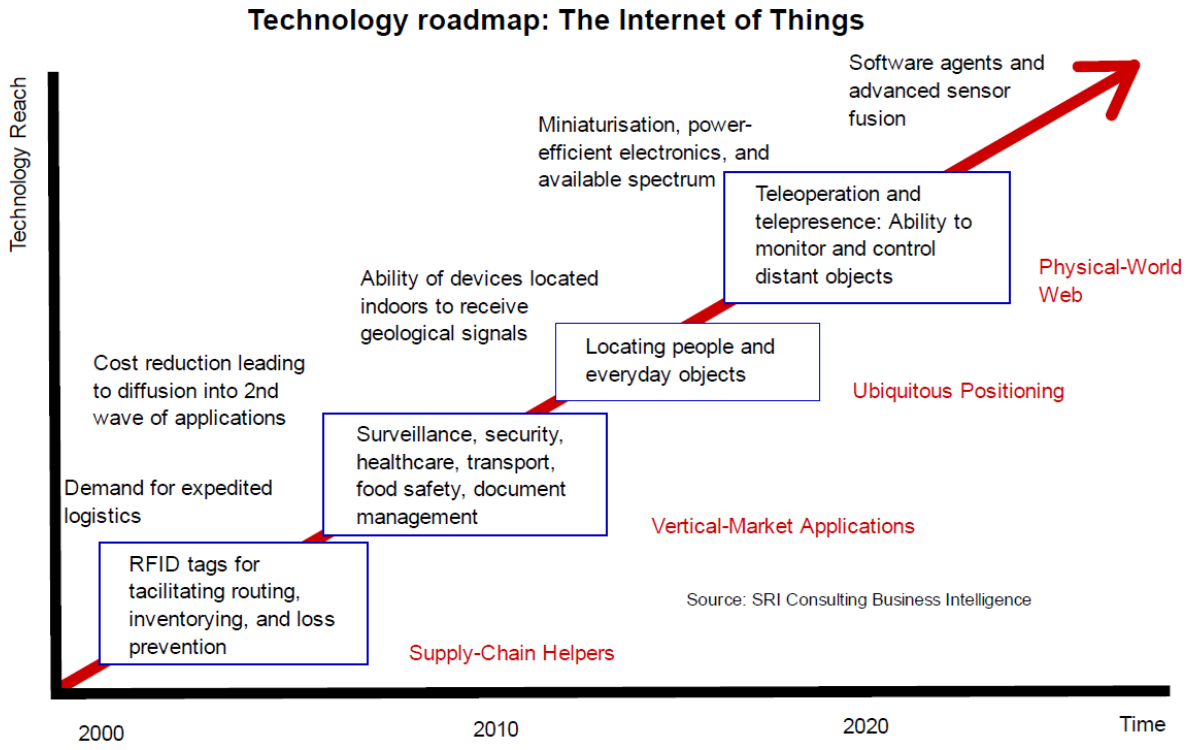
“Computers have promised us a fountain of wisdom but delivered a flood of data”

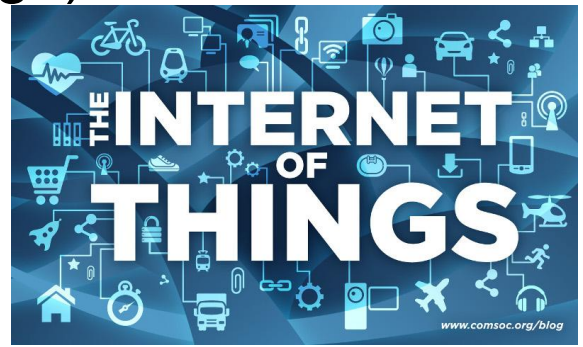
William J. Frawley, Gregory Piatetsky-Shapiro, and Christopher J. Matheus

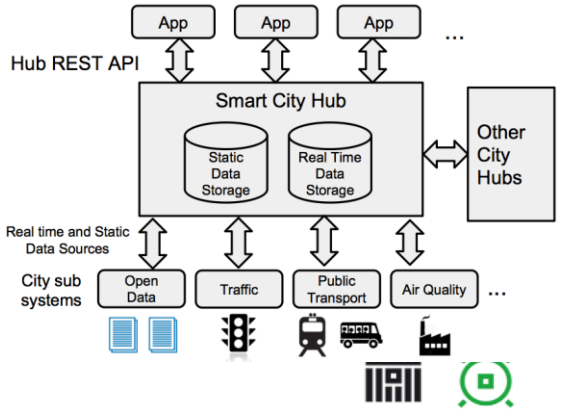



EVERY
MINUTE
OF THE DAY
PEOPLE SEND 16M
TEXTS
FACEBOOK
USERS SHARE
1.7M pieces of content
GOOGLE
USERS CONDUCT
5.9M searches
EMAIL
USERS SEND
231.4M messages
INSTAGRAM
USERS SHARE
66K photos
ONLINE
EVENT
GOERS PURCHASE
$12.9K
TWITTER
USERS SHARE
347.2K tweets
CRYPTO
BUYERS PURCHASE
$90.2M in cryptocurrency
SNAPCHAT
USERS SEND
2.43M snaps
VENMO
USERS SEND
$437.6K
AMAZON
SHOPPERS SPEND
$443K
TINDER
USERS SWIPE
1.1M times
YOUTUBE
USERS UPLOAD
500 hours of video
VIEWERS SPEND
1M hours
STREAMING
DOORDASH
DINERS PLACE
$76.4K in orders
104.6K hours
SPENT IN
ZOOM
MEETINGS

Ce urmeaza ?
Mai multe date via IoT (Internet of Things)







Cateva curiozitati

din experienta mea in modelare si data mining

- Computational Biomedicine Laboratory, University of Houston:

Abia prin 2005 s-a observat ca neuronul excitat transmite semnal nu numai inainte, catre neuronii conectati la dendrite, dar si inapoi, catre neuronii care l-au facut sa emita.

- Nationwide Insurance – locul 8 in SUA in 2015, cu 3% din piata:

Asiguratorii stiu de prin 2000, in urma unui studiu extins, ca scorul de credit este foarte puternic corelat cu despagubirile – cu alte cuvinte modul de cheltuire a banilor si de plata a creditelor indica/prezice stilul de sofat. Este insa ilegala utilizarea directa a acestei informatii confidentiale (credit score).

- Pioneer, o companie DuPont (concurent cu Monsanto)

Produce porumb experimental in 50 de locatii pe glob intr-o cantitate egala in 2006 cu cantitatea de porumb produsa de Australia

Intre 2006-2008 costurile de marcare a ADN-ului s-au redus cu 50-75%. Numarul de markeri genetici a crescut de la sute la zeci de mii, la fel au crescut datele colectate si folosite in modele predictive bazate pe regresie la markeri = variabile independente

- PROS, Inc. “The Revenue and Profit Realization Company“

In 2019, 57% din piata de bilete de avion foloseste (diverse versiunie ale unui) soft PROS de generare a preturilor optime (Lufthansa 25+ ani)

Pricing: soft de optimizare de preturi : HP, BP, Shell, Siemens, BASF, Disney;

- Optimizare de venit: Lufthansa, Iberia, Swiss, Etihad, Turkish Airlines, Southwest, etc. (80 companii in 2024); Carribean, Deutsche Bahn, Hertz, Avis;

Agenda curs1

Ce este Data Mining?

Ce este un ‘Data Scientist’?

Trecere in revista a tehnicilor de data mining

Ce este Data Mining? *

- Termen creat recent pentru o confluență de idei de la statistica si informatica (machine learning si metode de baze de date) aplicate la baze de date mari in stiinta , inginerie si afaceri.
- Definitii multiple, dispute legate de ce este si ce nu este data mining. Terminologia aferenta nu este standardizata inca (e.g. bias, clasificare, predictie)
- ***Data Mining*** a devenit între timp ***Data Science***

* Primul workshop international pe tema “Knowledge Discovery and Data Mining “ a fost in 1995

Definitii generice si punctuale

Definitiile generice includ metode statistice traditionale, cele punctuale scot in evidenta automatizari si metode euristice.

Exemple de nomenclatura:

- Data mining, data dredging (dragare de date), fishing expeditions
- Knowledge Discovery in Databases (KDD) – una din conferințele prestigioase din domeniu

Gartner Group

(http://www.gartner.com/it-glossary/?s=Data+mining + google translate)

“Data mining este procesul de a descoperi corelații, modele și tendințe noi, semnificative prin analizarea unor cantități mari de date stocate în arhive, folosind tehnologiile de recunoaștere a modelelor (pattern recognition) precum și tehnici statistice și matematice”

Alte definitii si comentarii



Daryl Pregibon
[1] ”KDD = Statistics at Scale and Speed”
[2] “un amestec de statistica, inteligenta artificiala, si cercetare in baze de date [mari]“



Sergey Brin – cofondator Google, PhD in DM
“Google's mission is to organize the world's information, making it universally accessible and useful”

[1] Daryl Pregibon. 2001: A statistical odyssey. KDD Conference ’99, 1999
[2] Daryl Pregibon 1997: Data Mining. Statistical Computing and Graphics

De ce Data Science?

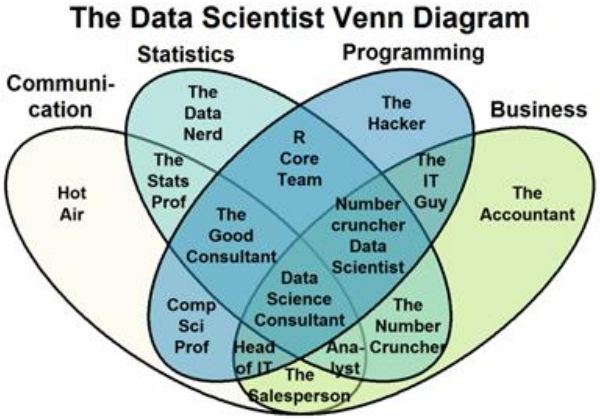
- Piata: tranzitia de la focus pe produs/serviciu la focus pe consumator
- IT: tranzitie de la inregistrari actualizate la zi catre cautare de sabloane/modele in inregistrari - Data Warehouses - OLAP
- Scadere dramatica a costurilor de stocare a datelor
- Captare automatizata a datelor din tranzactii – e.g. Cod bare, POS, clicuri Mouse, localizari (GPS, tel inteligente)
- Internet: interactiuni personalizate (Facebook, Google),date longitudinale
- Accelerarea producerii de date in era mobile

Și nu în ultimul rând: PNRR, digitalizare cu fonduri europene, start-up-uri, Gen AI etc.

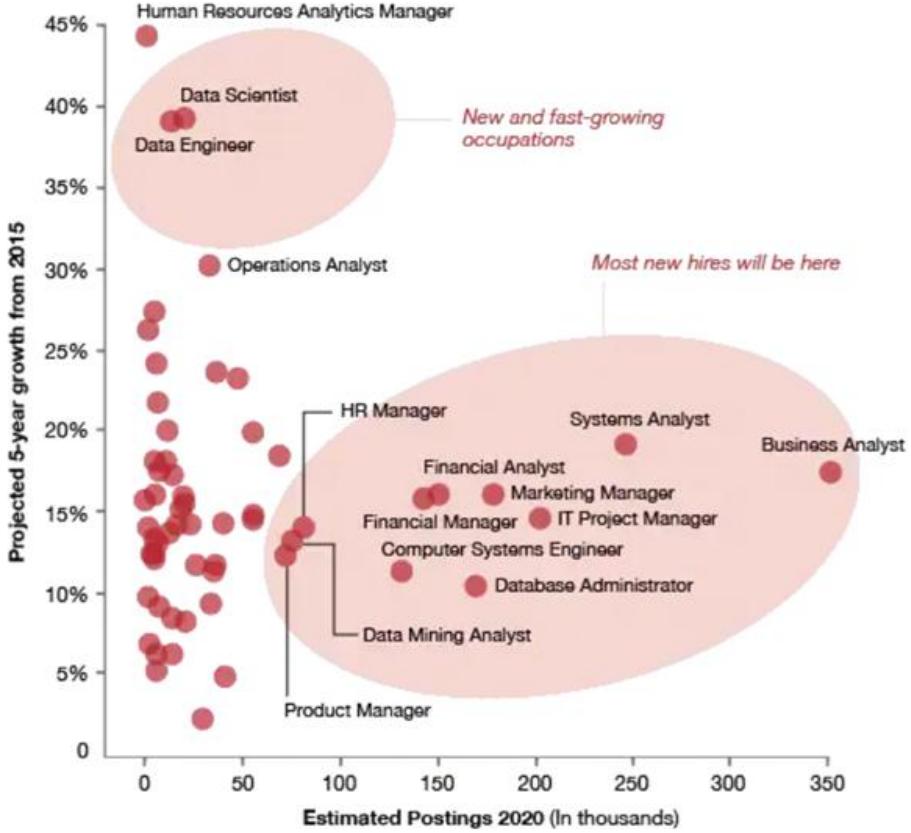
Universitatea Transilvania din Brașov

De ce data science?

- „Datele sunt noul petrol" - Clive Humby, 2006
- „ IA este noul curent electric" - Andrew Ng, 2017
- „Software 2.0" - Andrej Karpathy, Director of AI, Tesla, 2017



Data Scientist Venn Diagram by philippe therond Last updated about 3 years ago



Note: Each dot represents an occupation in the US jobs market where data science and analytics skills are required.
Source: PwC analysis based on Burning Glass Technologies data, January 2017.

https://www.pwc.com/us/en/library/data-science-and-analytics.html

Evolutie top companii dupa capitalizare

View by year: 1990

Full List | Companies

1990 Full list

Rank	Company
1	General Motors
2	Ford Motor
3	Exxon Mobil
4	Intl. Business Machines
5	General Electric
6	Mobil
7	Altria Group
8	Chrysler
9	DuPont
10	Texaco

View by year: 2000

Full List | Companies

2000 Full list

Rank	Company
1	General Motors
2	Wal-Mart Stores
3	Exxon Mobil
4	Ford Motor
5	General Electric
6	Intl. Business Machines
7	Citigroup
8	AT&T
9	Altria Group
10	Boeing

2010

Rank	Company
1	Exxon Mobil
2	Microsoft
3	Apple
4	Wal-Mart Stores
5	Berkshire Hathaway
6	General Electric
7	Procter & Gamble
8	Bank of America Corp.
9	Google
10	J.P. Morgan Chase & Co.

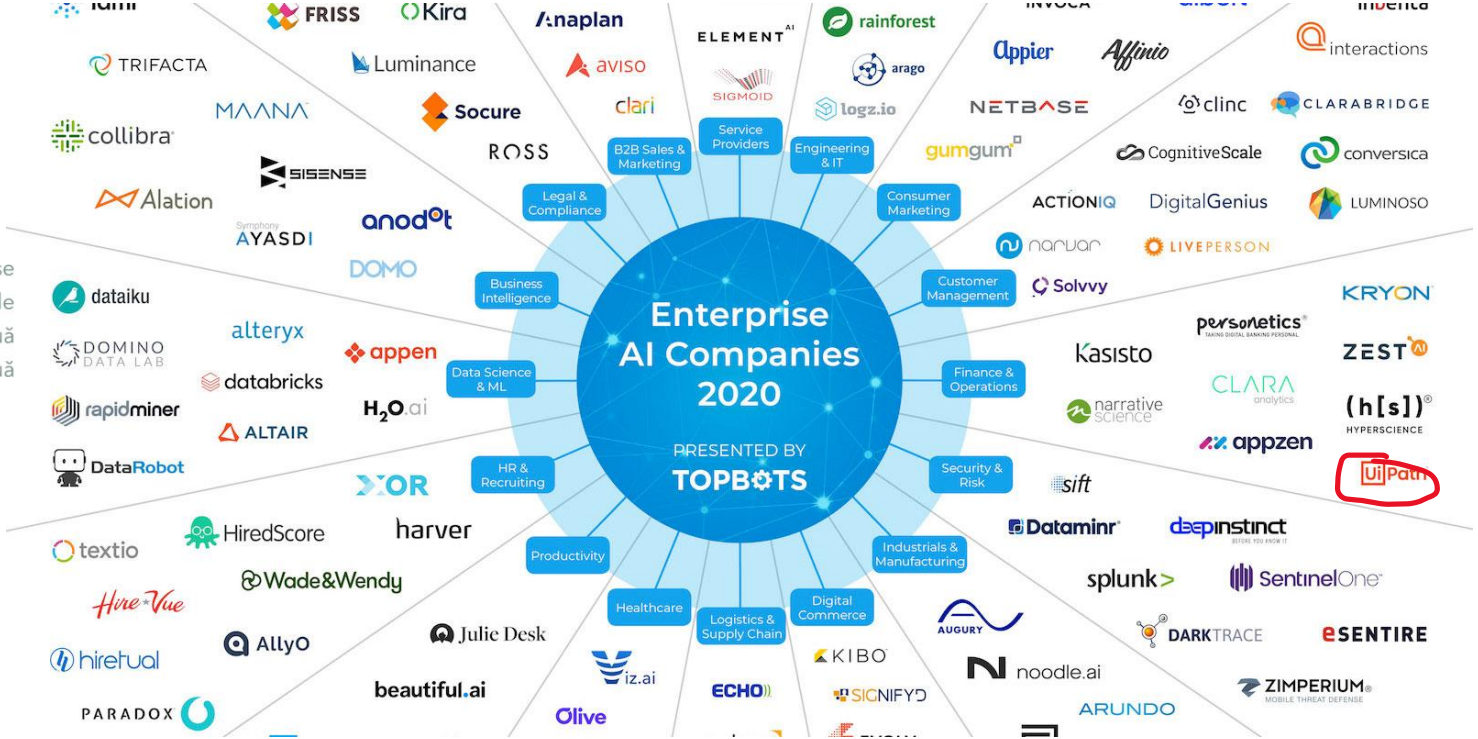
Rank	Company	Market Cap (Jul 1, 2022)
#1	Saudi Aramco	$2.27 trillion
#2	Apple	$2.25 trillion
#3	Microsoft	$1.94 trillion
#4	Alphabet	$1.43 trillion
#5	Amazon	$1.11 trillion
#6	Tesla	$707 billion
#7	Berkshire Hathaway	$612 billion
#8	United Health Group	$485 billion
#9	Johnson & Johnson	$472 billion
#10	Tencent	$435 billion

https://www.youtube.com/watch?v=Z93yWXb9Tb0

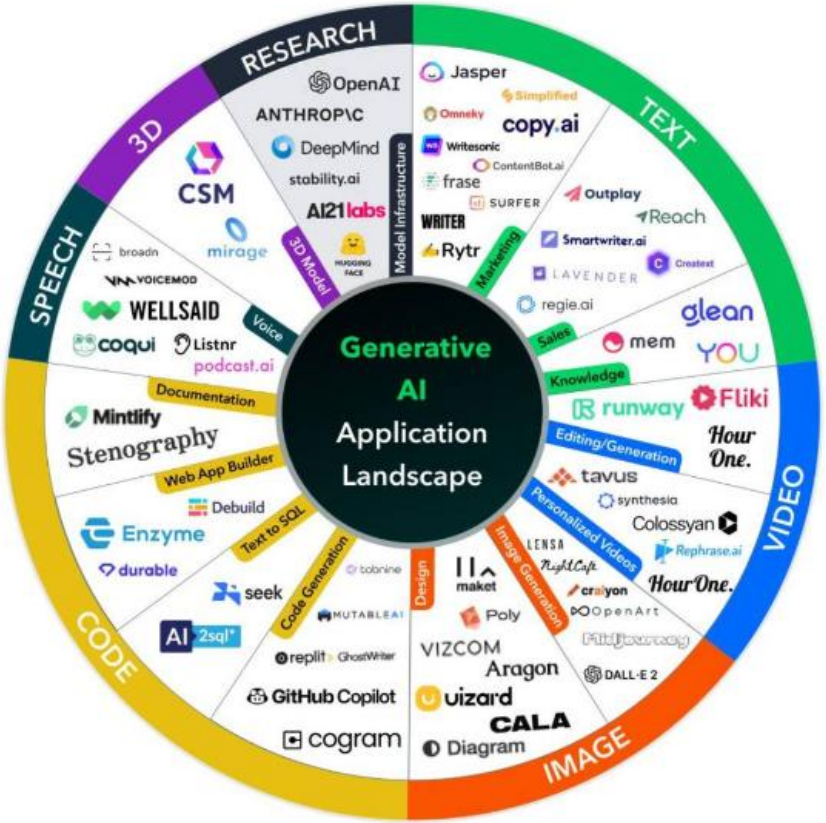
https://www.youtube.com/watch?v=PN1L0hPP6IY

Nevoie acută de specialiști data science

Numărul companiilor care se bazează pe servicii data science de exploatare a datelor este în continuă creștere, generând o cerere continuă de specialiști în domeniu



Si nici nu am pomenit de Gen AI...



Tehnici esentiale in DM

- Statistica (adaptată pentru mărimea datelor și viteza de procesare din secolul 21)

Exemple:

  - Statistica Descriptivă (EDA)
  - Vizualizari de date
  - Modelare: Regresie, Analiza Cluster, Clasificare

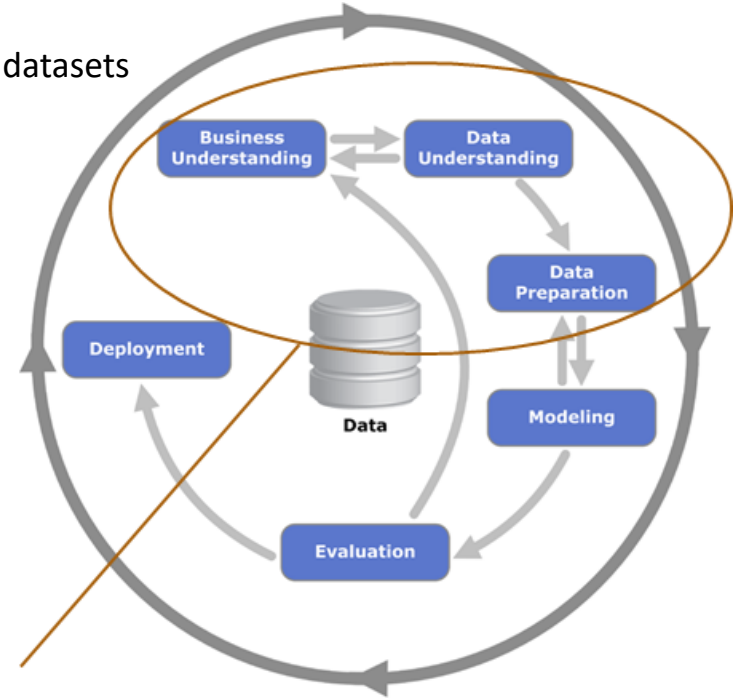
- Machine Learning, Inteligența Artificială: e.g. Retele Neuronale
- Lucrul cu baze de date structurare și nestructurate, SQL și no-SQL
- Procesare paralela/scalabilă în cloud: AWS, Azure, Google cloud

Pașii unui proiect de exploatare a datelor

1. Înțelegerea scopului și a datelor
2. Asamblarea setului de date pentru studiu
3. Curățirea, asanarea și preprocesarea datelor
4. Reducerea/simplificarea/agregarea datelor
5. Alegerea tipului de aplicație de învățare
6. Alegerea algoritmului de învățare automată
7. Rularea algoritmului
8. Interpretarea rezultatului și iterații ale pașilor 4-7 dacă e necesar
9. Integrarea procesului într-un sistem operațional

Metodologii: SEMMA (SAS) vs. CRISP-DM

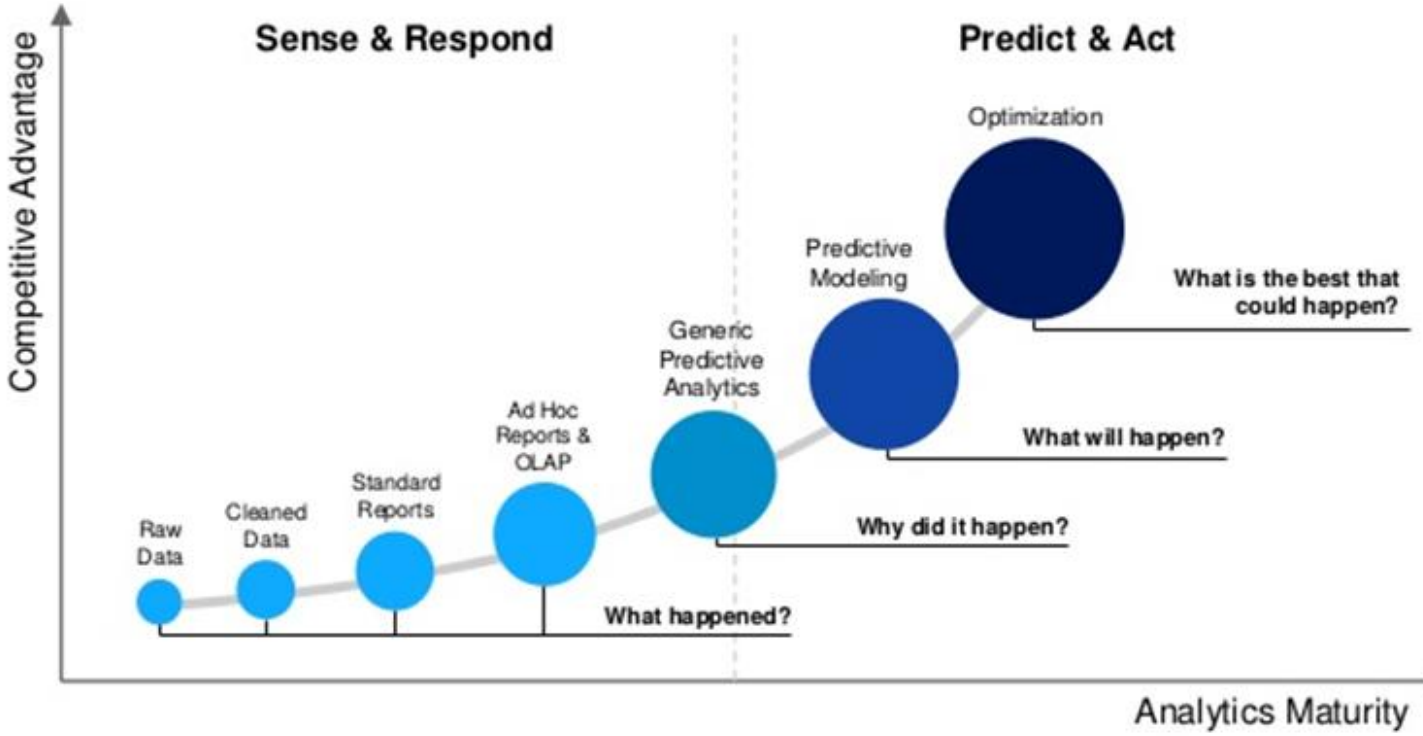
- **S**ample from data sets, Partition into Training, Validation and Test datasets
- **E**xplore data set statistically and graphically
- **M**odify:Transform variables, Impute missing values
- **M**odel: fit models e.g. regression, classfication tree, neural net
- **A**ssess: Compare models using Partition, Test datasets



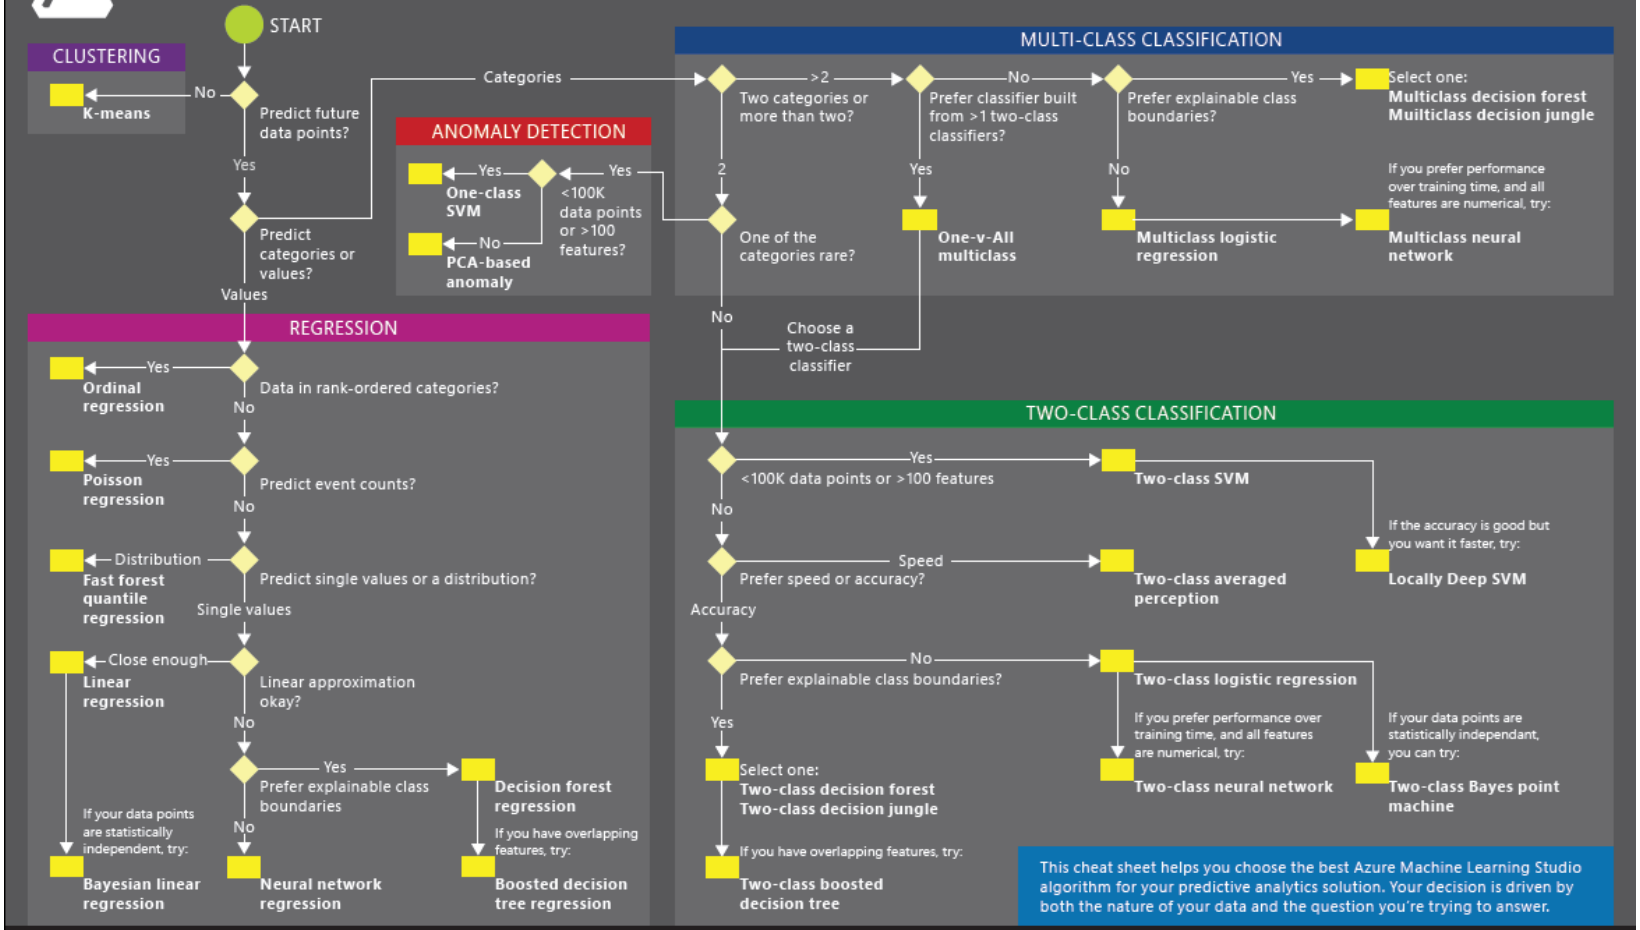
Cross Industry Standard Process for Data Mining

Esential, uneori 90% din proiecte repetitive.

Descriptiv, Predictiv, Prescriptiv[1]



Microsoft Azure Machine Learning: Algorithm Cheat Sheet



© 2015 Microsoft Corporation. All rights reserved.
Created by the Azure Machine Learning Team
Email: AzurePoster@microsoft.com
Download this poster: http://aka.ms/MLCheatSheet
Microsoft

Exemple de aplicatii[1],[2]

Servicii de telefonie si utilitati

Problema:

- Clienti traseisti –CHURN

Solutie:

- Segmentarea clientilor pe baza datelor de facturare, a interactiunilor directe, a vizitelor pe site, etc.
- Construirea unui scor probabilistic de pierdere a clientului

Actiune:

- Oferte personalizate si stimulente pentru fidelizarea celor cu risk mare

Exemple de aplicatii[1],[2]

France Telecom

Odata cu implementare unei solutii de data warehouse, pe partea BI s-a introdus si un sistem CHURN de profilare a clientilor (Customer Profile System – CPS)

- Profilarea preventiva a dus la retentia sporita a clientilor

Exemple de aplicatii[1],[2]

Retail – comertul cu amanuntul

Problema:

- Rezultate neclare din promotii

Solutie:

- Optimizarea promotiilor prin segmentarea clientilor pe baza tiparului de cumparaturi (purchase pattern)

Actiune:

- Clienti care cumpara des, putin, revin in timp, si au revenit de curand vor primi carduri de loialitate, si vor fi stimulati pentru upsell (catre branduri mai scumpe) si cross-sell (propuneri pentru extinderea cosului de cumparaturi)
- Clienti care cumpara mult si foarte rar pot primi o oferta personalizata de tip ‘win-back customer’

Exemple de aplicatii[1],[2]

Prevenirea fraudelor -Automobile Insurance Bureau of Massachusetts

Problema:

- Fraudele in asigurari maresc costurile si micsoreaza veniturile

Solutie:

- Folosind regresia logistica si retele neuronale s-au identificat caracteristicile cazurilor frauduloase pornind de la: date client, detalii ale accidentelor, detalii ale daunelor
- Prin segmentarea clientilor in grupe de risc se previn fraude ulterioare

Actiune:

- Clienti profilati ca problematici vor fi refuzati sau vor primi prime de asigurare mai mari astfel marindu-se venitul

Exemple de aplicatii[1],[2]

Agentii de Inteligenta, Criminalistica

Problema:

1. Detectarea zonelor cu grad sporit de risc
2. Detectarea persoanelor cu grad sporit de risc la granite
3. Profilarea informatiilor agentiilor de securitate

Solutie:

1. Segmentarea geografica pe baza unui scor din statisticile cumulate
2. Clasificarea traficului de frontier folosing caracteristici personale (date pasaport) si contextuale (geografie, tip transport, scopul vizitei, etc.)
3. Clasificare informatiilor de la agentii

Actiune:

1. Sporirea personalului de paza si protectie a ordinii publice la locul si timpul potrivit
2. Control selectiv amanuntit
3. Construirea unui caz pentru actiuni de contra-terorism

Exemple de aplicatii[1],[2]

AI in imagini

- Google cu image matching,
- recunoastere faciala, etc.
- Determinarea sentimentului pozitiv/negativ

AI in text

Filtre SPAM – primul filtru folosea clasificatori Bayesieni

Retele Sociale, Targeted Marketing, etc.

Administrative

Urmariti postarile pe elearning

Etape Proiecte/Seturi de Date Disponibile

- Intelegerea problemei, evaluarea datelor brute si analiza initiala (partea descriptiva)
- Masarea datelor si aplicarea unei tehnici DM (parte predictiva)

Cum vom lucra?

Python 3.*

- numpy, pandas, scikit-learn, plotly
- dataframes, dictionaries, lists, json files
- Machine learning: clasificatori, regresori, validari incrucisate, linii de antrenare, validare, si cautare hiperparametrii (parameter tuning)

Anaconda - Jupyter Notebooks/ VS code

Laboratoarele se vor desfasura cu prezenta fizica

Anaconda va fi instalat pe statiile de lucru

Puteti salva in contul propriu temele de laborator

Puteti folosi laptopul vostru daca preferati

Administrative

Etapele examinarii

1. Examinare partiala - analiza initiala a celor doua seturi de date (clasificare si regresie) precum si pregatirile in vederea modelarii
2. Examen - prezentarea finala a rezultatelor antrenarii modelelor si a performantei pe date test

3. Cerintele pentru examen vor fi pe elearning