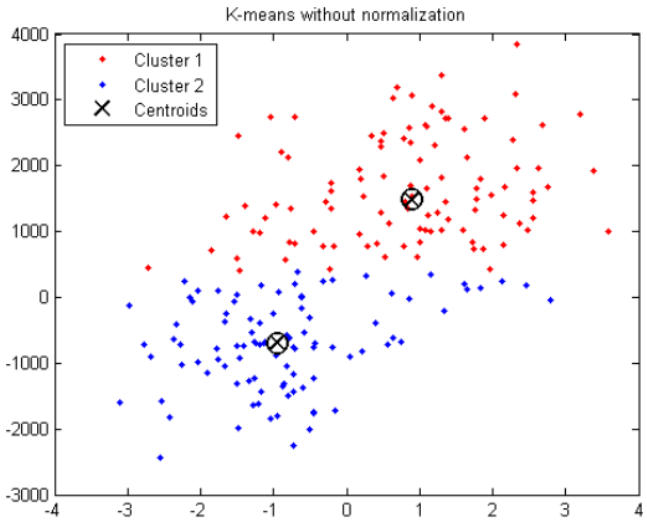
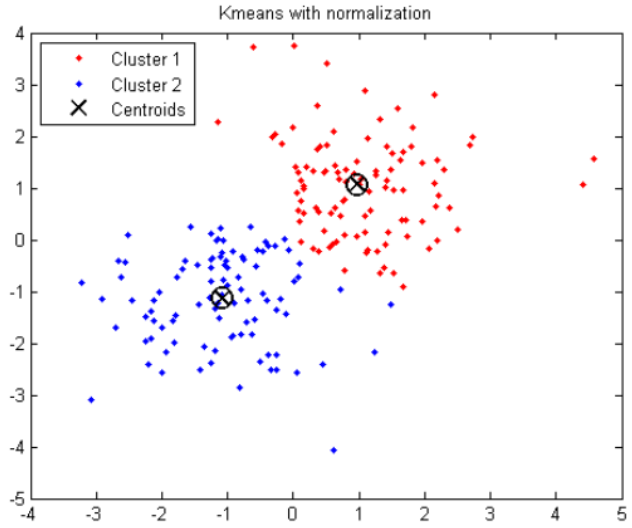
Normalizare, standardizare (ref)

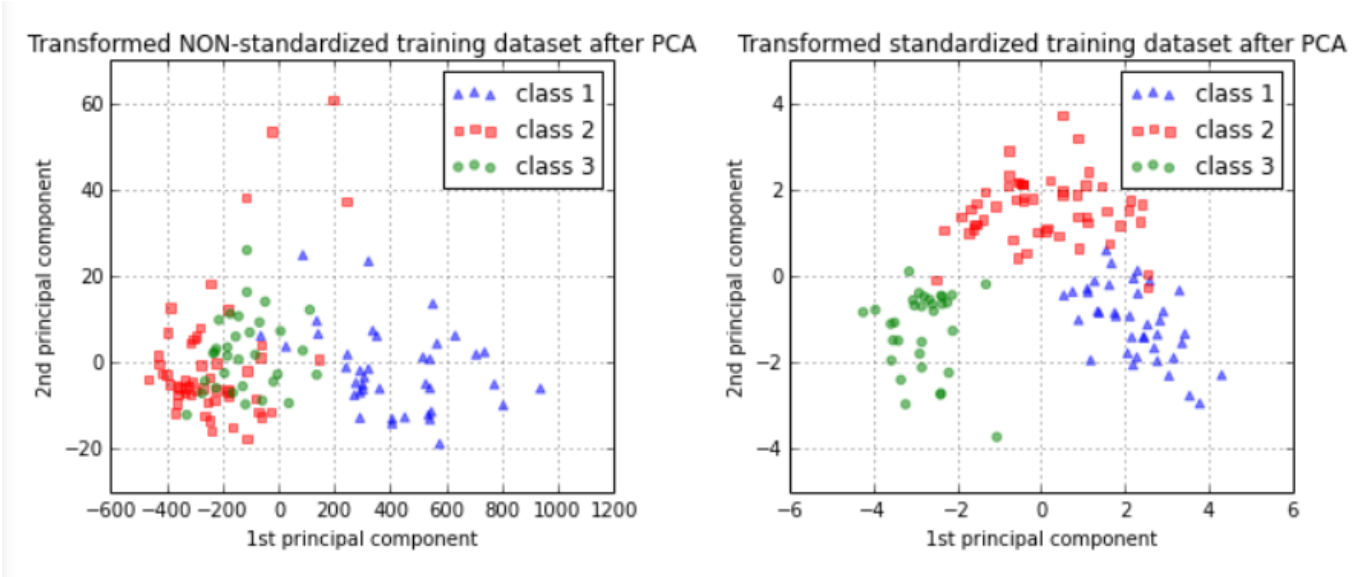
- Pentru modelele bazate pe distanță, standardizarea este efectuată pentru a preveni caracteristicile cu intervale mai largi să domine metrica distanței.





Normalizare, standardizare

- Metode de a comasa atributele numerice pe aceeiași scală pentru a putea măsura mai bine importanța lor, ca în cazul PCA, sau al regresiei statistice.



Normalizare, standardizare

- Motivul pentru care standardizăm datele nu este același pentru toate modelele de învățare automată și diferă de la un model la altul.

Beneficiu	Descriere
Compararea și interpretarea mai ușoară	Standardizarea transformă datele pentru a avea o medie de 0 și o deviație standard de 1, facilitând compararea și interpretarea.
Eliminarea unităților de măsură	Standardizarea elimină efectele unităților de măsură și dimensiunile diferite ale caracteristicilor, permitând compararea directă.
Îmbunătățirea performanței algoritmilor	Algoritmii de învățare automată sunt adesea influențați de scala datelor, iar standardizarea îmbunătățește performanța și convergența acestora.
Reducerea sensibilității la valori extreme	Standardizarea face datele mai robuste la valori extreme, evitând efectele incorecte ale acestora asupra analizei.
Simplificarea interpretării coeficienților	În modelele statistice, standardizarea facilitează interpretarea coeficienților, care devin mai direct interpretabili.

Normalizare, standardizare

- Aceste metode de standardizare pot fi aplicate în funcție de natura datelor, cerințele analizei și tipul de algoritm pe care intenționați să îl utilizați.
- Fiecare metodă are avantaje și dezavantaje și trebuie aleasă în funcție de contextul specific al setului de date și obiectivele analizei.

Metoda de Standardizare	Descriere
Standardizarea Z-score	Transformă datele astfel încât să aibă o medie de 0 și o deviație standard de 1, astfel încât valorile să fie centrate și scalate.
Min-Max Scaling	Redimensionează datele pentru a se încadra într-un interval specific, cum ar fi [0, 1], păstrând relațiile relative între valorile initiale.
Robust Scaling (Scaling robust)	Similar cu Standardizarea Z-score, dar utilizează statisticile robuste (mediană și cuartile) pentru a face față valorilor extreme.
Log Transformation	Aplică logaritmul natural asupra datelor, reducând variația în cazul datelor cu distribuție asimetrică sau exponențială.
Box-Cox Transformation	O metodă statistică care transformă datele într-o distribuție aproape normală, potrivită pentru date pozitive și negative.
Unit Vector Scaling	Redimensionează datele astfel încât vectorii caracteristicilor să aibă norma unitară, folosită în special în algoritmi care depind de distanță sau similaritate.

Normalizare, standardizare

- Resurse Python

The `sklearn.preprocessing` module includes scaling, centering, normalization, binarization methods.

User guide: See the Preprocessing data section for further details.

`preprocessing.Binarizer`(*[, threshold, copy])	Binarize data (set feature values to 0 or 1) according to a threshold.
`preprocessing.FunctionTransformer`([func, ...])	Constructs a transformer from an arbitrary callable.
`preprocessing.KBinsDiscretizer`([n_bins, ...])	Bin continuous data into intervals.
`preprocessing.KernelCenterer`()	Center an arbitrary kernel matrix K.
`preprocessing.LabelBinarizer`(*[, neg_label, ...])	Binarize labels in a one-vs-all fashion.
`preprocessing.LabelEncoder`()	Encode target labels with value between 0 and n_classes-1.
`preprocessing.MultiLabelBinarizer`(*[, ...])	Transform between iterable of iterables and a multilabel format.
`preprocessing.MaxAbsScaler`(*[, copy])	Scale each feature by its maximum absolute value.
`preprocessing.MinMaxScaler`([feature_range, ...])	Transform features by scaling each feature to a given range.
`preprocessing.Normalizer`([norm, copy])	Normalize samples individually to unit norm.
`preprocessing.OneHotEncoder`(*[, categories, ...])	Encode categorical features as a one-hot numeric array.
`preprocessing.OrdinalEncoder`(*[, ...])	Encode categorical features as an integer array.
`preprocessing.PolynomialFeatures`([degree, ...])	Generate polynomial and interaction features.
`preprocessing.PowerTransformer`([method, ...])	Apply a power transform featurewise to make data more Gaussian-like.
`preprocessing.QuantileTransformer`(*[, ...])	Transform features using quantiles information.
`preprocessing.RobustScaler`(*[, ...])	Scale features using statistics that are robust to outliers.
`preprocessing.SplineTransformer`([n_knots, ...])	Generate univariate B-spline bases for features.
`preprocessing.StandardScaler`(*[, copy, ...])	Standardize features by removing the mean and scaling to unit variance.
`preprocessing.TargetEncoder`([categories, ...])	Target Encoder for regression and classification targets.

Când este importantă standardizarea variabilelor?

- Înainte de o clusterizare
  - Tehnicile de analiză a grupurilor depind de conceptul de măsurare a distanței dintre diferitele observații pe care încercăm să le grupăm. Dacă o variabilă este măsurată la o scară mai mare decât celelalte variabile, atunci orice măsură pe care o folosim va fi influențată excesiv de acea variabilă.
- Înainte de PCA
  - PCA oferă mai multă pondere acelor variabile care au variațe mai mari decât variabilelor care au variațe foarte mici. De fapt, rezultatele analizei vor depinde de ce unități de măsură sunt utilizate pentru măsurarea fiecărei variabile. Standardizarea valorilor brute face o variație egală, astfel încât ponderea mare nu este atribuită variabilelor care au variațe mai mari.
- Înainte de regresii (LASSO, RIDGE) sau când interpretăm o regresie clasică

Atenție: standardizarea fără scurgeri de informație

- Scalerul învață din date: media și deviația standard (StandardScaler), minimul și maximul (MinMaxScaler)
- Dacă urmează evaluarea pe date noi (modulele 4–6):
  - împărțiți întâi train/test
  - scaler.fit(X_train), apoi transform pe train și pe test, cu aceiași parametri
- Greșeala clasică: fit pe tot setul înainte de împărțire; testul „aude” informație despre media și împrăștierea lui
- La clusterizare/PCA fără test, scalați tot setul, dar fără coloana țintă și fără ID-uri