ADS1 - Curs 6
Regresie

Instructor: Conf. Dr. Teodor-Ștefan Bîldea

Semestrul I

An I – SIIPA



Cuprins Curs

Modelare statistică

k-Nearest Neighbors (kNN)

Evaluarea modelului

Cât de bun e modelul pentru prognoză?

Compararea a două modele statistice

Cum putem alege între două modele?

Prognoza unei variabile

Să ne imaginăm un scenariu în care am dori să prezicem o variabilă folosind altă (sau un set de alte) variabilă(e).

Exemple:

- Prezicerea numărului de vizualizări pe care îl va primi un videoclip YouTube săptămâna viitoare în funcție de durata videoclipului, data la care a fost postat, numărul anterior de vizionări etc.
- Prezicerea filmelor pe care le va evalua un utilizator Netflix pe baza evaluărilor lui anterioare, a datelor demografice etc.

Date

Setul de date publicitare constă în vânzările unui produs în 200 de piețe diferite, împreună cu bugetele publicitare pentru produs din fiecare dintre aceste piețe pentru trei medii diferite: TV, radio și ziar. Totul este dat în unități de 1000 USD.

TV	radio	newspaper	sales
230.1	37.8	69.2	22.1
44.5	39.3	45.1	10.4
17.2	45.9	69.3	9.3
151.5	41.3	58.5	18.5
180.8	10.8	58.4	12.9

Unele dintre cifrele din această prezentare sunt preluate din „An Introduction to Statistical Learning, with applications in R” (Springer, 2013) autori: G. James, D. Witten, T. Hastie și R. Tibshirani

Variabile răspuns/target vs. Variabile predictor

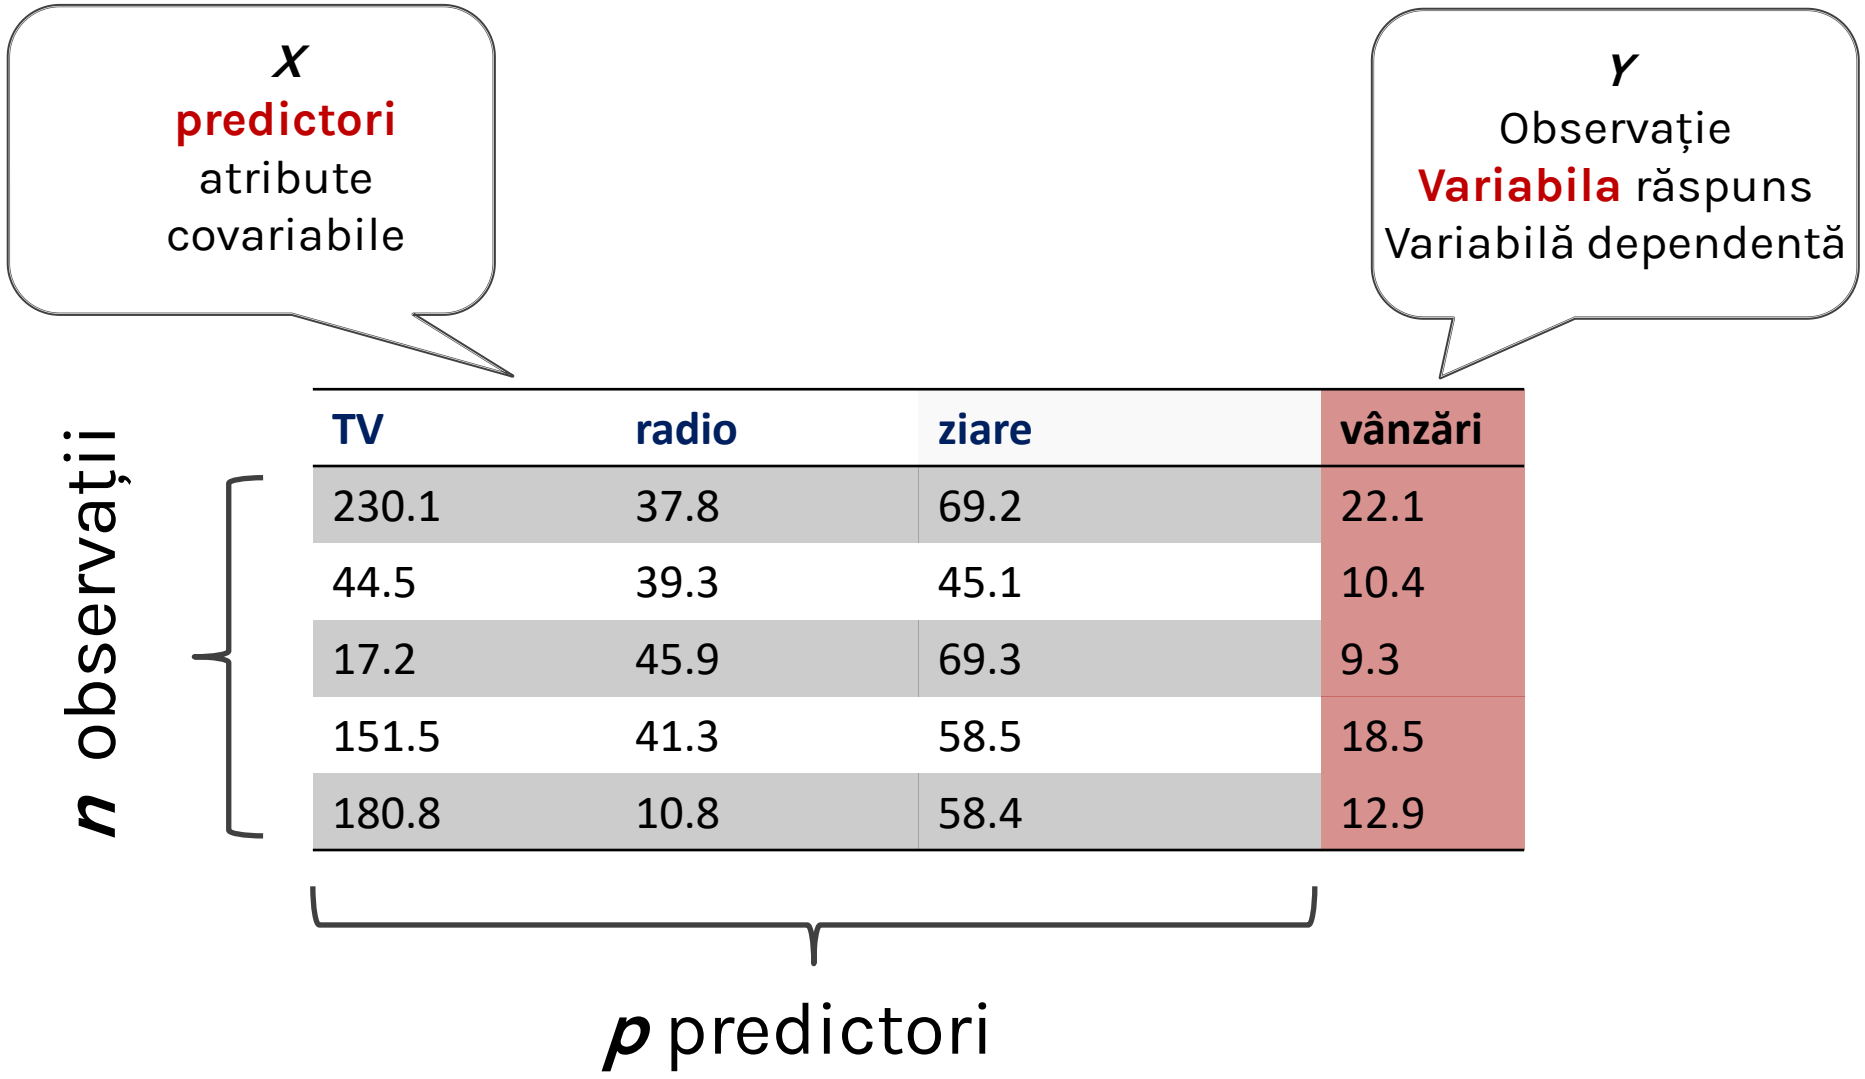
Există o asimetrie în multe dintre aceste probleme:

- Variabila pe care am dori să o prezicem poate fi mai dificil de măsurat, este mai importantă decât cealaltă sau poate fi influențată direct sau indirect de valorile celeilalte variabile.

Astfel, am dori să definim două categorii de variabile:

- variabile a căror valoare dorim să o prezicem
- variabile ale căror valori le folosim pentru a ne face predicția

Variabile răspuns/target vs. Variabile predictor



TV	radio	ziare	vânzări
230.1	37.8	69.2	22.1
44.5	39.3	45.1	10.4
17.2	45.9	69.3	9.3
151.5	41.3	58.5	18.5
180.8	10.8	58.4	12.9

Variabile răspuns/target vs. Variabile predictor

$X = X_1, \dots, X_p$

$X_j = x_{1j}, \dots, x_{ij}, \dots, x_{nj}$

predictori

features

covariabile

$Y = y_1, \dots, y_n$

Observație

Variabila **răspuns**

Variabilă dependentă

TV	radio	ziare	vânzări
230.1	37.8	69.2	22.1
44.5	39.3	45.1	10.4
17.2	45.9	69.3	9.3
151.5	41.3	58.5	18.5
180.8	10.8	58.4	12.9

n observații

p predictori

Definiție

Avem $p + 1$ variabile numerice și facem un set de n observații.

Definim:

- variabila pe care am dori să o prezicem și o numim **rezultatul** sau **variabila răspuns**; de obicei, notăm această variabilă prin Y iar observațiile/măsurătorile/valorile individuale prin y_i.
- variabilele pe care le folosim pentru a face predicțiile și le numim **caracteristici** (features) sau **variabile predictor**; de obicei, notăm aceste variabile prin $X = X_1, \dots, X_p$ iar valorile lor cu $x_{i,j}$.

Obs: i indexează observațiile ($i = 1, \dots, n$) iar j indexează valorile variabilei predictor ($j = 1, \dots, p$).

Modelare Statistică

Model real vs. Model Statistic

Vom presupune că variabila de răspuns, Y, este în legătura cu predictorii, X, prin intermediul unei funcții necunoscute exprimate în general ca:

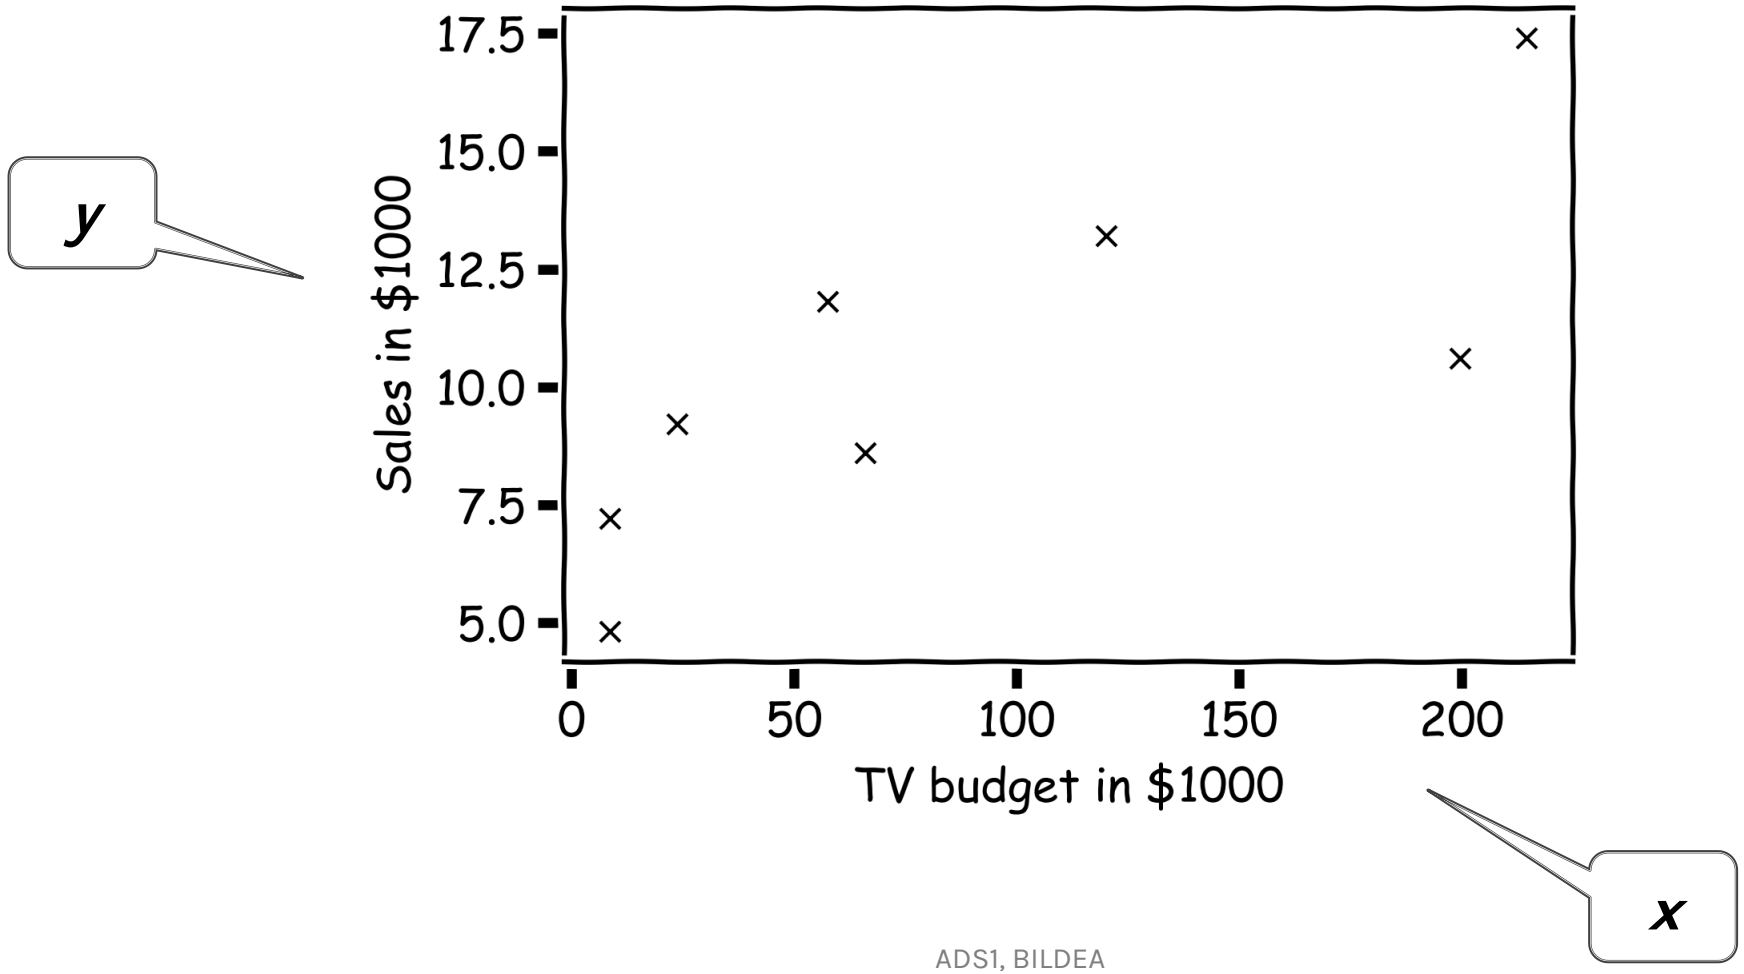
$$Y = f(X) + \varepsilon$$

Aici f este funcția necunoscută care exprimă o regulă de bază pentru relaționarea lui Y cu X, ε este cantitatea aleatoare(independentă de X) prin care Y diferă de funcția $f(X)$.

Un ***model*** (***statistic***) este orice algoritm care estimează funcția f.

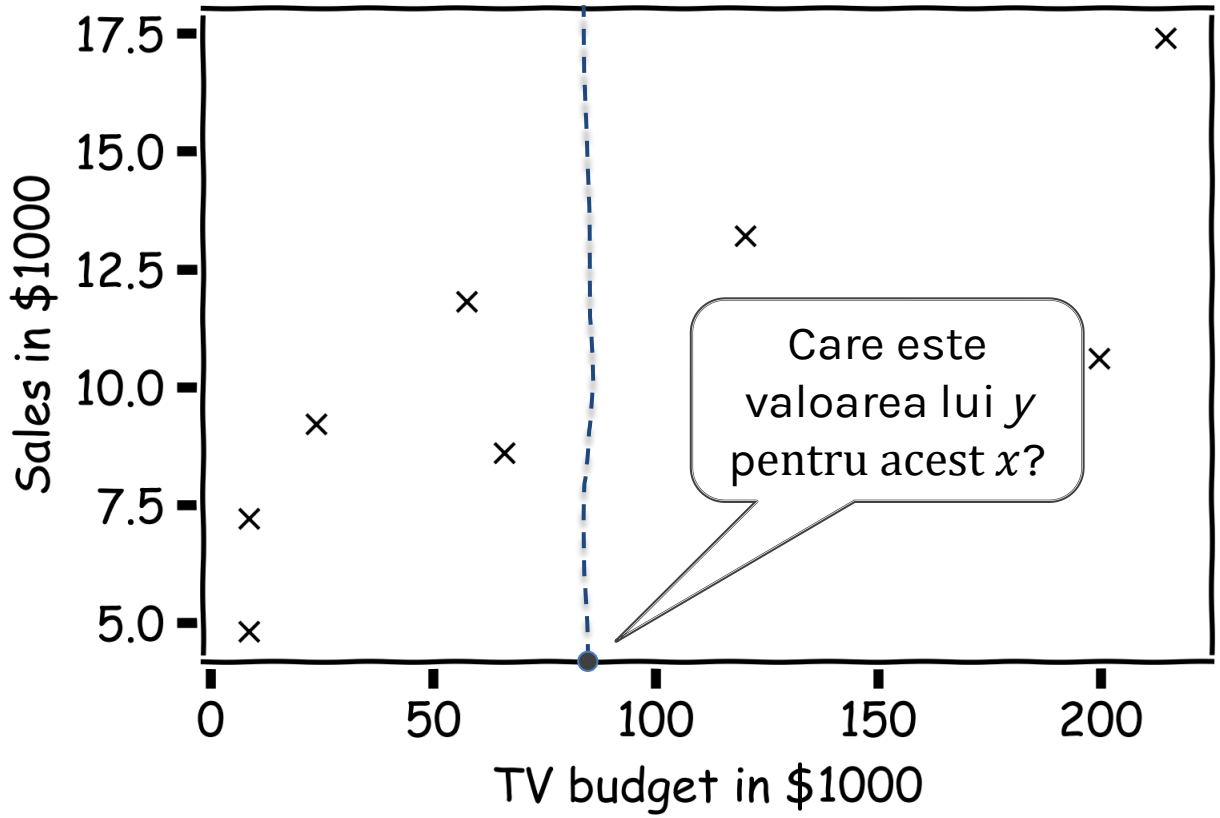
Notăm estimata funcției f cu $\widehat{f}$.

Model Statistic



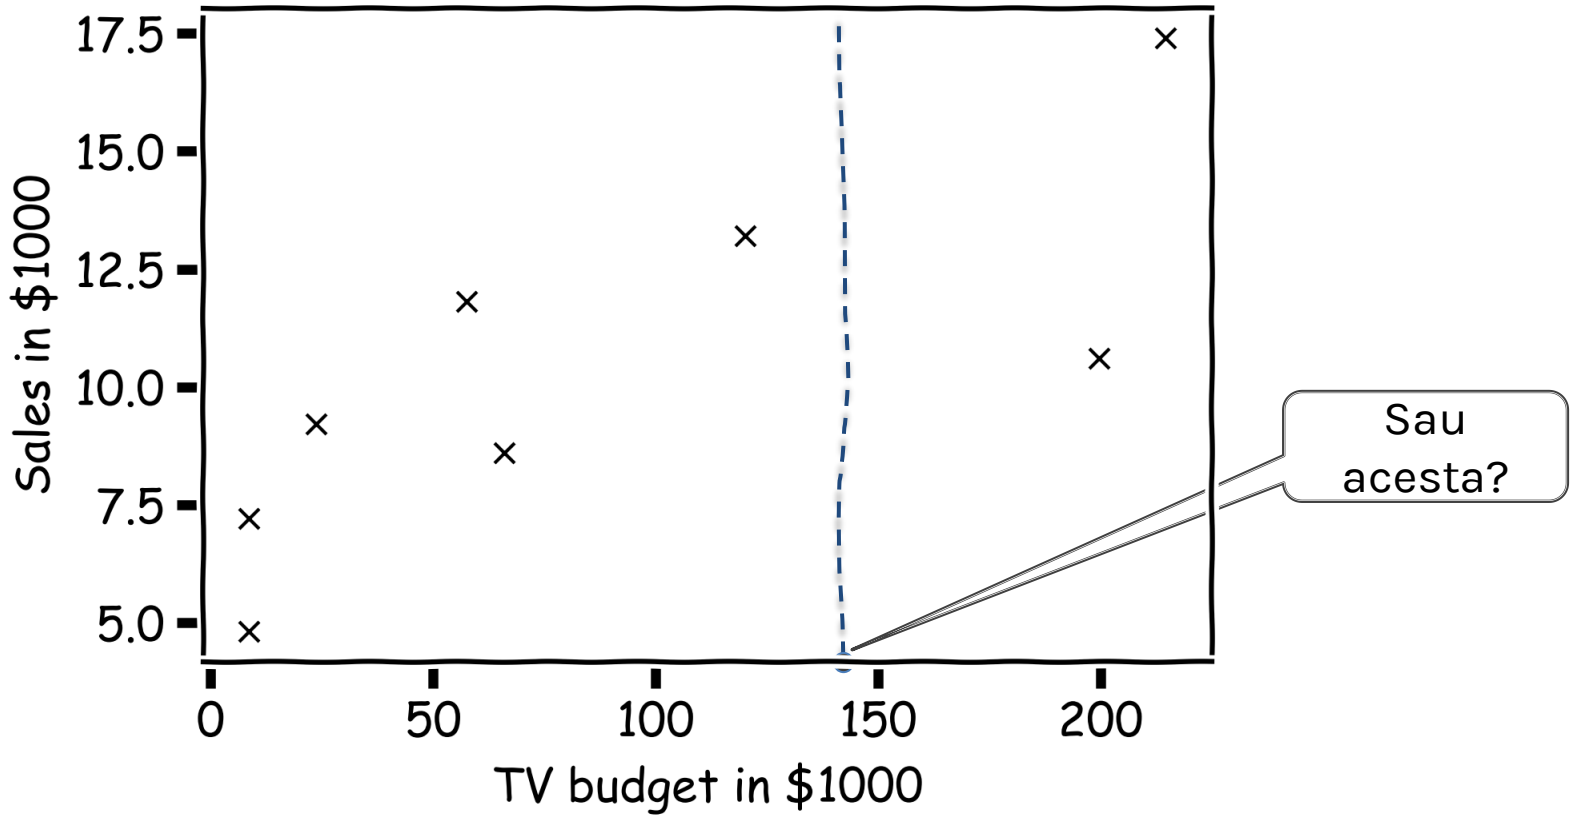
Model Statistic

Cum să găsim $\hat{f}(x)$?



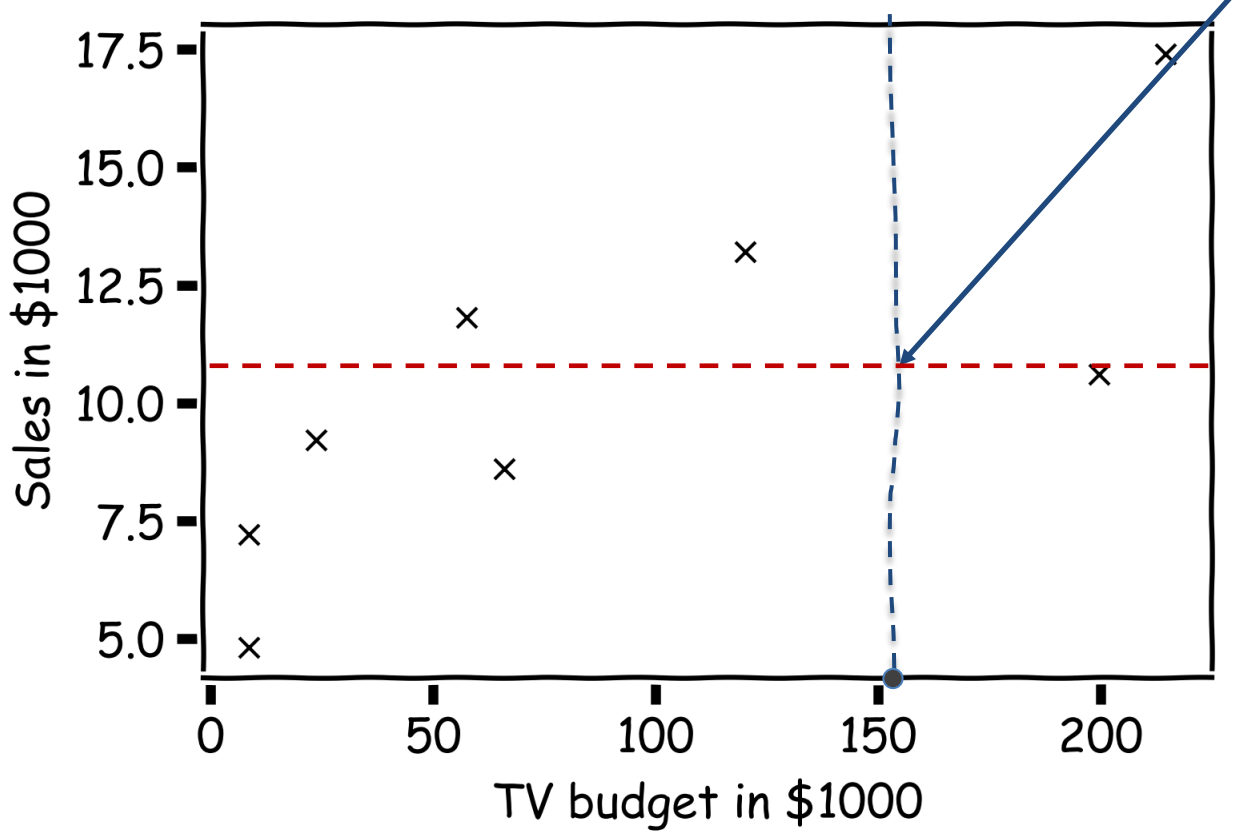
Model Statistic

Cum să găsim $\hat{f}(x)$?



Model Statistic

O idee simplă ar fi să facem media tuturor valorilor y, $\hat{f}(x) = \frac{1}{n}\sum_1^n y_i$



Predicție vs. Estimare

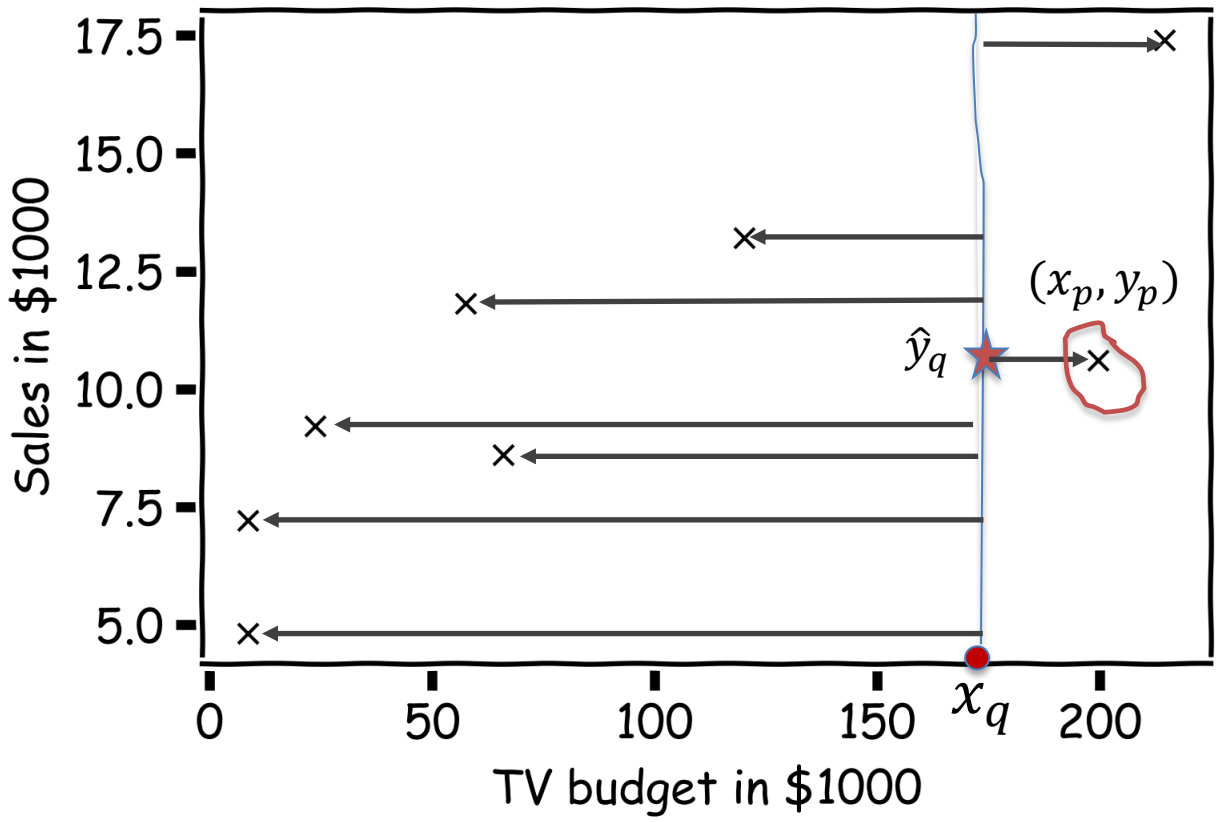
Pentru unele probleme, ceea ce este important este obținerea lui $\hat{f}$, estimarea lui f. Aceste probleme se numesc probleme de ***inferență***.

Când folosim un set de măsurători, $(x_{i,1}, \dots, x_{i,p})$ pentru a prezice o valoare pentru variabila de răspuns, notăm ***predicția*** cu:

$$\hat{y}_i = \hat{f}(x_{i,1}, \dots, x_{i,p}).$$

Pentru alte probleme, nu ne pasă de forma specifică a lui $\hat{f}$, vrem doar să ne asigurăm că predicțiile $\hat{y}$ sunt cât se poate de apropiate de valorile observate y. Aceste probleme se numesc probleme de ***predicție/prognoză.***

Model Simplu de Predicție



Care ar fi un bun $\hat{y}_q$ pentru un x_q ?

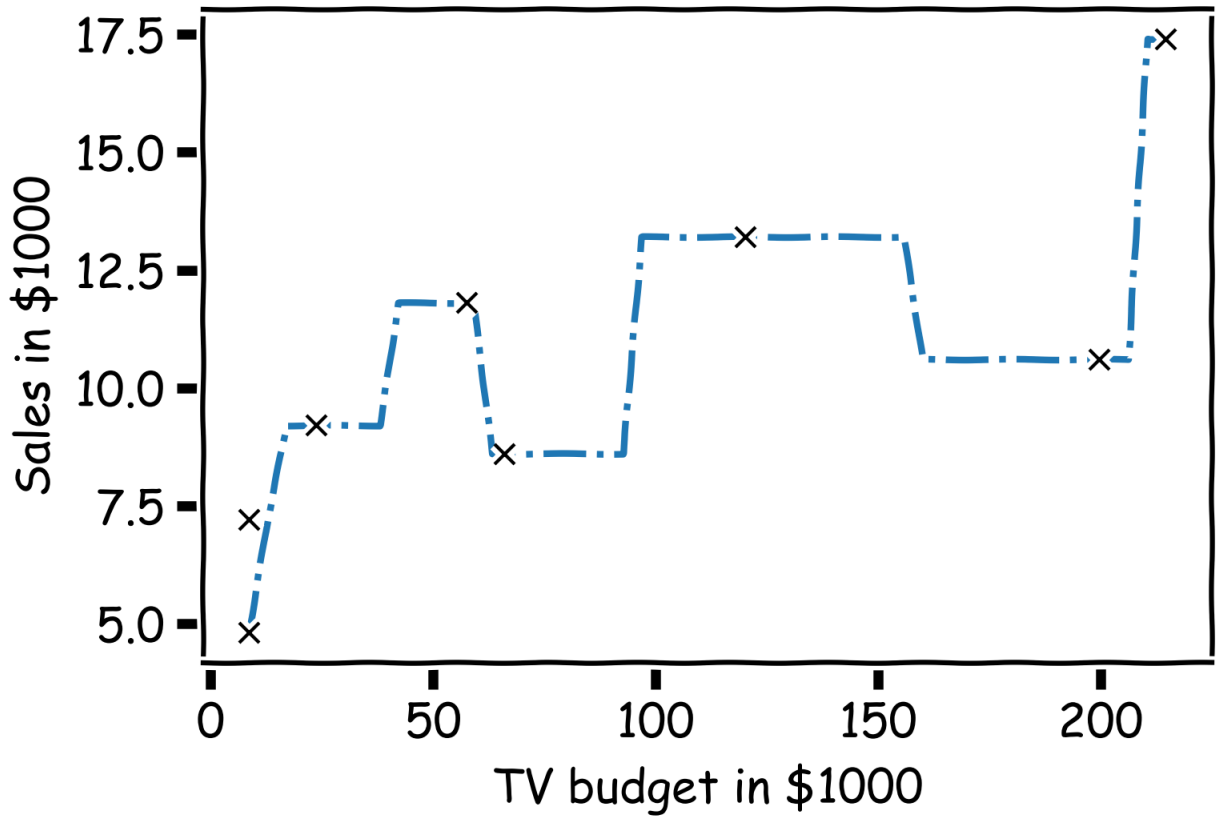
Găsim distanțe față de toate celelalte puncte $D(x_q, x_i)$

Găsim cel mai apropiat vecin, (x_p, y_p)

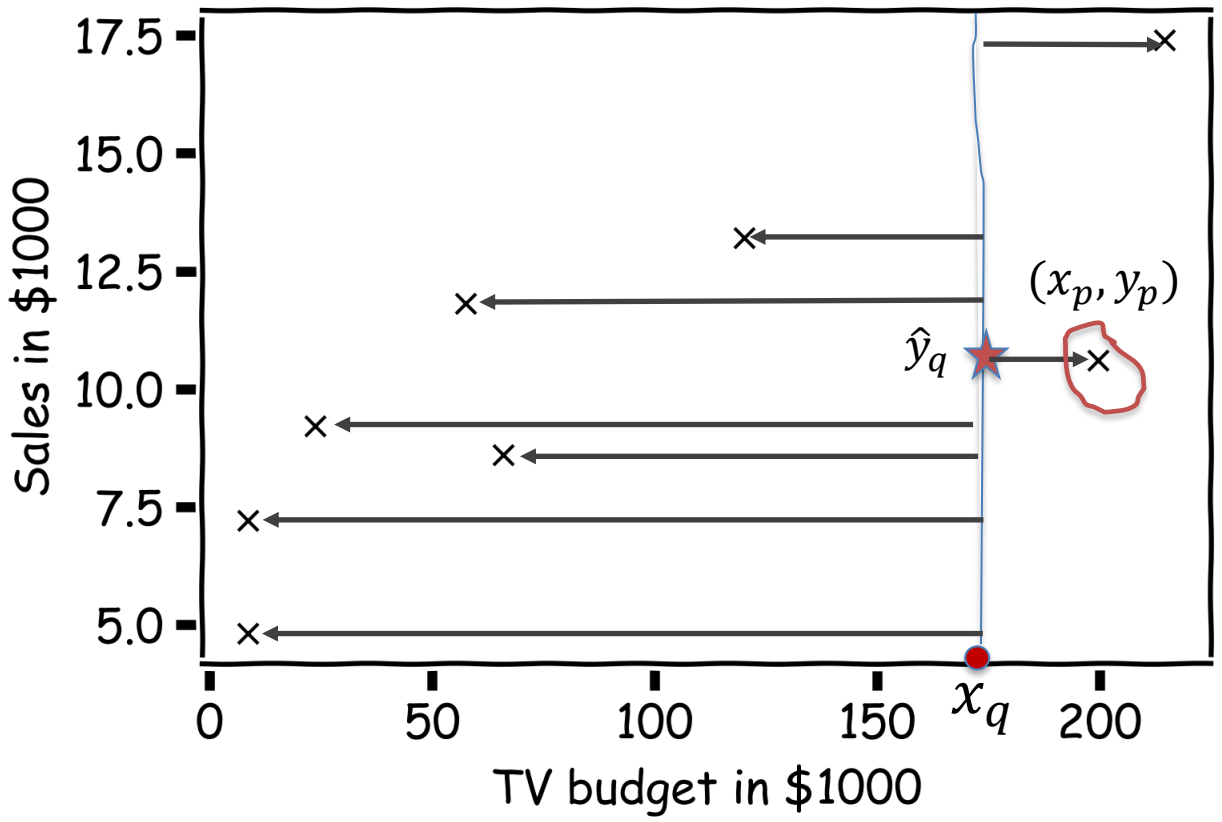
Predicția: $\hat{y}_q = y_p$

Model Simplu de Predicție

Facem asta pe rând pentru toate valorile x



Extensia Modelului Simplu



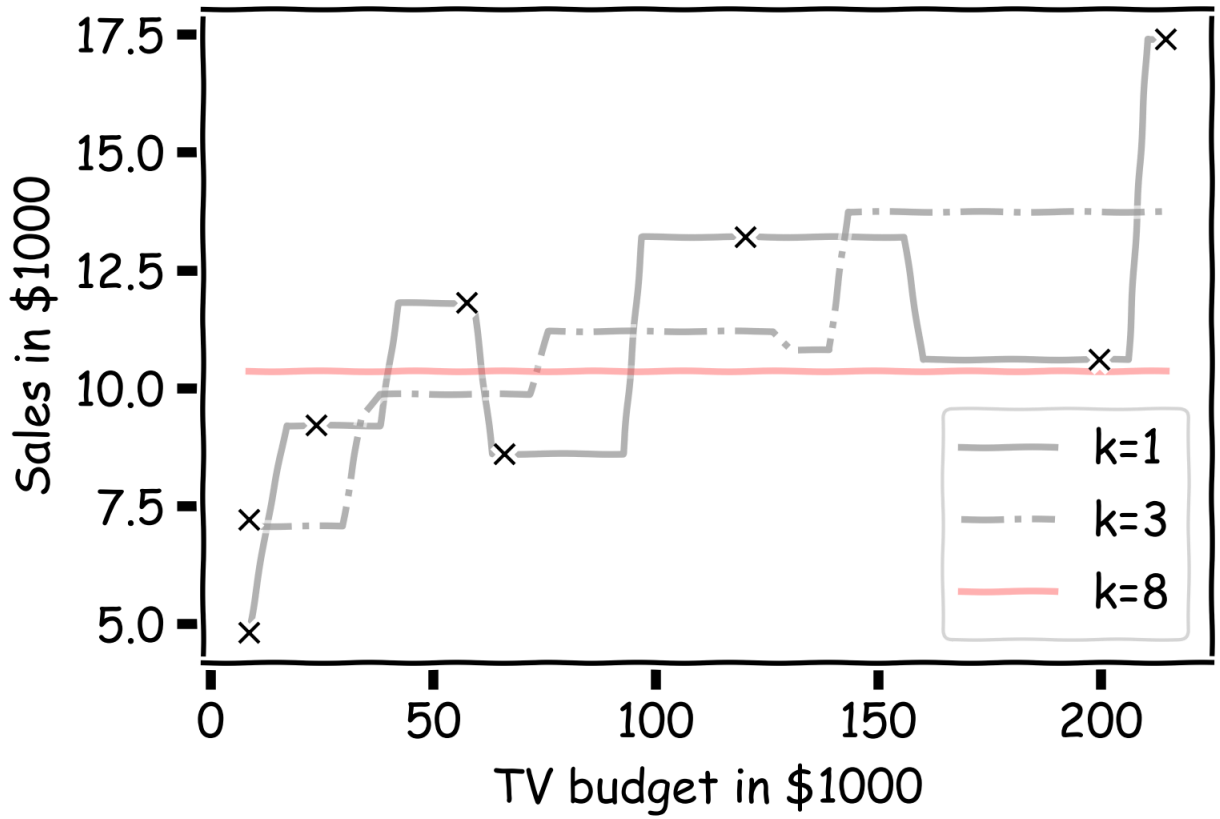
Care ar fi un bun $\hat{y}_q$ pentru un x_q ?

Găsim distanțe față de toate celelalte puncte $D(x_q, x_i)$

Găsim cei mai apropiați k vecini, $x_{q_1}, \dots, x_{q_k}$

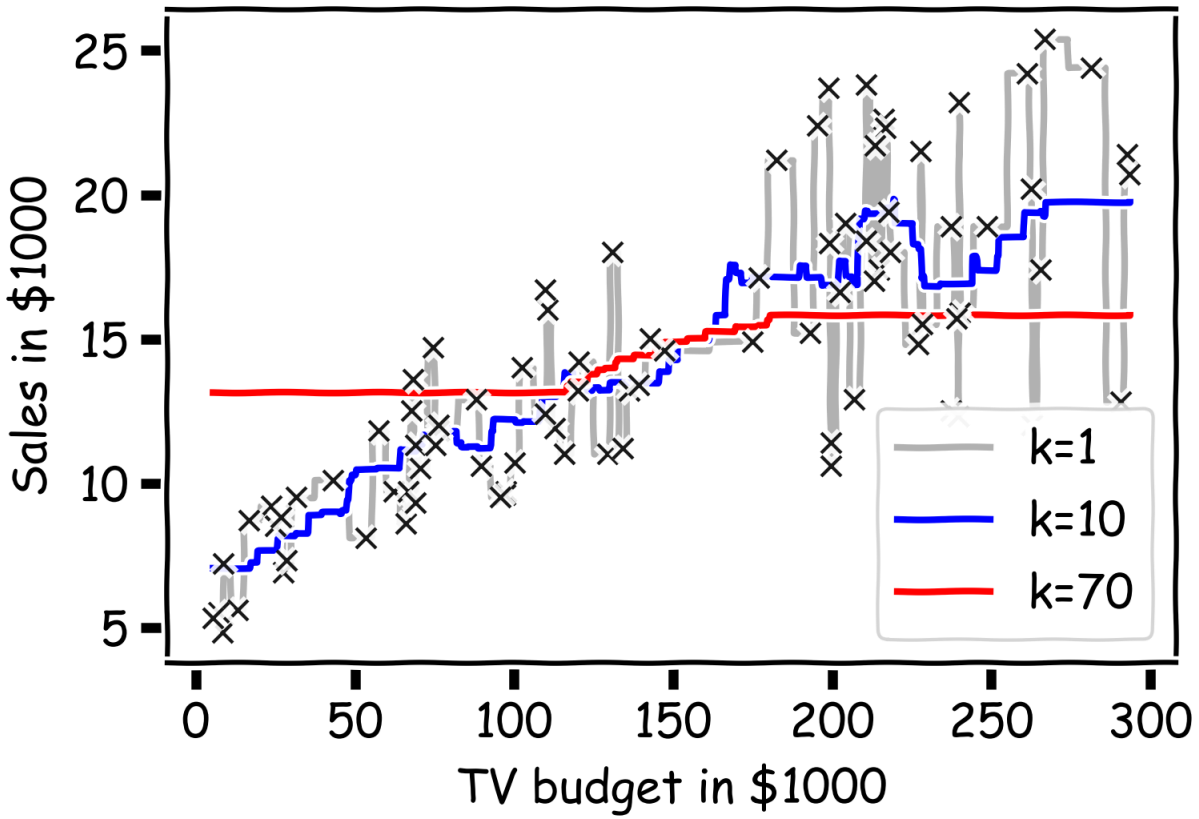
Predicția: $\widehat{y_q} = \frac{1}{k}\sum_i^k y_{q_i}$

Model Simplu de Predicție și Extensii la k - vecini



Model Simplu de Predicție

Putem încerca diferite valori k pe mai multe date



k-Nearest Neighbors (cei mai apropiați k vecini)

Modelul ***k-Nearest Neighbor (kNN)*** este o modalitate intuitivă de a prezice o variabilă de răspuns cantitativă:

> *pentru a prezice un răspuns pentru un set de valori predictor observate, folosim răspunsurile altor observații cât mai similare cu acesta*

Observație: această strategie poate fi aplicată și în clasificare pentru a prezice o variabilă categorială. Vom întâlni din nou kNN mai târziu în curs, în contextul clasificării.

k-Nearest Neighbors - kNN

Pentru un k fixat, răspunsul prognozat pentru a q-a observație este media răspunsului observat al celor mai apropiate k observații:

$$\hat{y}_q = \frac{1}{k}\sum_{i}^{k} y_{q_i}$$

unde $\{x_{q1}, \ldots, x_{qk}\}$ sunt cele k observații cele mai 'similare' to x_q (*similar* se referă aici la noțiunea de distanță între valorile predictorilor, apropierea fiind interpretată ca și similaritate – aceasta este strategia kNN).

Unde suntem:

Modelare statistică

k-Nearest Neighbors (kNN)

Evaluarea modelului

Cât de bun e modelul pentru prognoză?

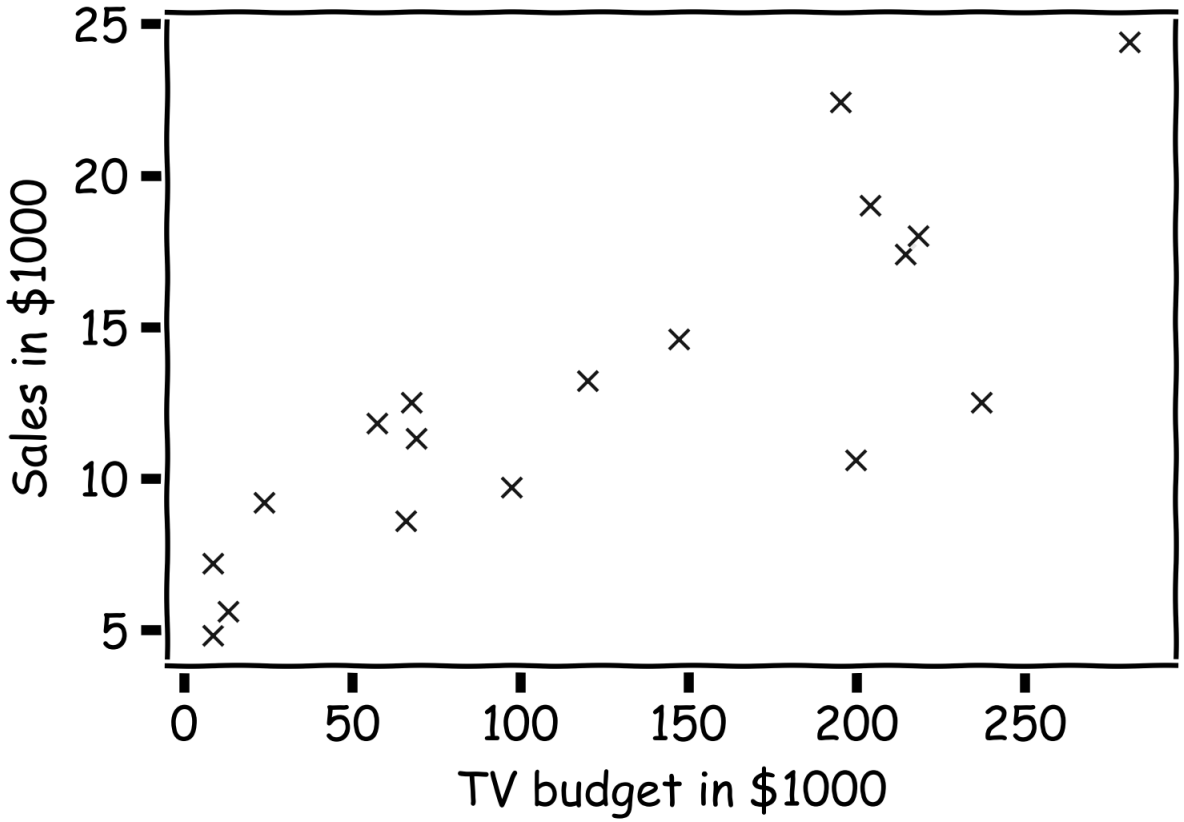
Compararea a două modele statistice

Cum putem alege între două modele?

Evaluarea Modelului

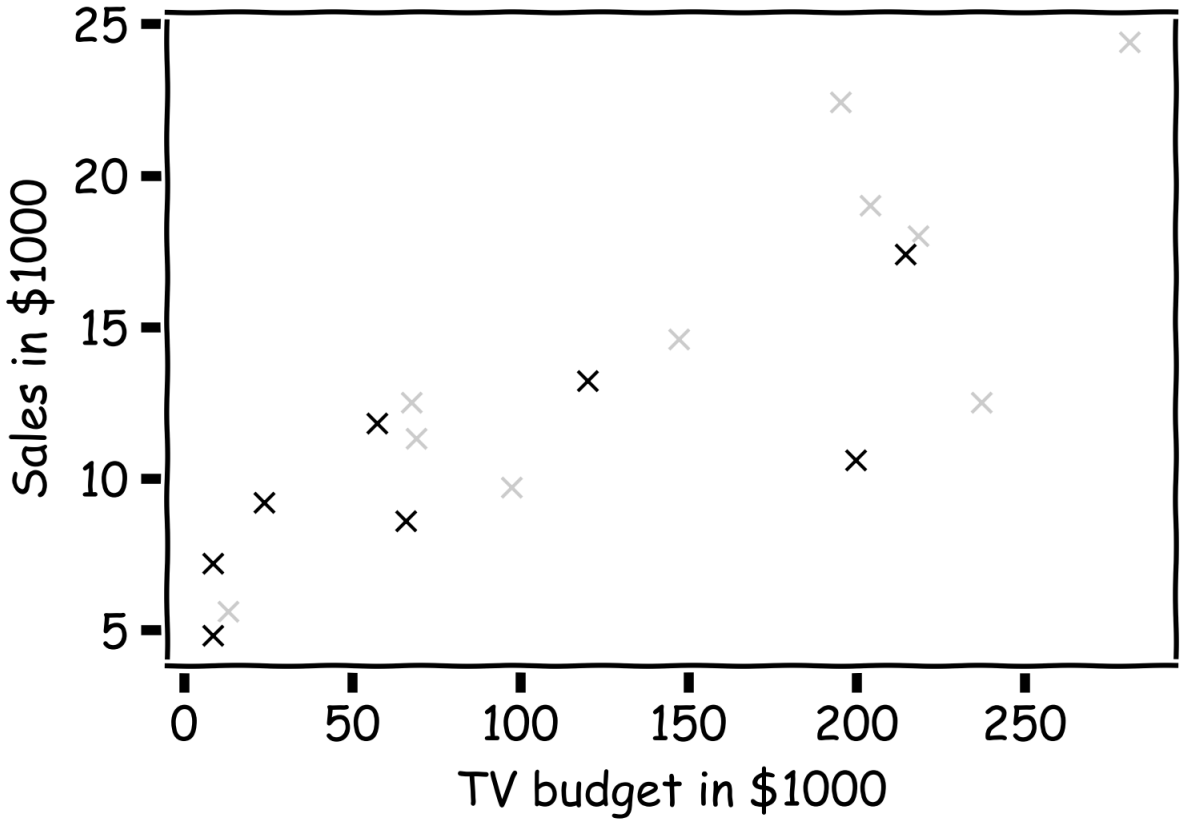
Evaluarea Erorilor

Revenim la date.



Evaluarea Erorilor

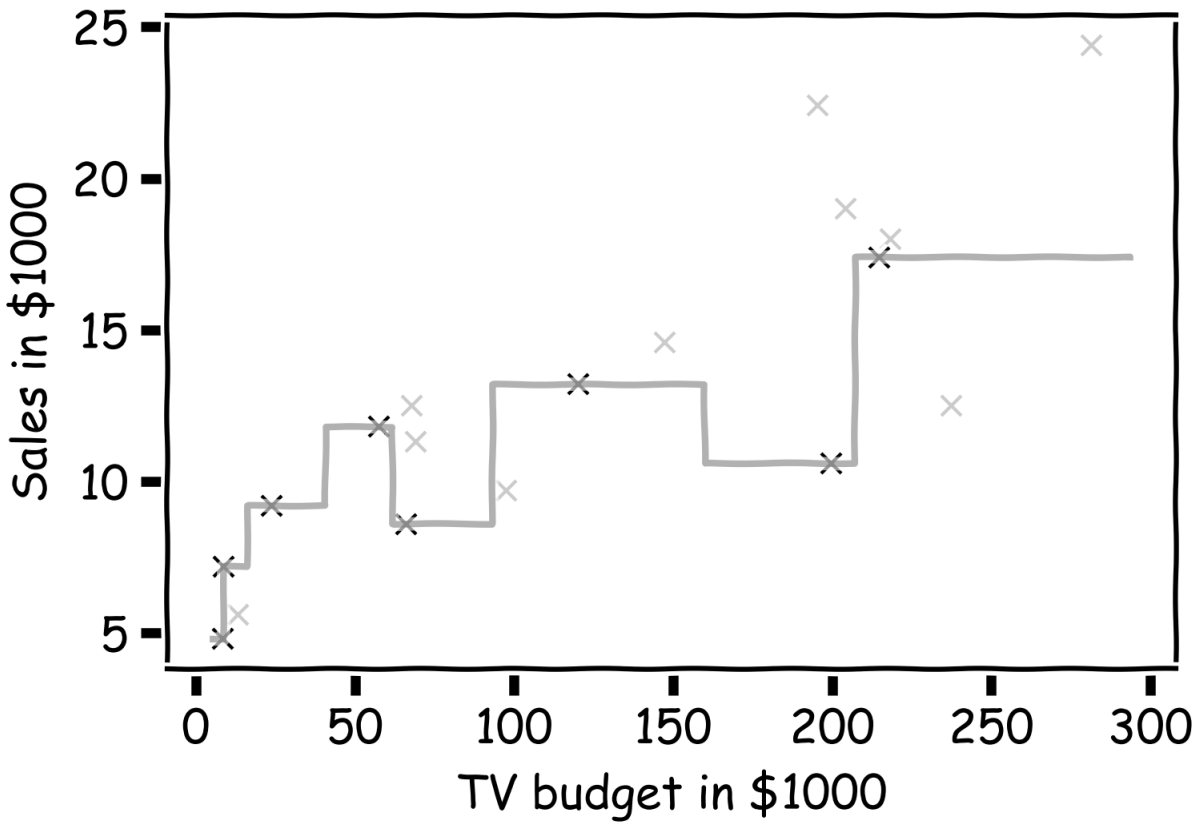
Ascundem parte din date. Aceasta este spargerea datelor în date de antrenament și date de test: **train-test** split.



Folosim datele de antrenament să estimăm $\hat{y}$, și cele de test să evaluăm modelul rezultat.

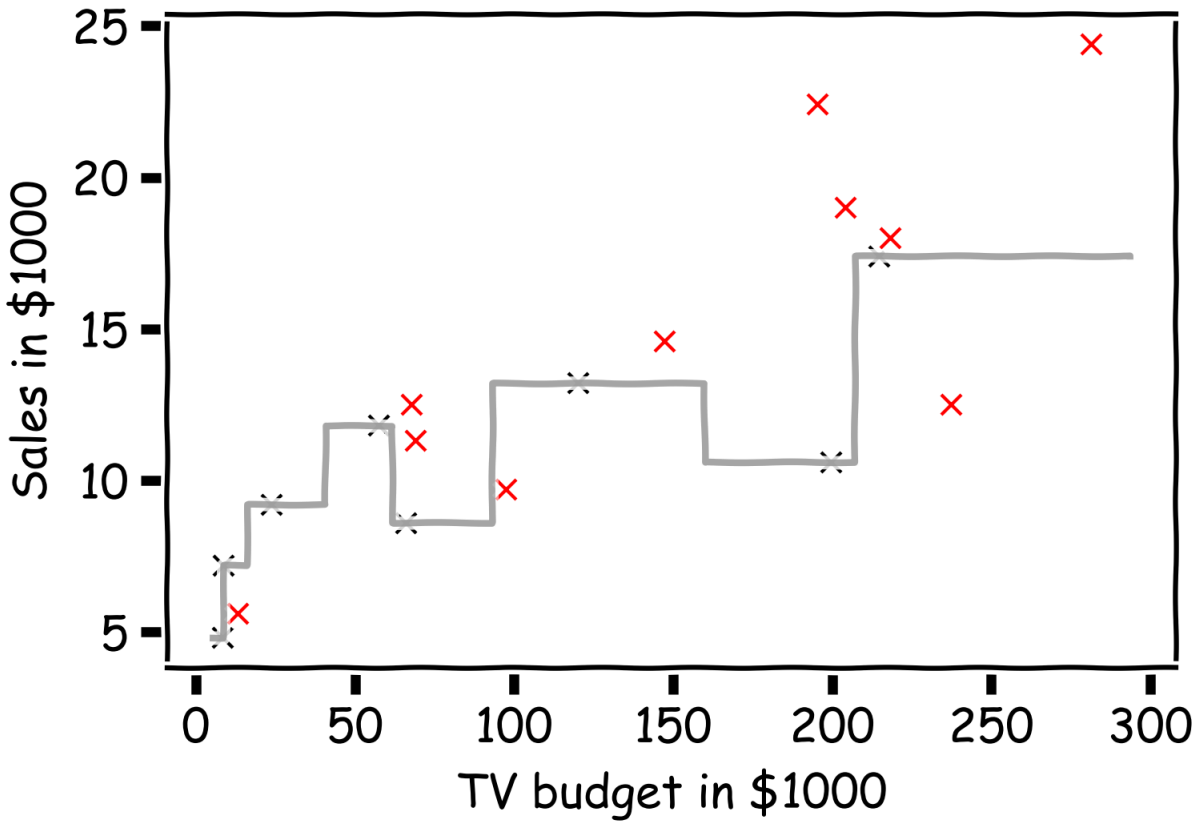
Evaluarea Erorilor

Estimare $\hat{y}$ pentru *k=1*.



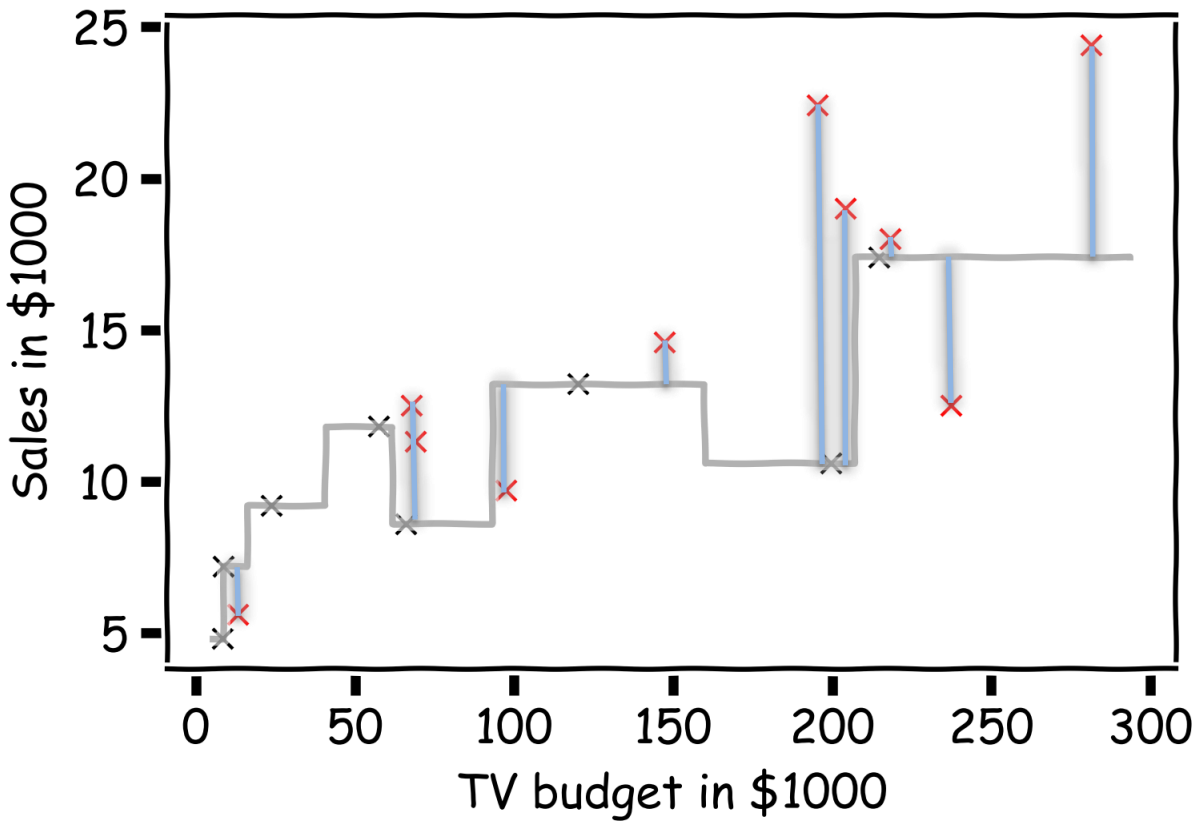
Evaluarea Erorilor

Acum ne uităm la datele nefolosite în modelare, setul de date de **test** (marcate cu roșu).



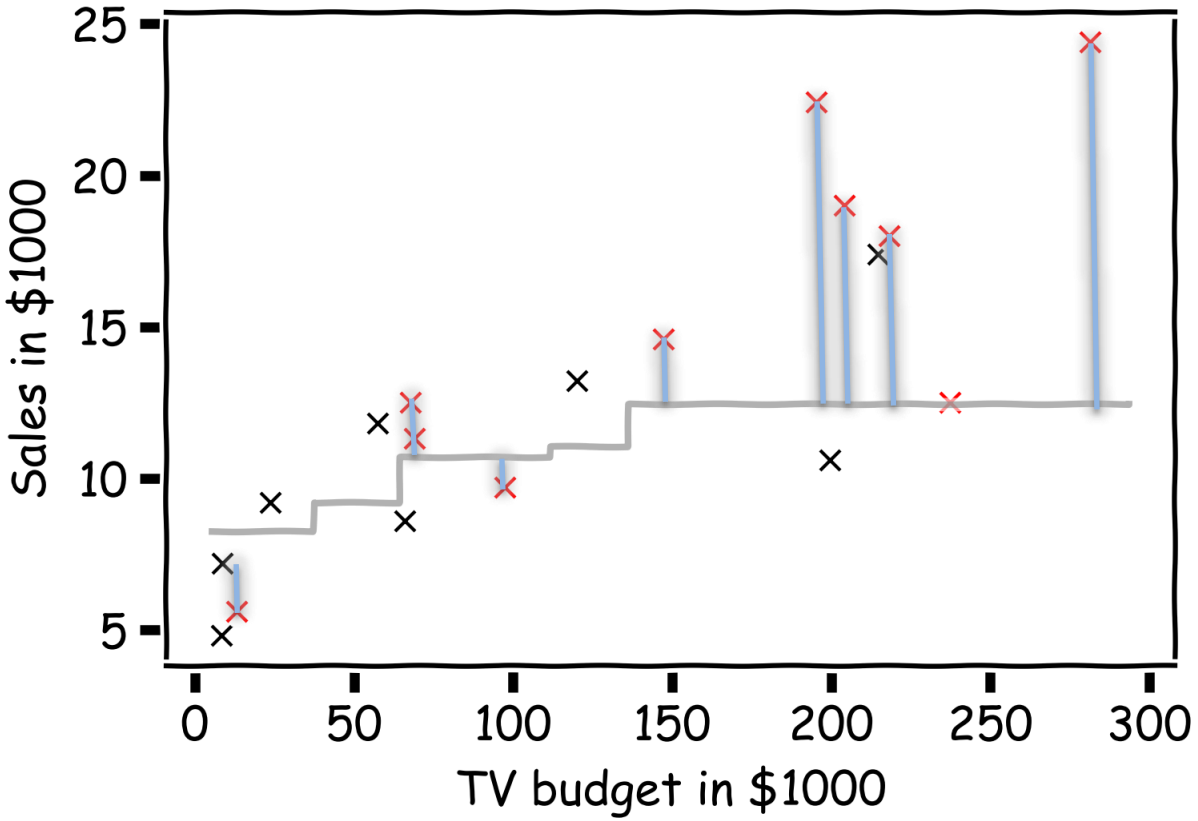
Evaluarea Erorilor

Calculăm **reziduurile** $(y_i - \hat{y}_i)$.



Evaluarea Erorilor

Facem la fel pentru *k=3.*



Evaluarea Erorilor

Pentru a cuantifica cât de bine funcționează un model, definim o funcție pierdere (***loss***) sau eroare (***error function***).

O funcție uzuală în acest sens este Eroarea Medie Pătratică - **Mean Squared Error (MSE):**

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \widehat{y}_i)^2$$

Cantitatea $y_i - \hat{y}_i$ se numește ***reziduul*** și măsoară eroarea celei de a *i*-a predicții.

Evaluarea Erorilor

Atenție: Eroarea medie pătratică nu este unica funcție de acest fel și nici cea mai bună!

Întrebare: Cum am putea măsura eroarea în cazul variabilelor țintă categoriale (clasificare)?

Observație: Abaterea medie pătratică - the square **R**oot of the **M**ean of the **S**quared **E**rrors sau (RMSE) este de asemena foarte des folosită.

$$RMSE = \sqrt{MSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \widehat{y_i})^2}$$

Unde am ajuns:

Modelare statistică

k-Nearest Neighbors (kNN)

Evaluarea modelului

Cât de bun e modelul pentru prognoză?

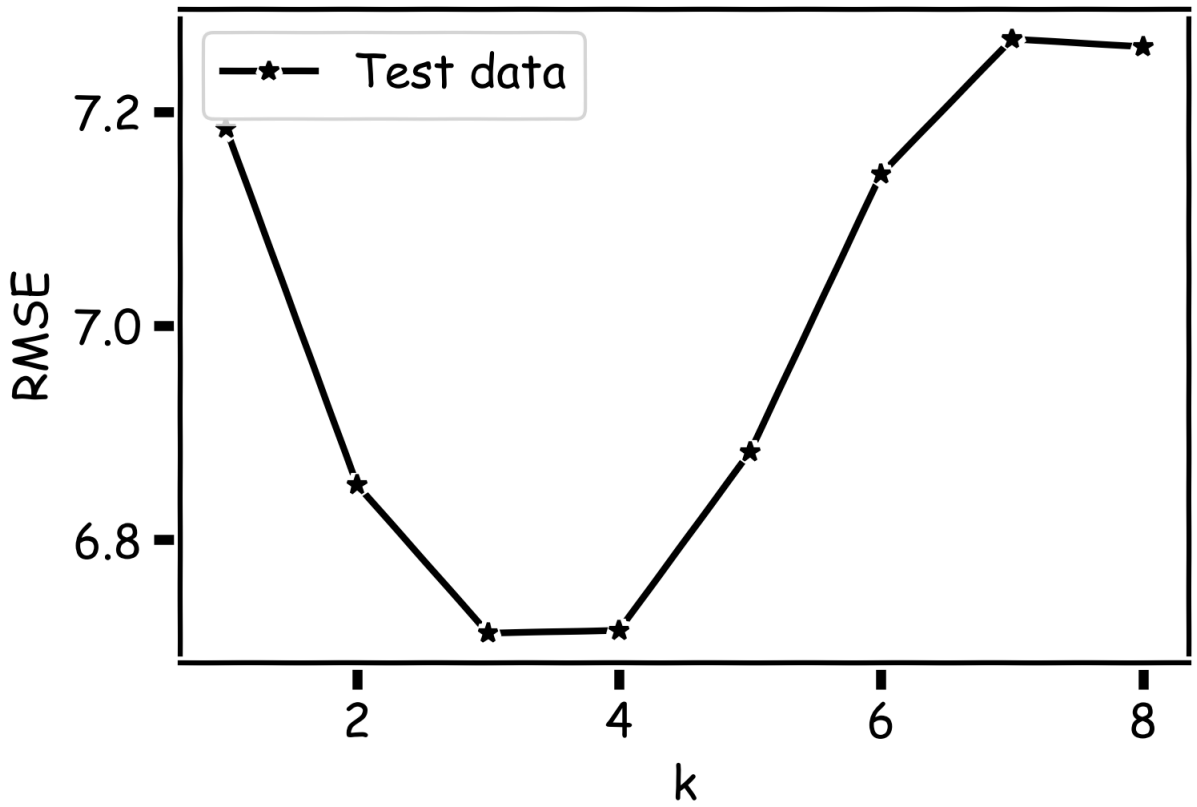
Compararea a două modele statistice

Cum putem alege între două modele?

Compararea modelelor

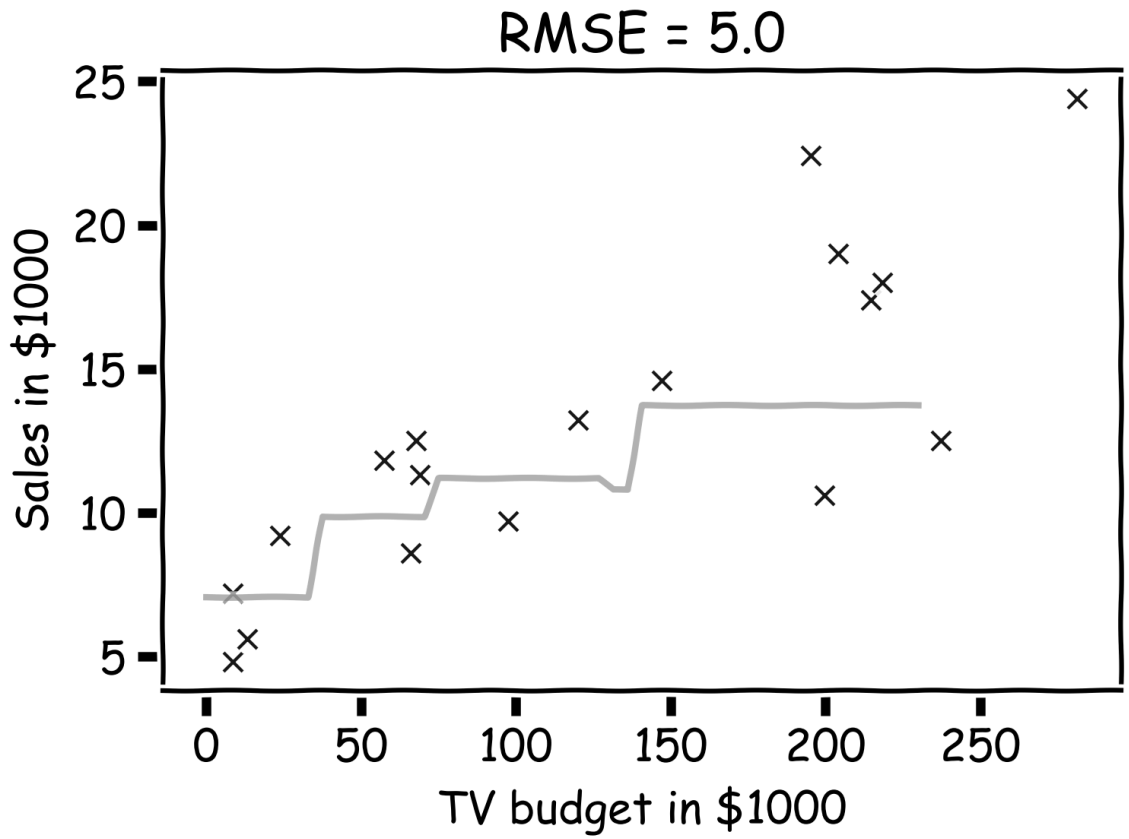
Compararea modelelor

Calculăm erorile pentru diferite valori ale lui *k* și comparăm RMSE-urile. *k=3* pare cea mai buna alegere.



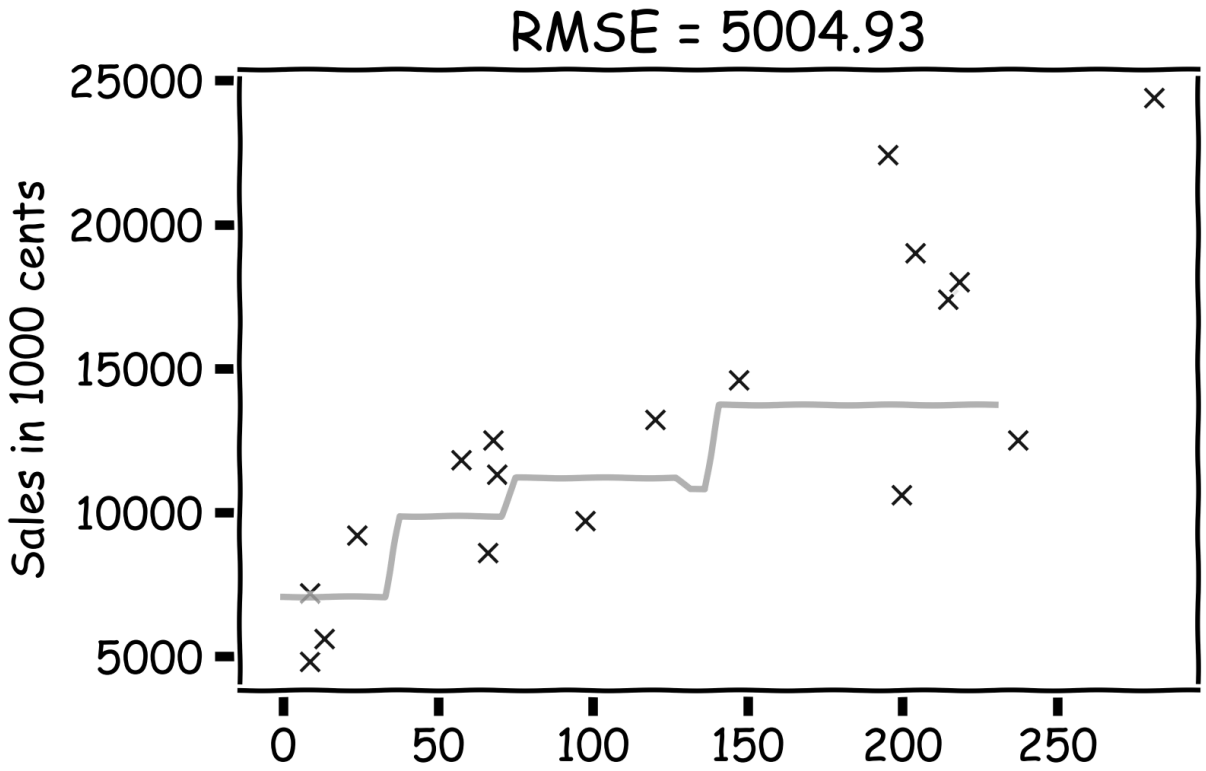
Evaluarea modelului

Pentru o submulțime de antrenament calculăm RMSE pentru *k=3.*
Este o valoare RMSE=5.0 suficient de bună?



Evaluarea modelului

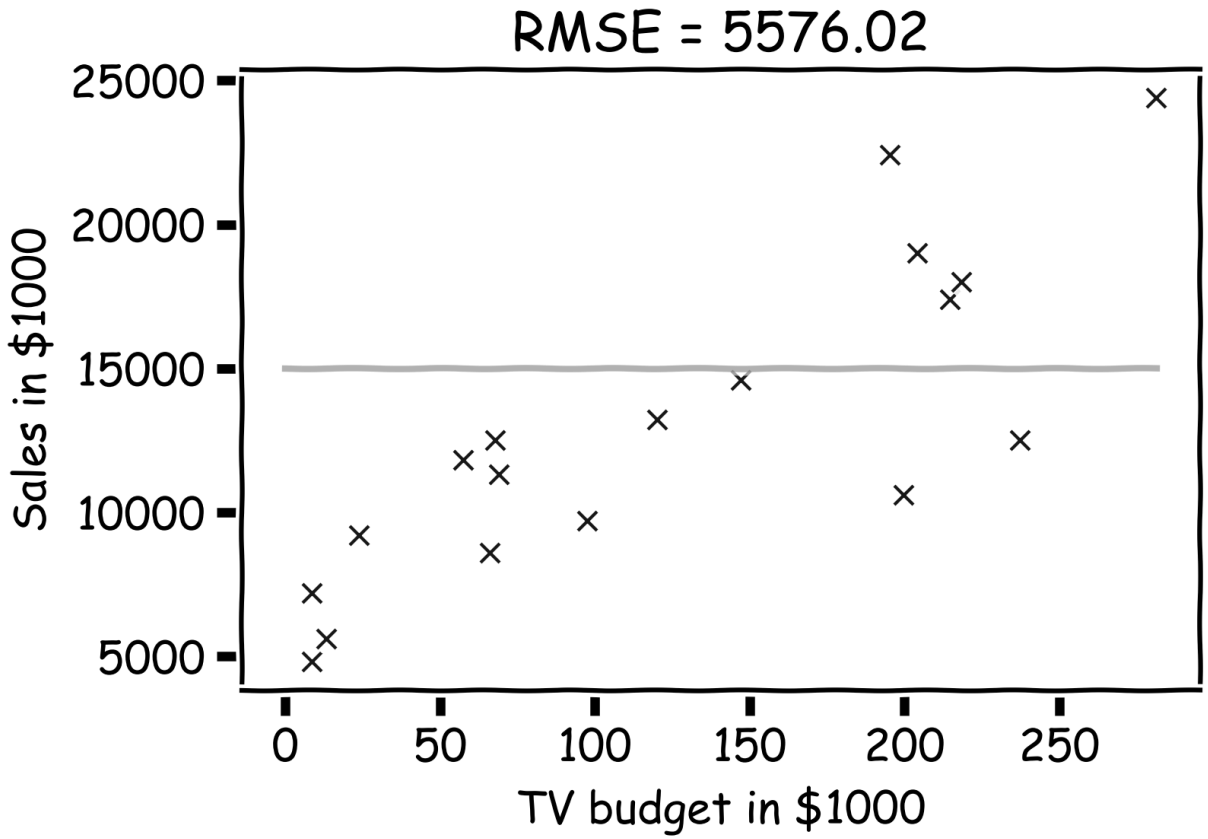
Dar dacă măsurăm vânzările în cenți în loc de dolari?



RMSE este 5004.93.
E bine așa?

Evaluarea modelului

Cel mai bine să comparăm cu ceva.



Folosim cel mai simplu model:

$$\hat{y} = \frac{1}{n}\sum_{i}^{n} y_i$$

R-pătrat (R-squared)

$$R^2 = 1 - \frac{\sum_i (\hat{y}_i - y_i)^2}{\sum_i (\bar{y} - y_i)^2}$$

- Dacă modelul e la fel de bun ca media, $\bar{y}$, atunci $R^2 = 0$
- Dacă modelul e perfect atunci $R^2 = 1$
- R^2 poate fi negativ dacă modelul rezultat e mai prost ca media. Asta se poate întâmpla în practică, atunci când evaluăm pe datele de test.

Media erorilor absolute la predicție – MAE, MAPE

- În practica modelelor de învățare cu supervizare, comparația modelelor se face pe un set de date adnotat pentru a evalua performanța la pronoza pe date ***noi***
- Alte două metode utilizate frecvent sunt:

$$MAE = \frac{1}{n}\sum_{i} |y_i - \hat{y}_i|$$

$$MAPE = \frac{1}{n}\sum_{i} \left|\frac{y_i - \hat{y}_i}{y_i}\right|$$

Recapitulare

Modelare statistică

k-Nearest Neighbors (kNN) – exemplu de modelare statistică

Evaluarea modelului

Cât de bun e modelul pentru prognoză? - MSE, RMSE, MAE

Compararea a două modele statistice

Cum putem alege între două modele? - R^2, MAE, MAPE pe date test

Regresie Liniară Simplă



Planul cursului

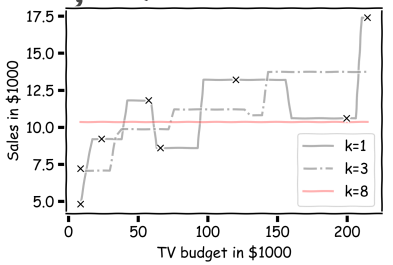
- Modele Liniare
- Estimarea coeficienților de regresie
  - Metoda exactă
  - Metoda Gradientului - Gradient Descent
- Intervale de încredere pentru estimările predictorilor

Planul cursului

- **Modele Liniare**
- Estimarea coeficienților de regresie
  - Metoda exactă
  - Metoda Gradientului - Gradient Descent
- Intervale de încredere pentru estimările predictorilor

Modele liniare

Rețineți că, în construirea modelului nostru kNN pentru predicție, nu am calculat o formă închisă pentru $\hat{f}$.



Dar ce facem cu o întrebare de tipul:

"cât de mult ne așteptăm să crească vânzările dacă dublăm bugetul publicității TV?"

Alternativ, putem construi un model presupunând mai întâi o formă simplă de pentru f:

$$Y = f(X) + \epsilon = \beta_1 X + \beta_0 + \epsilon.$$

Regresie liniară

... apoi rezultă că estimatorul nostru este:

$$\widehat{Y} = \widehat{f}(X) = \widehat{\beta_1} X + \widehat{\beta_0}$$

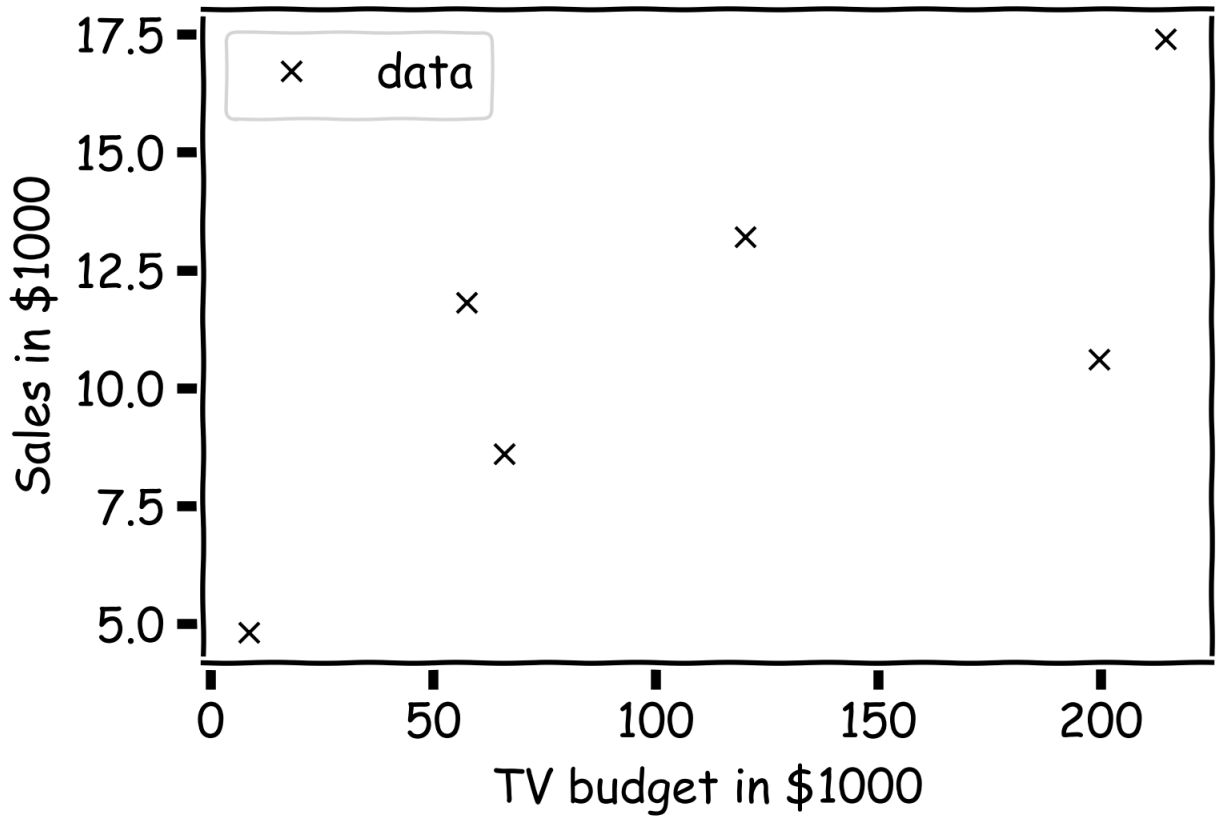
unde $\hat{\beta}_1$ și $\hat{\beta}_0$ sunt **estimări** pentru β_1 și β_0 respectiv, și le calculăm folosind observațiile.

Planul cursului

- Modele Liniare
- **Estimarea coeficienților de regresie**
  - Metoda exactă
  - Metoda Gradientului - Gradient Descent
- Intervale de încredere pentru estimările predictorilor

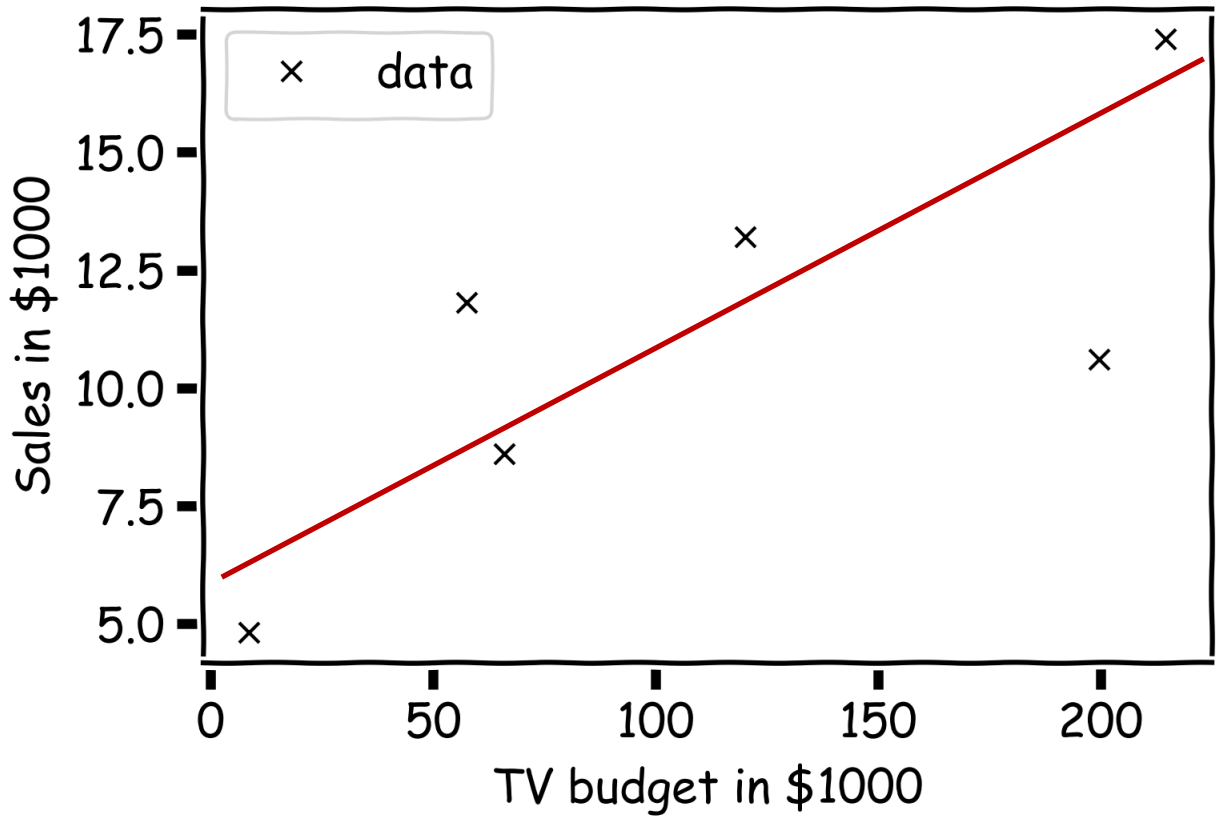
Estimarea coeficienților de regresie

Fie un set de date



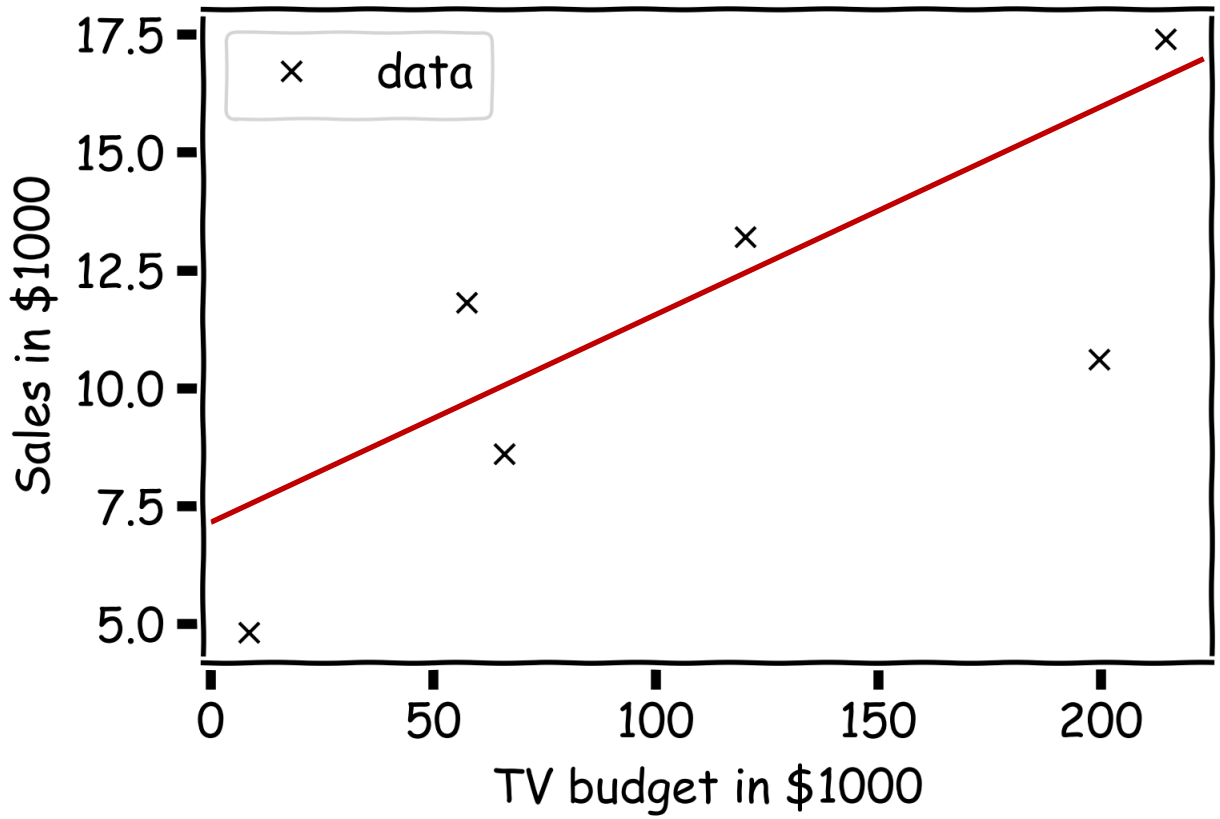
Estimarea coeficienților de regresie (cont)

Este linia asta bună?



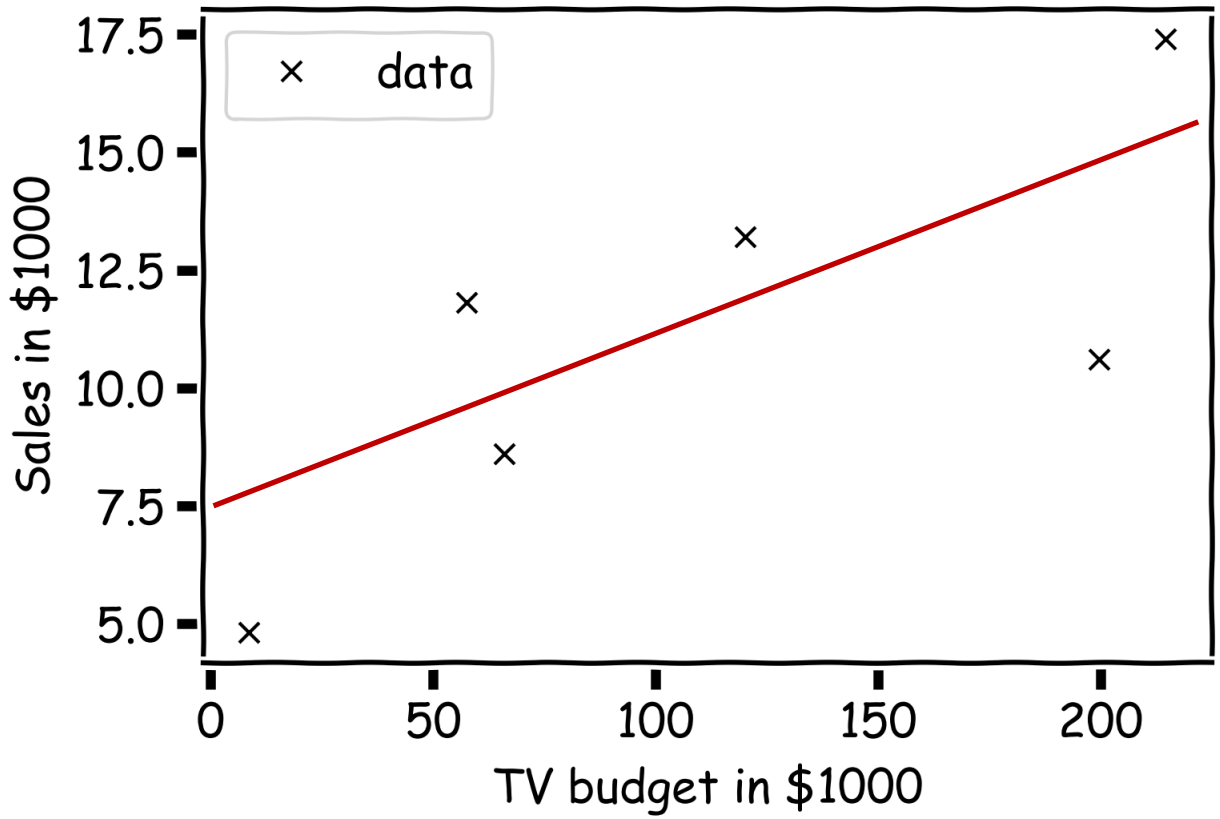
Estimarea coeficienților de regresie (cont)

Poate asta?



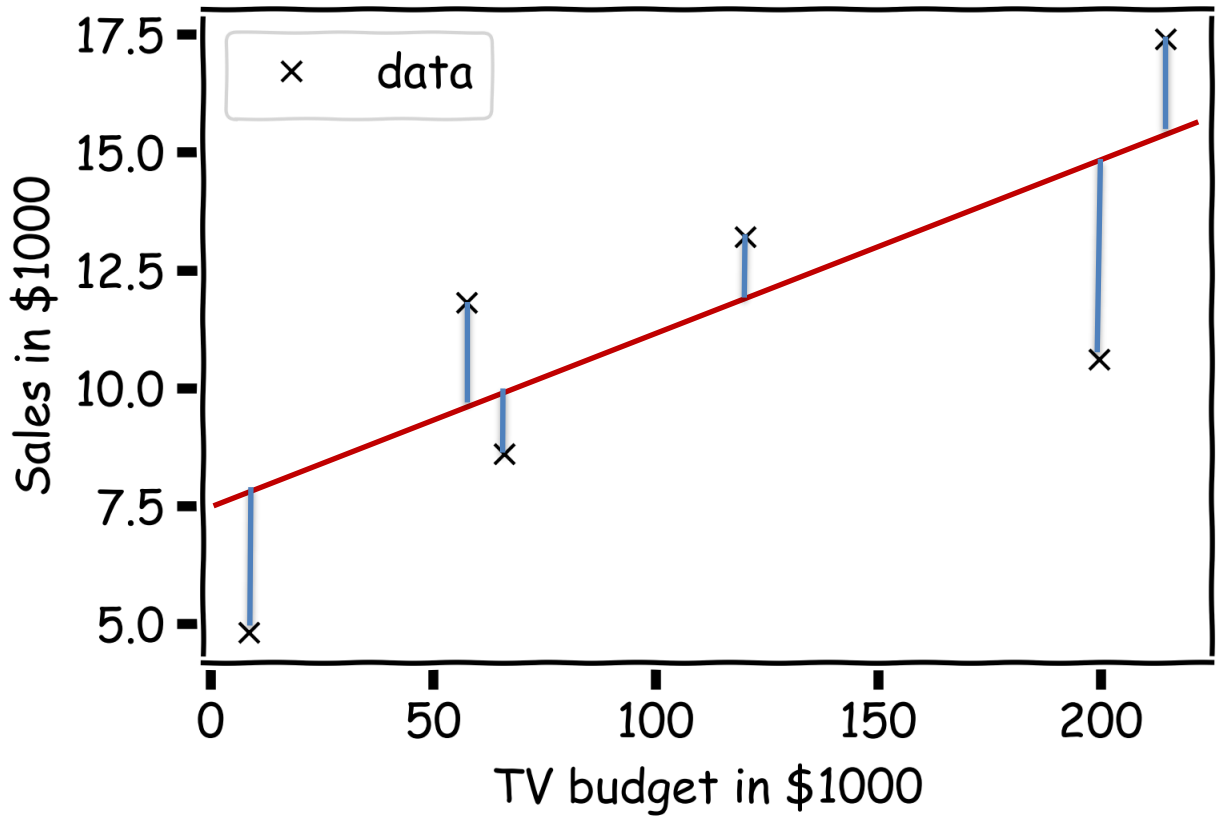
Estimarea coeficienților de regresie (cont)

Dar asta?



Estimarea coeficienților de regresie (cont)

Întrebare: Care linie este cea mai bună?
Calculăm reziduurile!



Estimarea coeficienților de regresie (cont)

Folosim MSE ca și pierdere (**loss function)**,

$$L(\beta_0, \beta_1) = \frac{1}{n}\sum_{i=1}^{n}(y_i - \widehat{y}_i)^2 = \frac{1}{n}\sum_{i=1}^{n}[y_i - (\beta_1 X + \beta_0)]^2 .$$

Alegem $\hat{\beta}_1$ și $\hat{\beta}_0$ pentru a minimiza erorile predictive făcute de modelul nostru, adică pentru a minimiza pierderea.

Valorile optime pentru $\hat{\beta}_0$ și $\hat{\beta}_1$ ar fi:

$$\widehat{\beta}_0, \widehat{\beta}_1 = \underset{\beta_0, \beta_1}{\operatorname{argmin}} L(\beta_0, \beta_1).$$

Estimarea coeficienților de regresie: metoda exactă

Calculați derivatele parțiale ale lui L la β_0 și β_1, egalați cu zero, și găsiți soluția ecuației. Această procedură dă soluția exactă pentru $\hat{\beta}_0$ și $\hat{\beta}_1$:

$$\hat{\beta}_1 = \frac{\sum_i (x_i - \overline{x})(y_i - \overline{y})}{\sum_i (x_i - \overline{x})^2}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

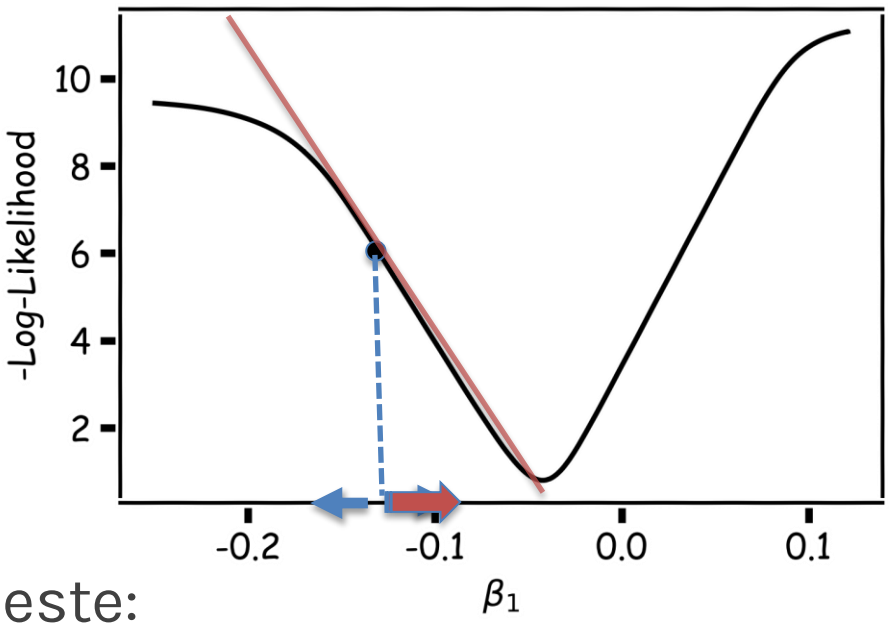
unde $\bar{y}$ și $\bar{x}$ sunt mediile de eșantion.

Linia:

$$\widehat{Y} = \widehat{\beta}_1 X + \widehat{\beta}_0$$

se numește linie de regresie.

Estimarea coeficienților de regresie: gradient descent



O metodă mai flexibilă este:

1. Porniți dintr-un punct arbitar
2. Determinați în ce direcție să mergeți pentru a reduce eroarea (stânga sau dreapta):

   Calculați panta funcției în acest punct și treceți la dreapta dacă panta este negativă sau treceți la stânga dacă panta este pozitivă
3. Înapoi la #1

Estimarea coeficienților de regresie: gradient descent

Întrebare: Care este funcția matematică care descrie panta?

Derivata

Întrebare : Care credeți că este o abordare bună pentru a spune modelului cum să se schimbe (care este dimensiunea pasului) pentru a deveni mai bun?

Dacă pasul este proporțional cu panta, atunci evitați depășirea minimului

Întrebare : Cum generalizăm acest lucru la mai mult de un predictor?

Calculați derivata în raport cu fiecare coeficient și faceți același lucru secvențial

Estimarea coeficienților de regresie: gradient descent

Știm că vrem să mergem în direcția opusă derivatei și știm că vrem să facem un pas proporțional cu derivata.

Notație: $w = \beta_0, \beta_1$

Să facem un pas înseamnă:

$$w^{nou} = w^{vechi} + pas$$

Direcția opusă a derivatei și proporțională cu panta (derivata) înseamnă:

$$w^{nou} = w^{vechi} - \lambda \frac{d\mathcal{L}}{dw}$$

Rata de învățare (learning rate)

Cu o notație mai convențională:

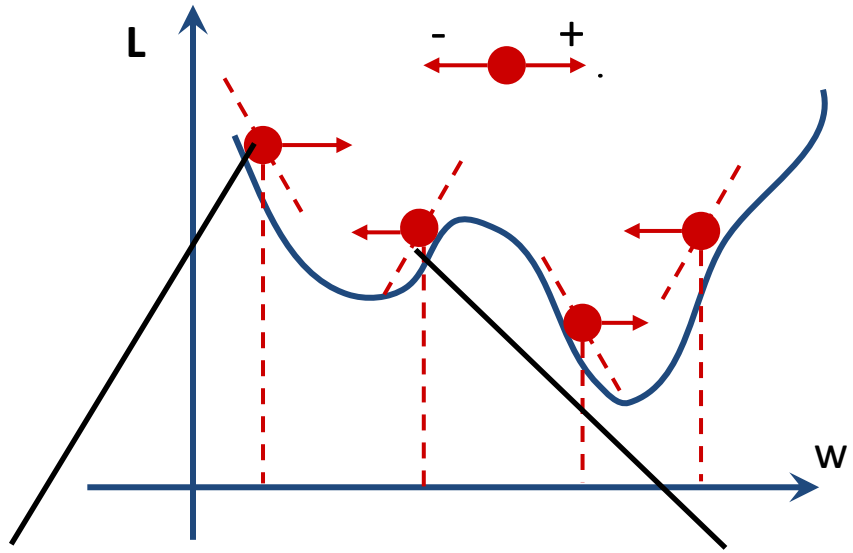
$$w^{(i+1)} = w^{(i)} - \lambda \frac{d\mathcal{L}}{dw}$$

Estimarea coeficienților de regresie: gradient descent

Rezumat metoda gradientului (Gradient Descent)

- Algoritm pentru optimizarea primului ordin pentru a găsi un minim de funcție.
- Este o metdă iterativă.
- $\mathcal{L}$ scade în direcția derivatei negative.
- Rata de învățare este controlată de mărimea lui $\lambda > 0$.

$$w^{(i+1)} = w^{(i)} - \lambda \frac{d\mathcal{L}}{dw}$$

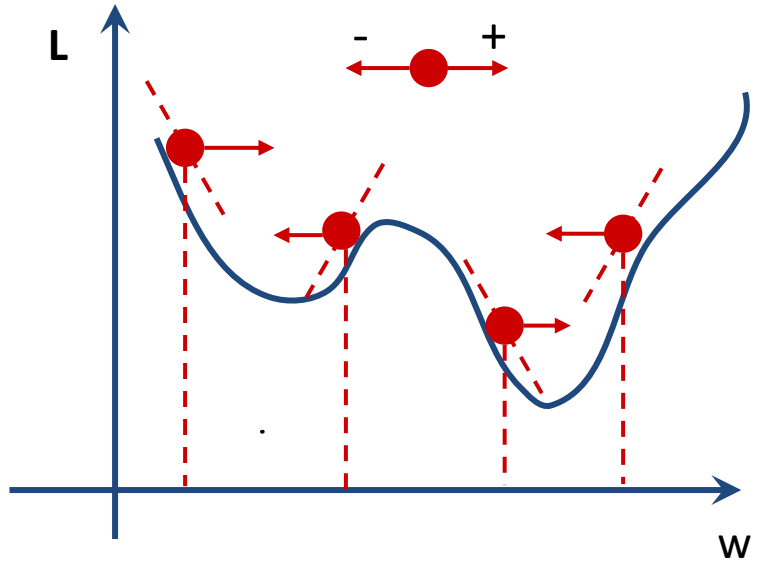


$\frac{d\mathcal{L}}{dw}$ <0 deci $w^{(i+1)} > w^{(i)}$

$\frac{d\mathcal{L}}{dw}$ >0 deci $w^{(i+1)} < w^{(i)}$

Gradient Descent: considerații

- Trebuie să calculăm/estimăm derivatele.
- Trebuie să știm care este rata de învățare sau cum să o setăm.
- Trebuie să evităm minimele locale.
- Funcția de eroare include însumarea tuturor „*erorilor*” individuale. Aceasta poate însemna foooarte multe valori.



Gradient Descent: considerații

- În regresia liniară, nu există valori minime locale, deoarece funcția de pierdere este convexă
- În regresia liniară, folosim adesea formula exacta
- Algoritmii pentru care există formule exacte sunt rari

Interpretarea Predictorilor

Întrebare: Ce crezi că înseamnă un coeficient predictor?

$$Sales = 7.5 + 0.04\,TV$$

Ce înseamnă 7.5 și ce înseamnă 0.04?

Dacă mărim reclama TV cu $1000 de dolari, care vă așteptați să fie creșterea vânzărilor?

Dar dacă: $Sales = 7.5 + 1.01\,TV$

Interpretarea predictorilor depinde de valori, dar deciziile depind de cât de mult avem încredere în aceste valori.

Planul cursului

- Modele Liniare
- Estimarea coeficienților de regresie
  - Metoda exactă
  - Metoda Gradientului - Gradient Descent
- **Intervale de încredere pentru estimările predictorilor**

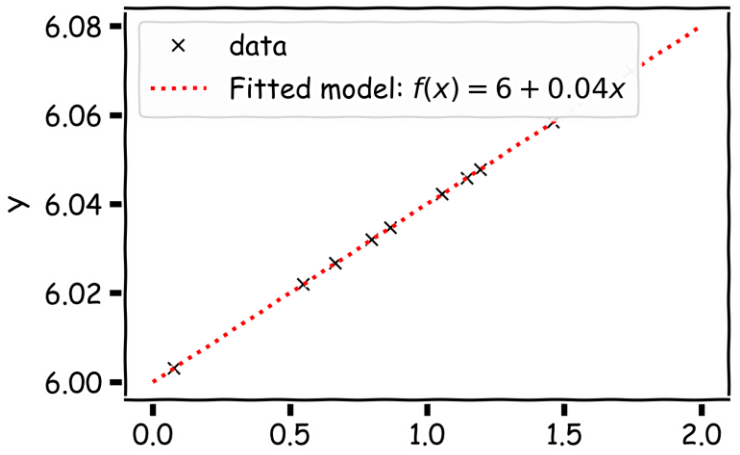
Intervale de încredere pentru estimările predictorilor

Interpretăm termenul ε din observații

$$y = f(x) + \epsilon$$

ca fiind zgomotul introdus de variații aleatorii în sistemele naturale sau impreciziile instrumentelor noastre științifice.

Dacă am ști forma exactă a lui $f(x)$, de exemplu, $f(x) = \beta_0 + \beta_1 x$, și nu ar exista ε , atunci estimarea coeficienților $\hat{\beta}$ ar fi exactă.



Intervale de încredere pentru estimările predictorilor (cont)

Cu toate acestea, se întâmplă trei lucruri, care duc la neîncredere în valorile $\hat{\beta}$:

- $\boldsymbol{\varepsilon}$ este întotdeauna întâlnit în practică
- nu cunoaștem forma exactă a lui $f(x)$
- eșantioanele sunt limitate

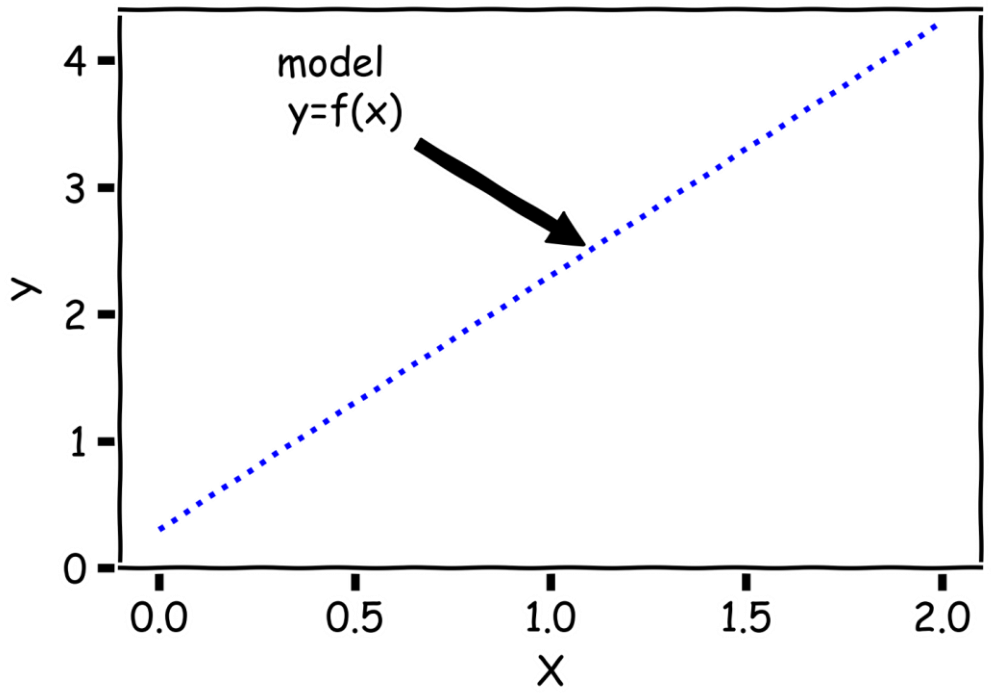
Prima dată ne ocupăm de ε

Numim ε eroarea de măsurare sau ***eroare ireductibilă***, intrinsecă.

Datorită lui ε, de fiecare dată când măsurăm răspunsul Y pentru o valoare fixă a lui X, vom obține o observație diferită și, prin urmare, o estimare diferită pentru $\hat{\beta}$.

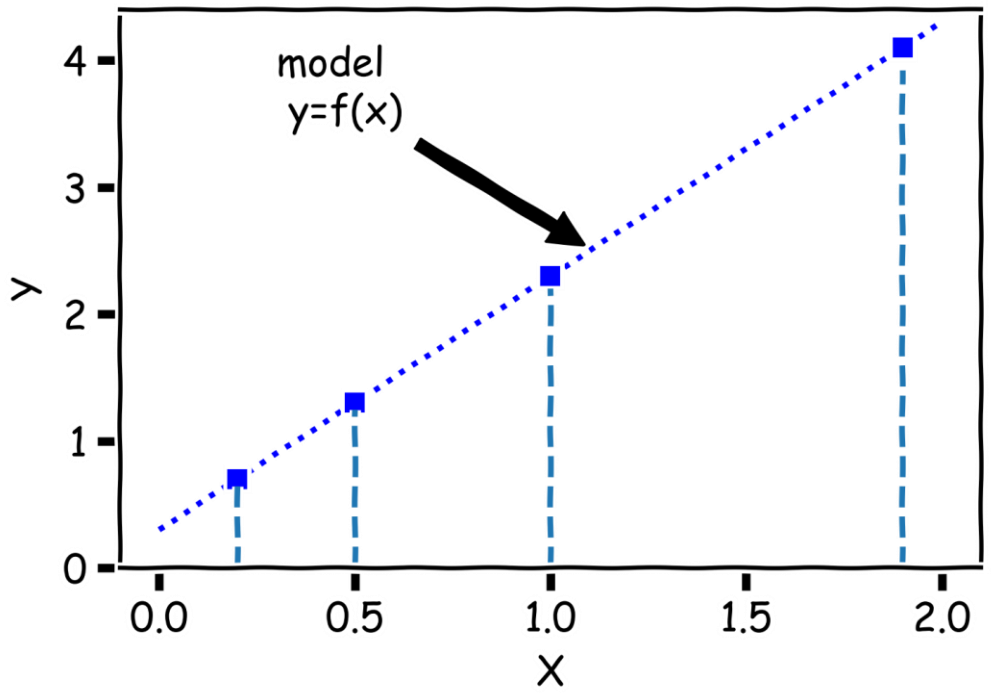
Intervale de încredere pentru estimările predictorilor (cont)

Pornim cu un model:



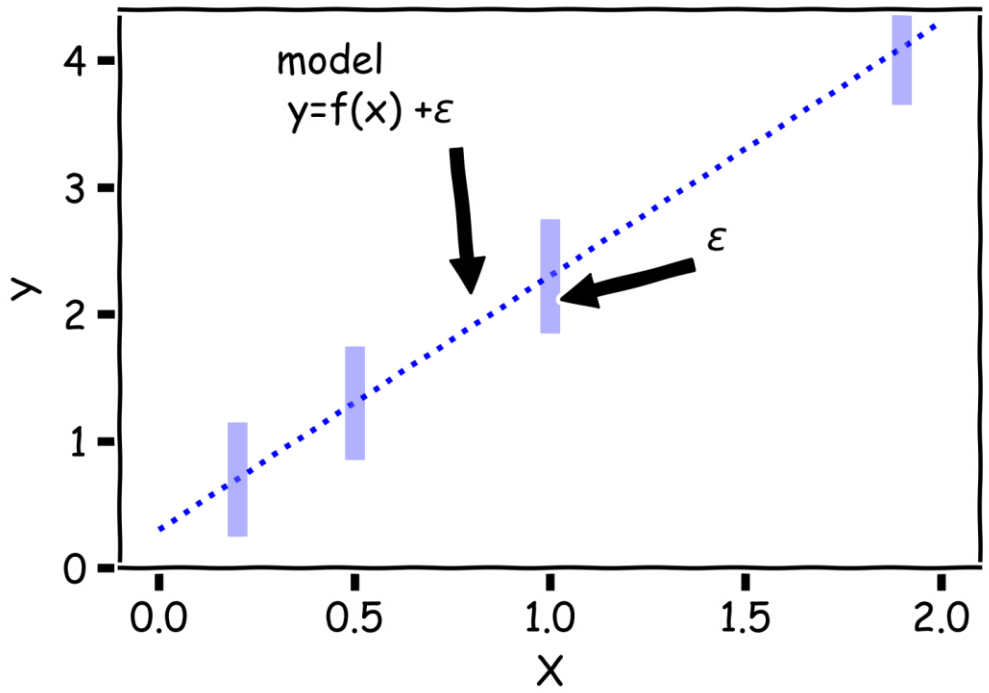
Intervale de încredere pentru estimările predictorilor (cont)

Pentru unele valori ale lui X, $Y = f(X)$



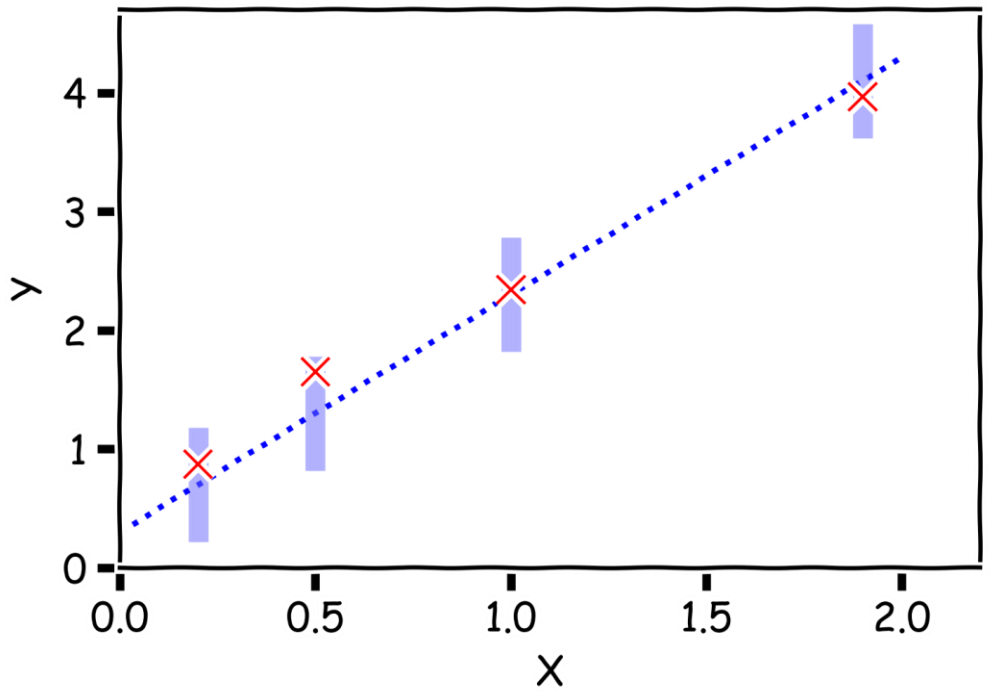
Intervale de încredere pentru estimările predictorilor (cont)

Dar, din cauza erorii, de fiecare dată când măsurăm răspunsul *Y* pentru aceleași valori fixate ale lui X vom obtine observații diferite.



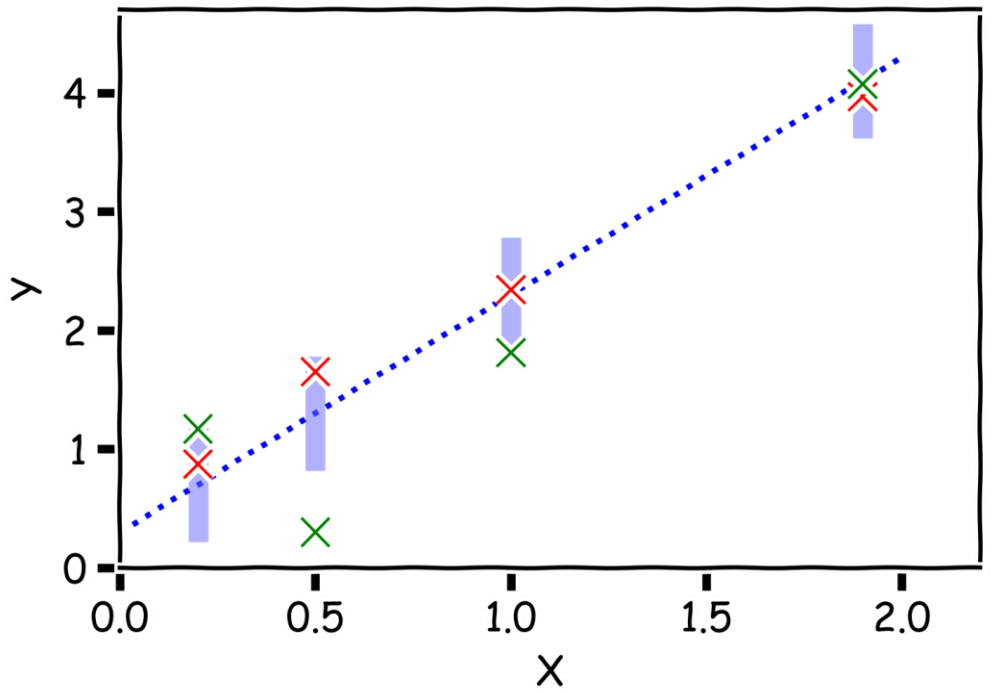
Intervale de încredere pentru estimările predictorilor (cont)

O serie de observații, “o realizare” – obținem un set de Y (marcate cu x roșu).



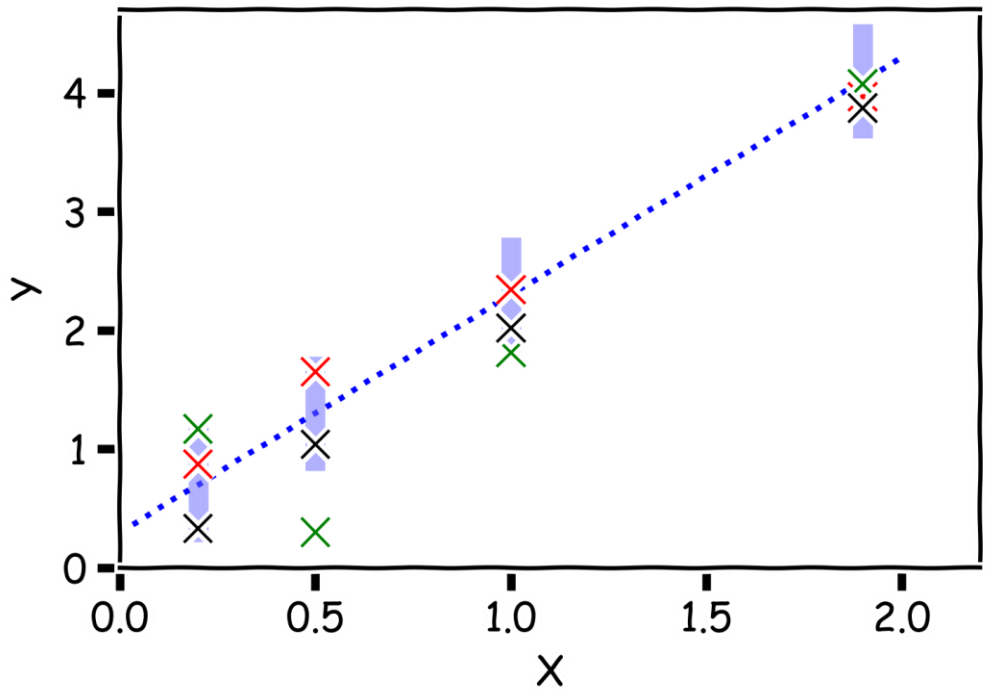
Intervale de încredere pentru estimările predictorilor (cont)

Alt set de observații – același X, “altă realizare” – obținem alte valori *Y* (marcaj verde).



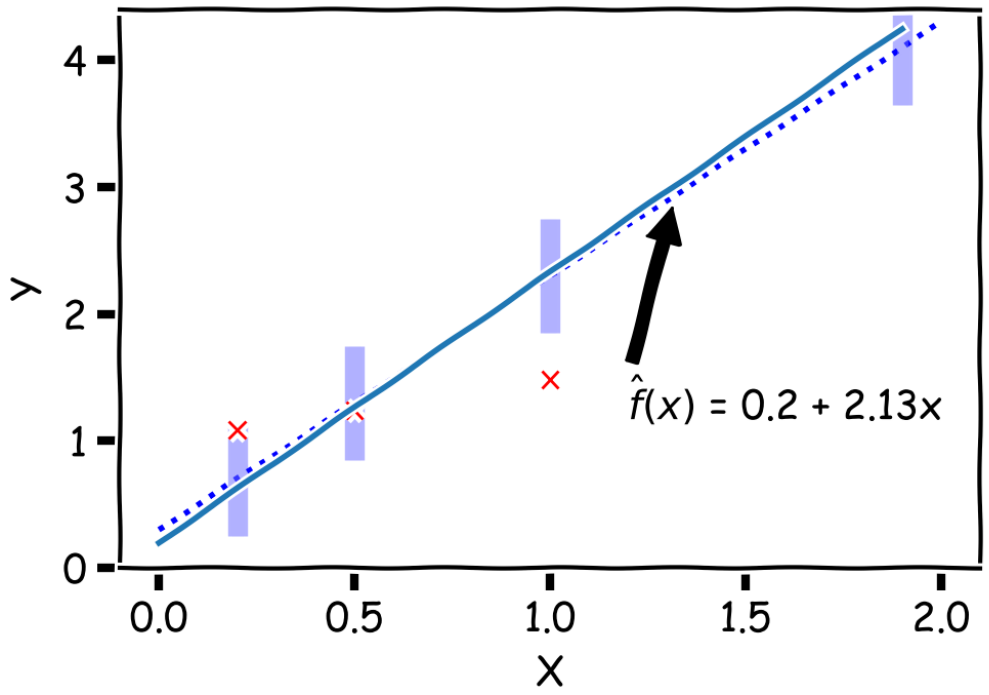
Intervale de încredere pentru estimările predictorilor (cont)

Alt set de observații – același X, “altă realizare” – obținem alte valori *Y* (marcaj negru).



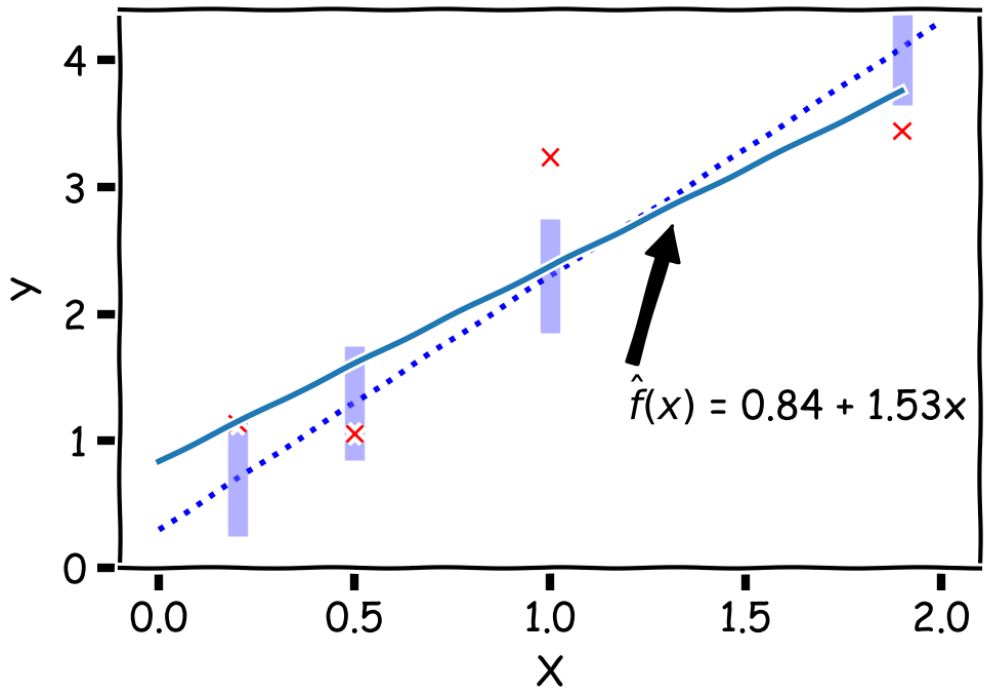
Intervale de încredere pentru estimările predictorilor (cont)

Pentru fiecare din aceste “realizări” ale lui Y, am putea alcătui un model și o estimare $\hat{\beta}_0$ și $\hat{\beta}_1$.



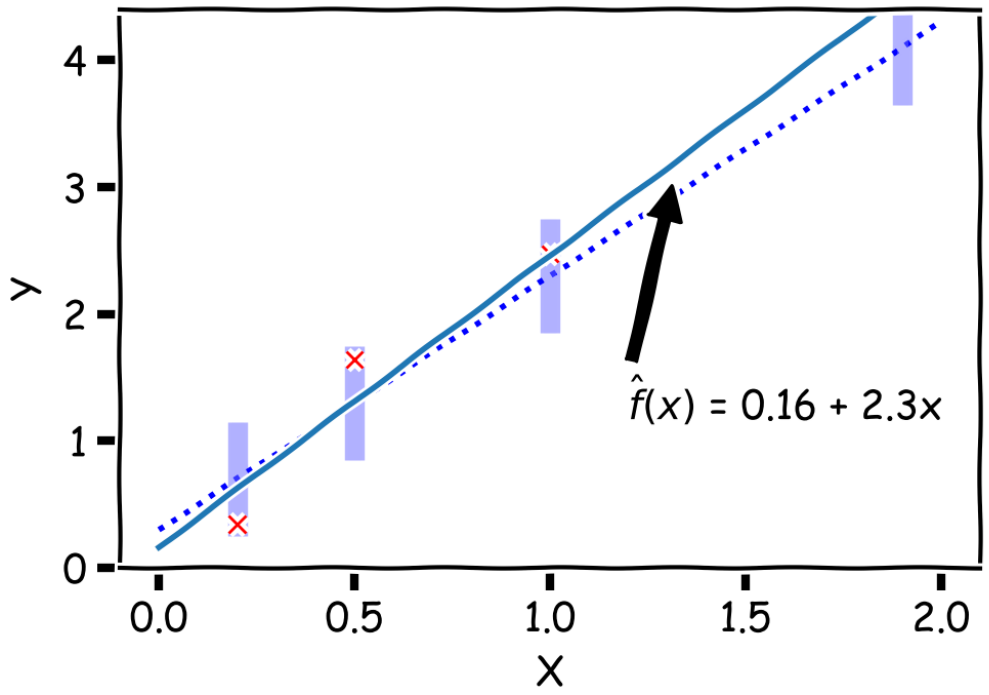
Intervale de încredere pentru estimările predictorilor (cont)

Pentru fiecare din aceste “realizări” ale lui Y, am putea alcătui un model și o estimare $\hat{\beta}_0$ și $\hat{\beta}_1$.



Intervale de încredere pentru estimările predictorilor (cont)

Pentru fiecare din aceste “realizări” ale lui Y, am putea alcătui un model și o estimare $\hat{\beta}_0$ și $\hat{\beta}_1$.



Bootstrapping pentru Estimarea Erorii de Eșantionare

În practică avem o singura listă cu observații – prea puțin pentru a avea o certitudine asupra valorilor $\hat{\beta}_0$ și $\hat{\beta}_1$ pe care le putem calcula.

Pe baza lor trebuie să estimăm cumva care ar putea fi alte observații posibile care ar duce la estimarea incertitudinii în coeficienți

Bootstrapping pentru Estimarea Erorii de Eșantionare

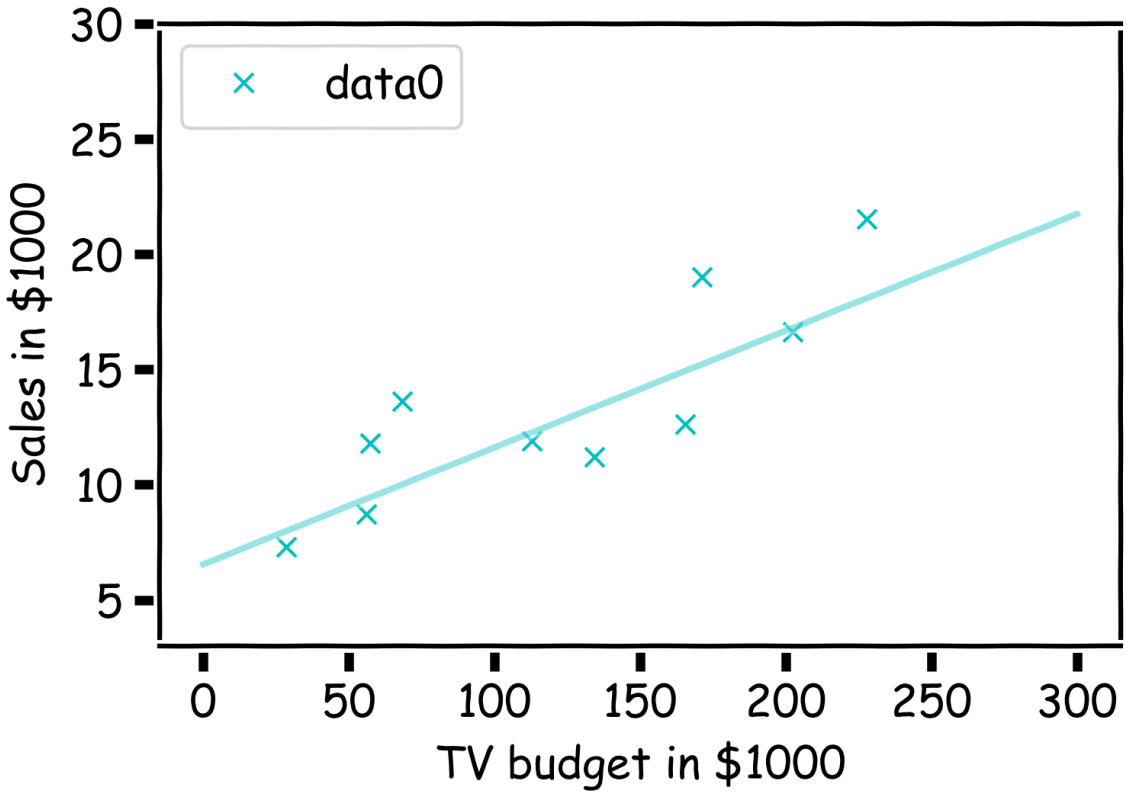
Definiție

Bootstrapping este practica estimării proprietăților unui estimator prin măsurarea acelor proprietăți, de exemplu, prin eșantionare cu repetiție din datele observate.

De exemplu, putem calcula $\hat{\beta}_0$ și $\hat{\beta}_1$ de mai multe ori prin eșantionare aleatorie din setul nostru de date. Apoi folosim varianța estimărilor noastre multiple pentru a aproxima varianța reală a lui $\hat{\beta}_0$ și $\hat{\beta}_1$.

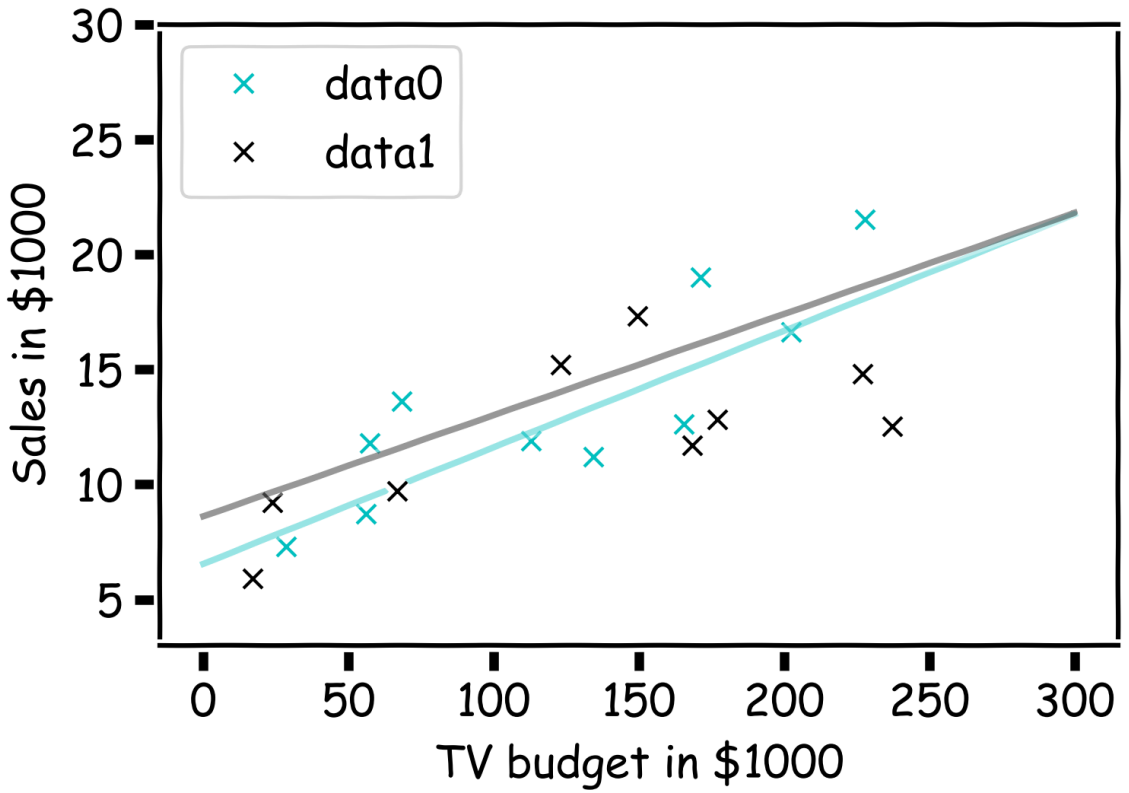
Cât de bine cunoaștem modelul $\hat{f}$?

Încrederea în f este direct legată de încrederea în coeficienții β. Deci, pentru fiecare eșantion bootstrap, avem un β pe care îl putem folosi să construim modelul.



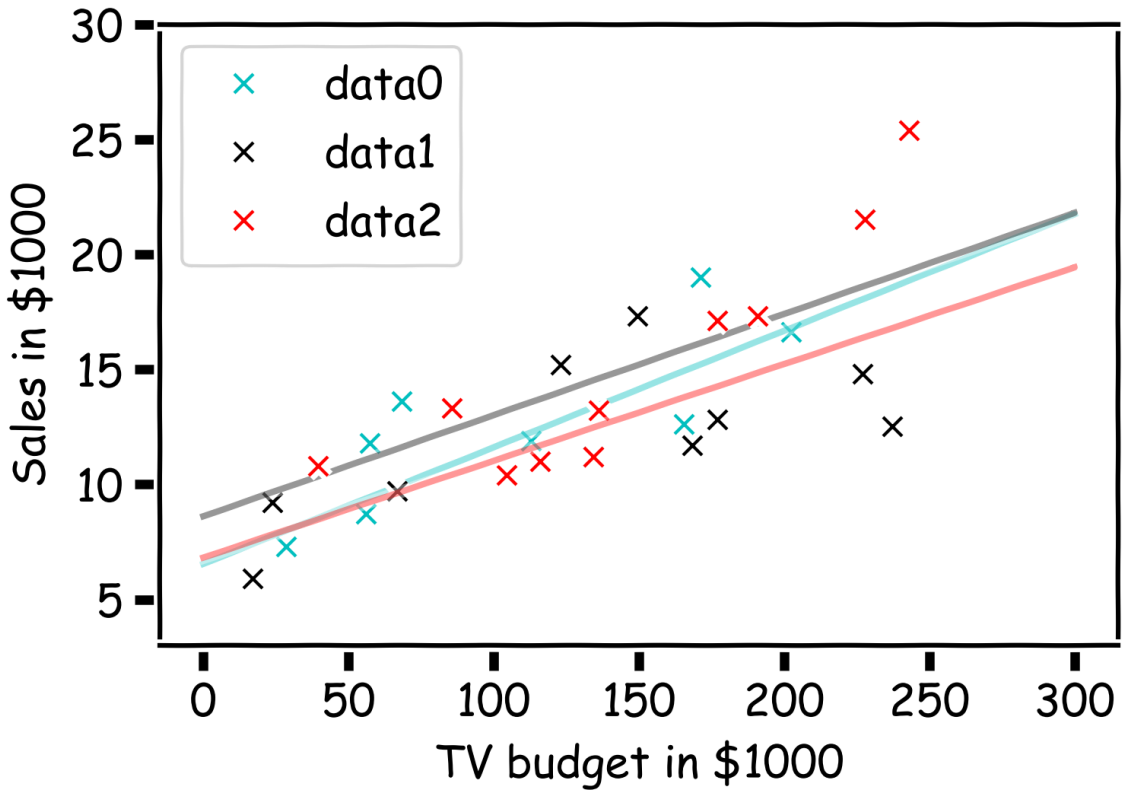
Cât de bine cunoaștem modelul $\hat{f}$?

Aici vom arăta două seturi de modele de date, cu coeficienții estimați.



Cât de bine cunoaștem modelul $\hat{f}$?

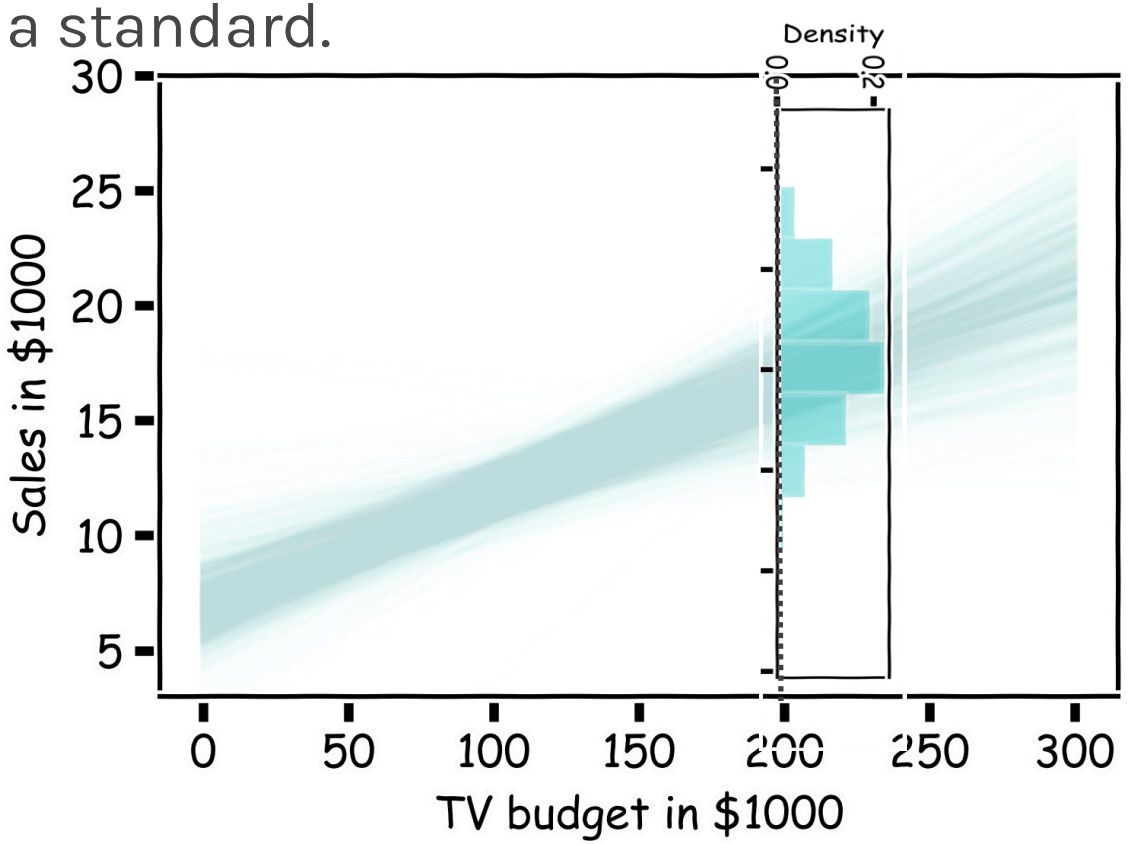
Există o astfel de linie de regresie pentru fiecare eșantion bootstrapped.



Cât de bine cunoaștem modelul $\hat{f}$?

Mai jos arătăm toate liniile de regresie pentru o mie de astfel de eșantioane bootstrapate.

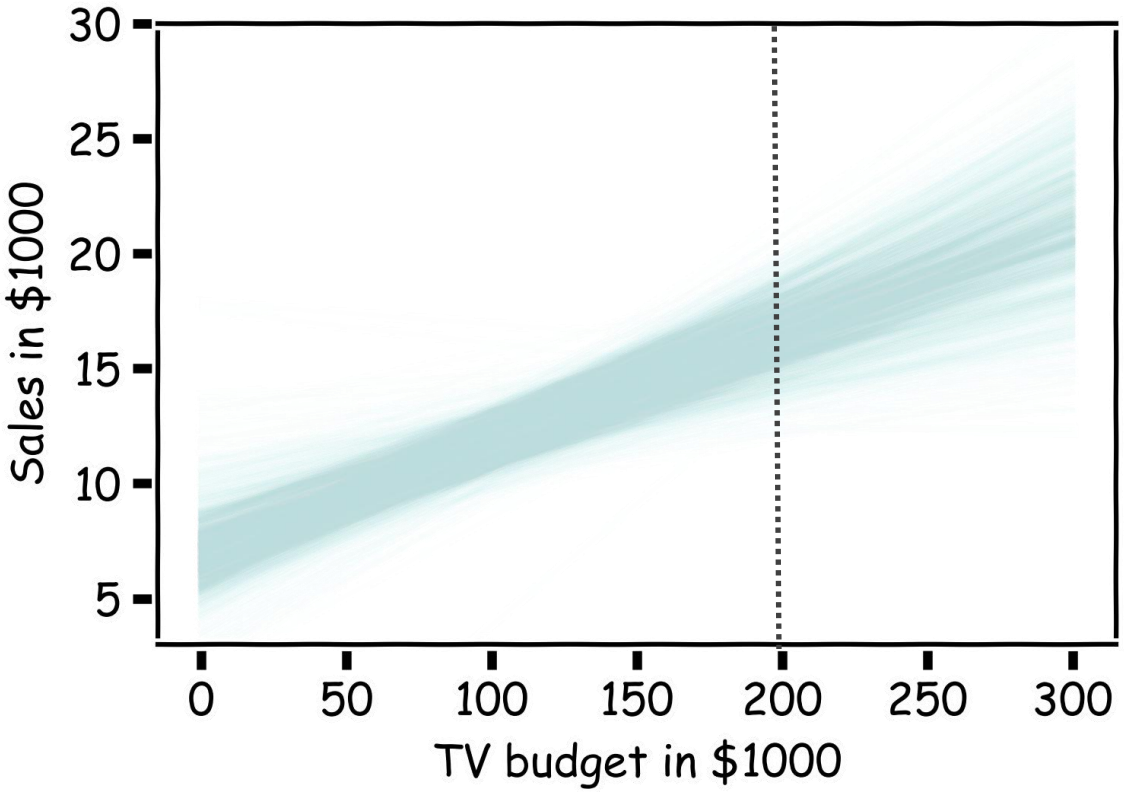
Pentru un x, examinăm distribuția valorilor $\hat{f}$, și aflăm media și deviația standard.

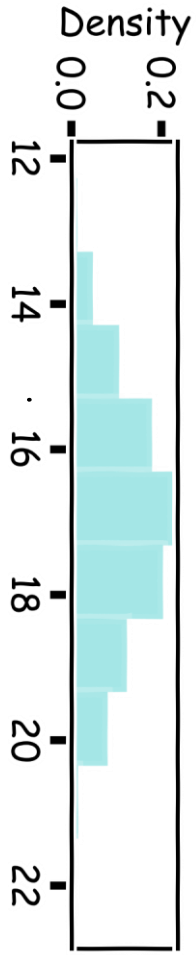


Cât de bine cunoaștem modelul $\hat{f}$?

Mai jos arătăm toate liniile de regresie pentru o mie de astfel de eșantioane

Pentru un x, examinăm distribuția valorilor $\hat{f}$, și aflăm media și deviația standard.

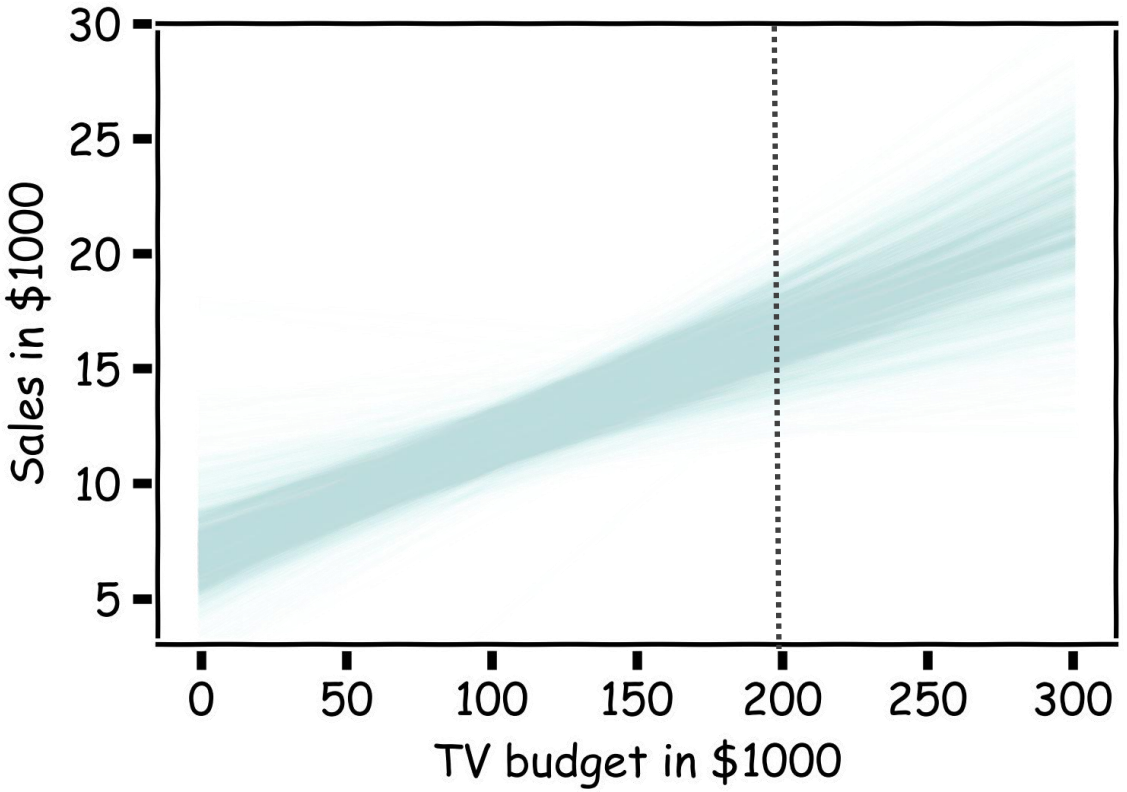


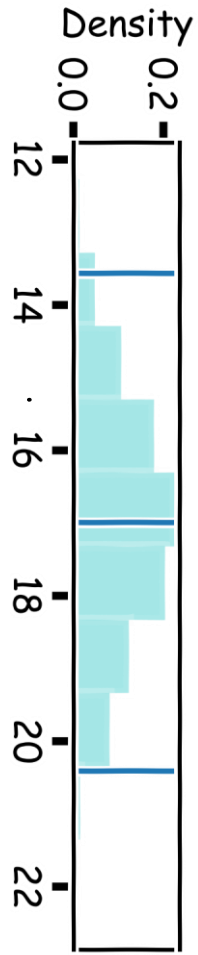


Cât de bine cunoaștem modelul $\hat{f}$?

Mai jos arătăm toate liniile de regresie pentru o mie de astfel de eșantioane

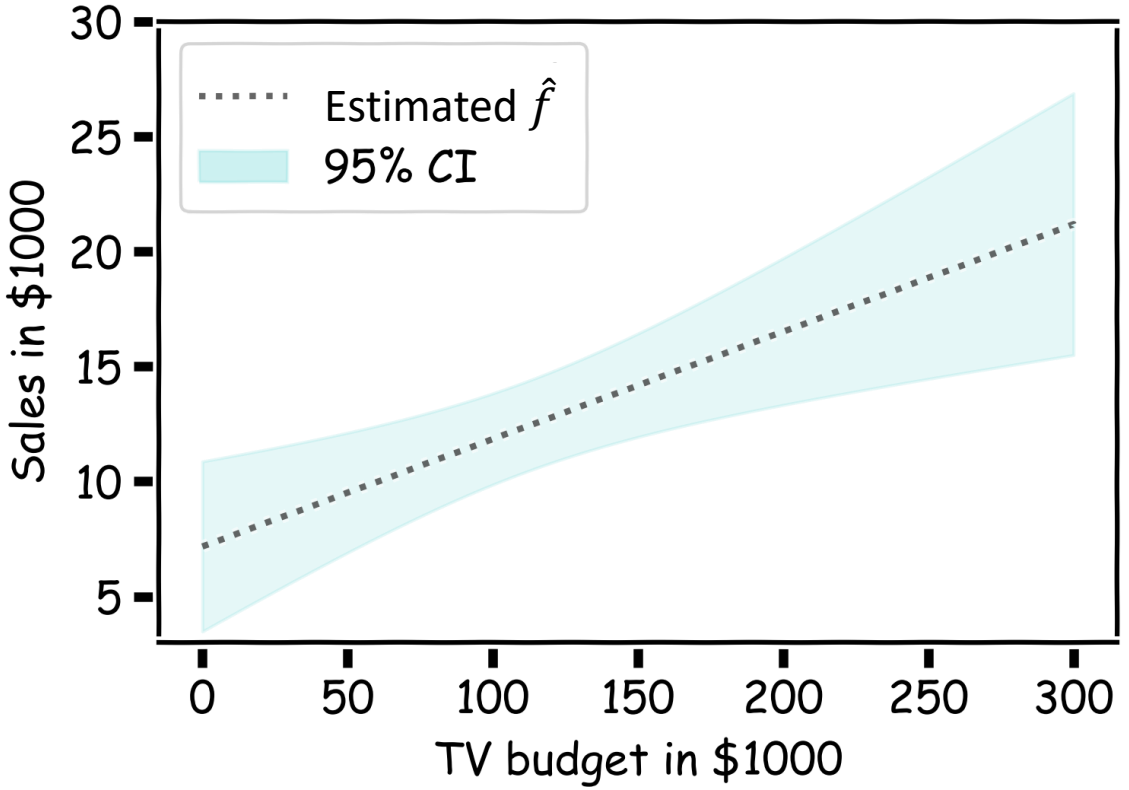
Pentru un x, examinăm distribuția valorilor $\hat{f}$, și aflăm media și deviația standard.



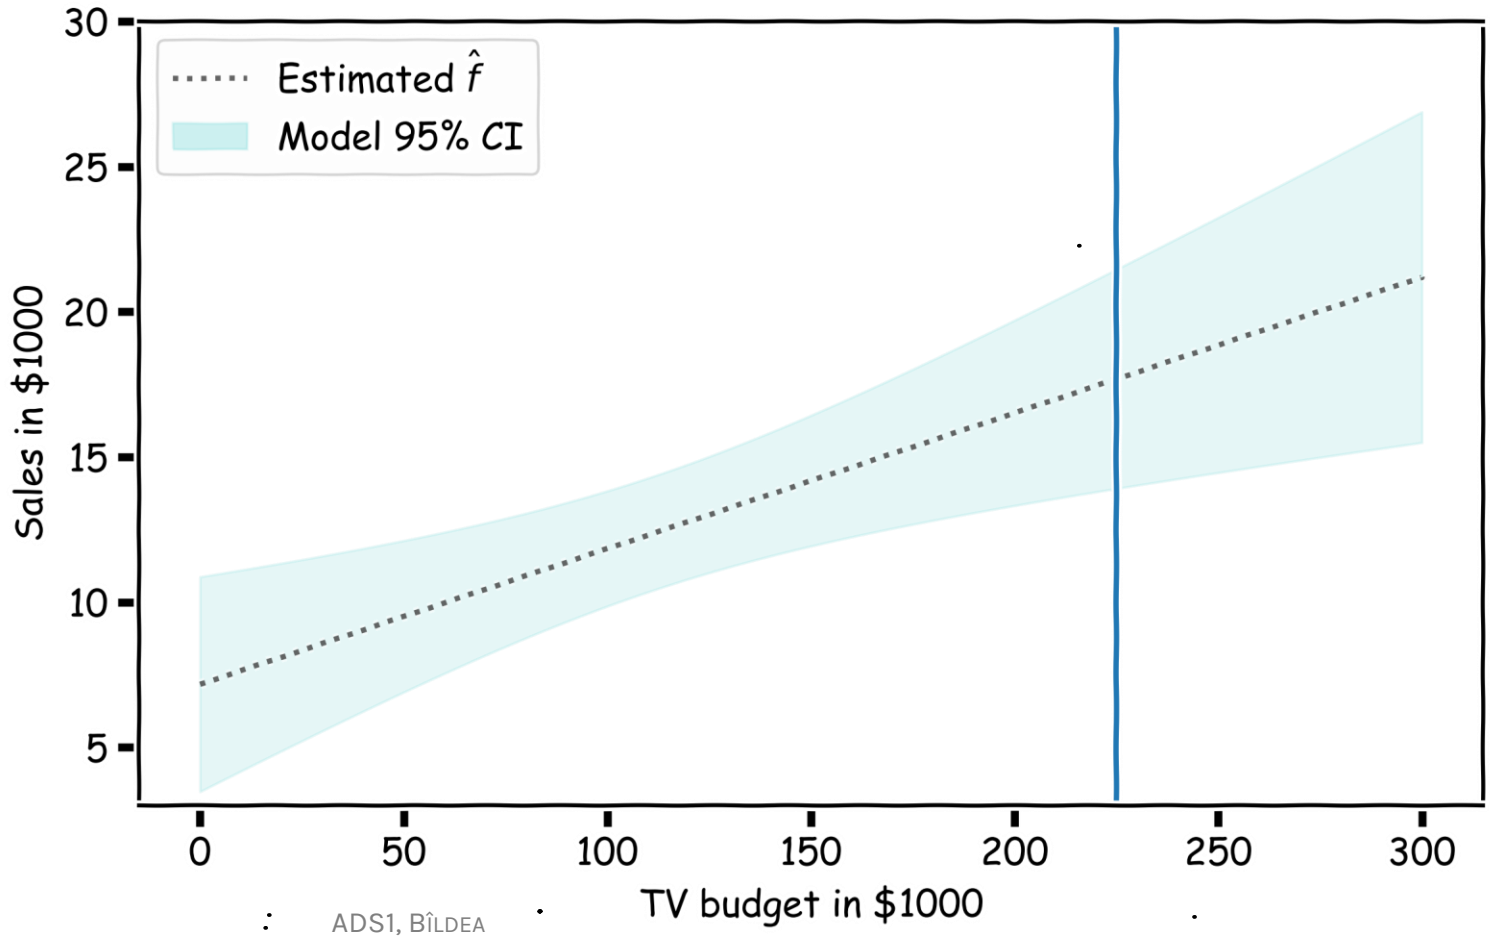


Cât de bine cunoaștem modelul $\hat{f}$?

Pentru fiecare x, calculăm media tuturor modelelor $\hat{f}$ (linia punctată) și intervalul de încredere de 95% pentru modele (zona albastră).

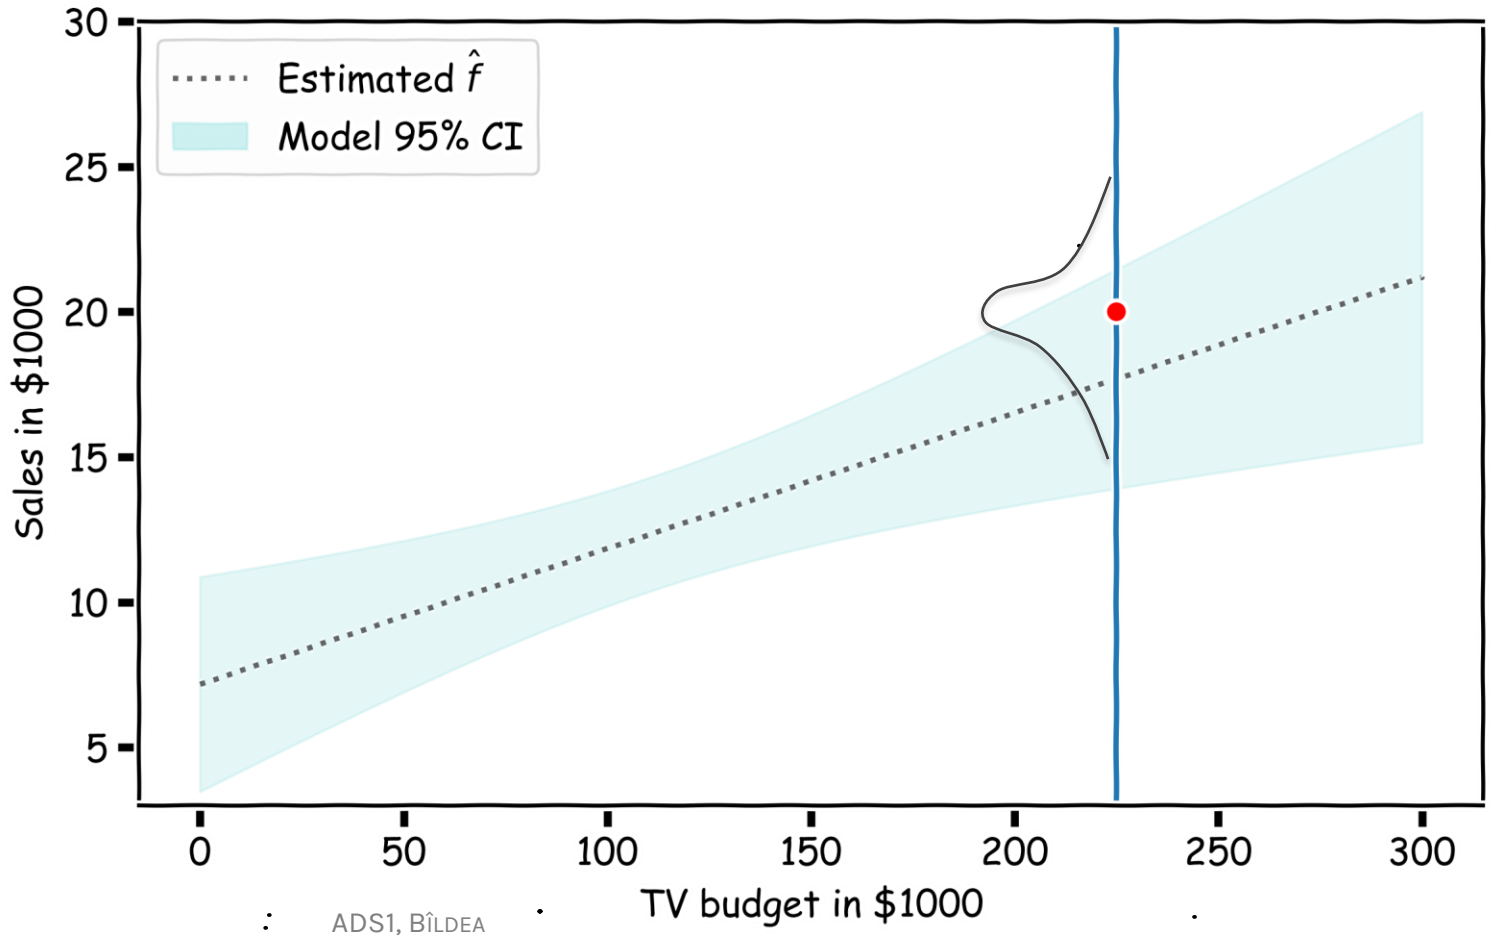


Încrederea în predicțiile $\hat{y}$



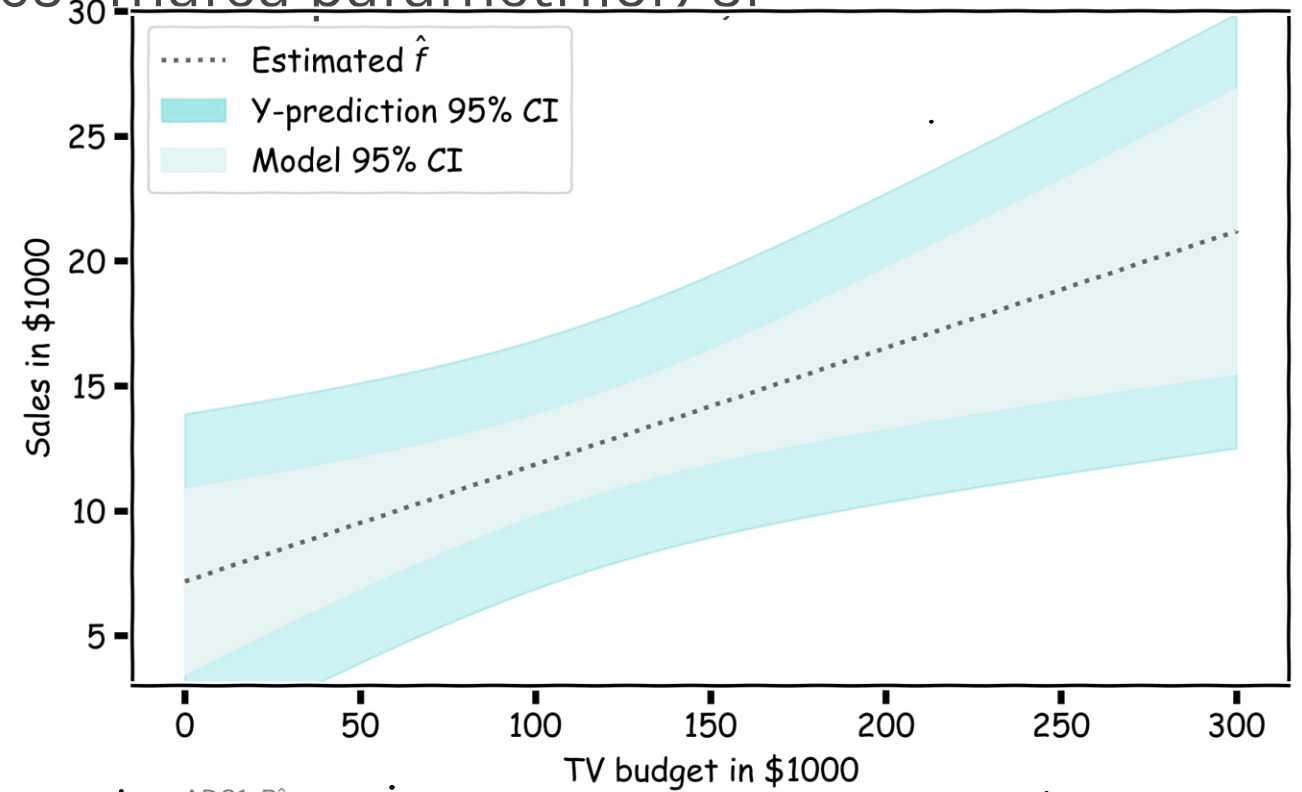
Încrederea în predicțiile $\hat{y}$

- Pentru un eșantion x, avem o distribuție de modele $f(x)$
- Pentru fiecare $f(x)$, predicțiile sunt distribuite astfel: $y \sim N(f, \sigma_\epsilon)$



Încrederea în predicțiile $\hat{y}$

- Pentru un eșantion x, avem o distribuție de modele $f(x)$
- Pentru fiecare $f(x)$, predicțiile sunt distribuite astfel: $y \sim N(f, \sigma_\epsilon)$
- Intervalele de încredere în predicție sunt atunci combinația între încrederea în model (în estimarea parametrilor) și în estimarea valorilor y



Cross-validare

