REGULARIZARE: LASSO ȘI RIDGE

Regularizare: O imagine de ansamblu

Ideea de regularizare se învârte în jurul modificării funcției de pierdere L (loss function; de ex MSE); în special, adăugăm un termen de regularizare care penalizează unele proprietăți specificate ale parametrilor modeluluiȘ

$$L_{reg}(\beta) = L(\beta) + \lambda R(\beta),$$

unde λ este un scalar care dă greutatea (sau importanța) termenului de regularizare *R*.

Antrenarea modelului utilizând funcția de pierdere modificată L_{reg} ar duce la parametrii ai modelului cu proprietăți dorite (specificate de R).

Regresie LASSO

Deoarece dorim să descurajăm valorile extreme în parametrii modelului, trebuie să alegem un termen de regularizare care să penalizeze magnitudinea parametrilor. Pentru funcția noastră de pierdere vom folosi din nou MSE:

$$L_{LASSO}(\beta) = \frac{1}{n}\sum_{i=1}^{n}|y_i - \boldsymbol{\beta}^\top \boldsymbol{x}_i|^2 + \lambda\sum_{j=1}^{J}|\beta_j|.$$

Aici $\sum_{j=1}^{J}|\beta_j|$ este norma l_1 a vectorului β

$$\sum_{j=1}^{J}|\beta_j| = \|\boldsymbol{\beta}\|_1$$

Regresie LASSO

Prin urmare, vom spune în mod uzual că L_{LASSO} este funcția de pierderi (loss-function) pentru regularizare l_1.

Găsirea parametrilor modelului, β_{LASSO} , care minimizează funcția de pierdere pentru regularizarea l_1 se numește regresie ***LASSO***.

In [ ]:
```
from sklearn.linear_model import Lasso
```

In [22]:
```
lasso_regression = Lasso(alpha=1.0, fit_intercept=True)
lasso_regression.fit(np.vstack((X_train, X_val)), np.hstack((y_train, y_val)))

print('Lasso regression model:\n {} + {}^T . x'.format(lasso_regression.intercept_, lasso_regression.coe
```

```
Lasso regression model:
 10.424895873901445 + [ 0.24482603  3.48164594  1.84836859 -0.06864603 -0.         -0.
 -0.02249766 -0.          0.          0.          0.          ]^T . x
```

In [23]:
```
print('Train R^2: {}, test R^2: {}'.format(lasso_regression.score(np.vstack((X_train, X_val)),
                                                                  np.hstack((y_train, y_val))),
                                           lasso_regression.score(X_test, y_test)))
```

```
Train R^2: 0.48154992527975765, test R^2: 0.6846451270316087
```

Regresie Ridge

Alternativ, putem alege un termen de regularizare care să penalizeze pătratele magitudinilor parametrilor. Astfel funcția noastră de pierdere regularizată este:

$$L_{Ridge}(\beta) = \frac{1}{n}\sum_{i=1}^{n}|y_i - \boldsymbol{\beta}^\top \boldsymbol{x}_i|^2 + \lambda\sum_{j=1}^{J}\beta_j^2.$$

Aici $\sum_{j=1}^{J}|\beta_j|^2$ este norma l_2 a vectorului $\boldsymbol{\beta}$

$$\sum_{j=1}^{J}\beta_j^2 = \|\boldsymbol{\beta}\|_2^2$$

Ridge Regression

Prin urmare, vom spune în mod uzual că L_{ridge} este funcția de pierderi (loss-function) pentru regularizare l_2.

Găsirea parametrilor modelului β_{ridge} care minimizează funcția de pierdere pentru regularizarea l_2 se numește regresie ***ridge.***

In [ ]:
```
from sklearn.linear_model import Ridge
```

In [20]:
```
X_train = train[all_predictors].values
X_val = validation[all_predictors].values
X_test = test[all_predictors].values

ridge_regression = Ridge(alpha=1.0, fit_intercept=True)
ridge_regression.fit(np.vstack((X_train, X_val)), np.hstack((y_train, y_val)))

print('Ridge regression model:\n {} + {}^T . x'.format(ridge_regression.intercept_, ridge_regression.coe
```

```
Ridge regression model:
 -525.7662550875951 + [ 0.24007312  8.42566029  2.04098593 -0.04449172 -0.01227935  0.41902475
 -0.50397312 -4.47065168  4.99834262  0.          0.          0.29892679]^T . x
```

In [21]:
```
print('Train R^2: {}, test R^2: {}'.format(ridge_regression.score(np.vstack((X_train, X_val)),
                                                                  np.hstack((y_train, y_val))),
                                           ridge_regression.score(X_test, y_test)))
```

```
Train R^2: 0.5319764744847737, test R^2: 0.7881798111697319
```

Alegerea lui λ

Atât la regresia ridge cât și la cea LASSO, vedem că cu cât este mai mare alegerea parametrului de regularizare λ, cu atât penalizăm mai mult valorile mari în β

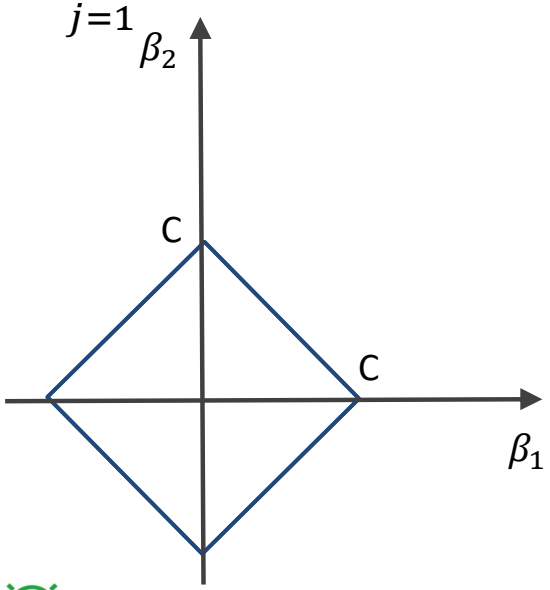
- Dacă λ e aproape de zero, regăsim MSE, adică regresiile ridge și LASSO regression se apropie de regresia obișnuită.
- Dacă λ este suficient de mare, termenul MSE în funcția de pierdere regularizată va fi nesemnificativ și termenul de regularizare β_{ridge} sau β_{LASSO} va fi forțat să se apropie de zero.

Pentru a evita alegeri ad-hoc pentru λ putem folosi validare încrucișată.

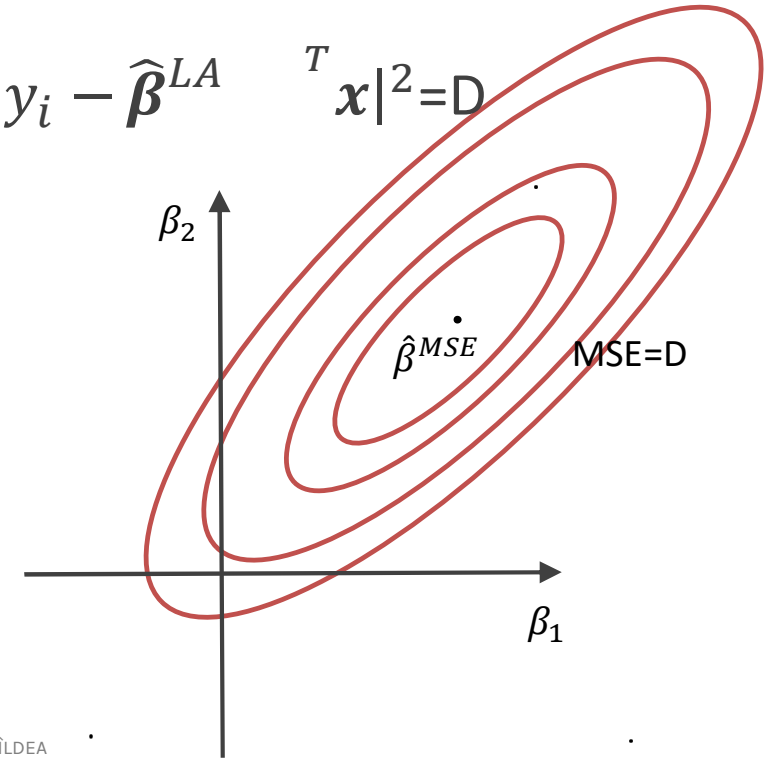
Geometria regularizării (LASSO)

$$L_{LASSO}(\boldsymbol{\beta}) = \frac{1}{n}\sum_{i=1}^{n} |y_i - \boldsymbol{\beta}^T \boldsymbol{x}|^2 + \lambda \sum_{j=1}^{J} |\beta_j| \qquad \widehat{\boldsymbol{\beta}}^{LASSO} = \operatorname{argmin} L_{LASSO}(\boldsymbol{\beta})$$

$$\lambda \sum_{j=1}^{J} |\hat{\beta}_j^{LASSO}| = C$$



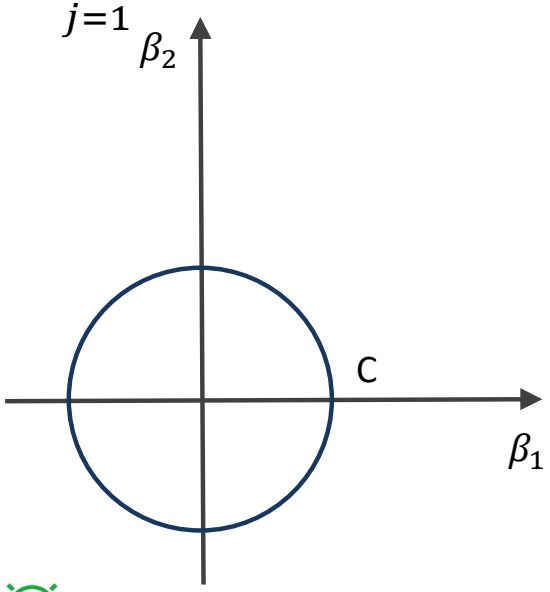
$$\frac{1}{n}\sum_{i=1}^{n} |y_i - \widehat{\boldsymbol{\beta}}^{LA} \quad {}^T \boldsymbol{x}|^2 = D$$



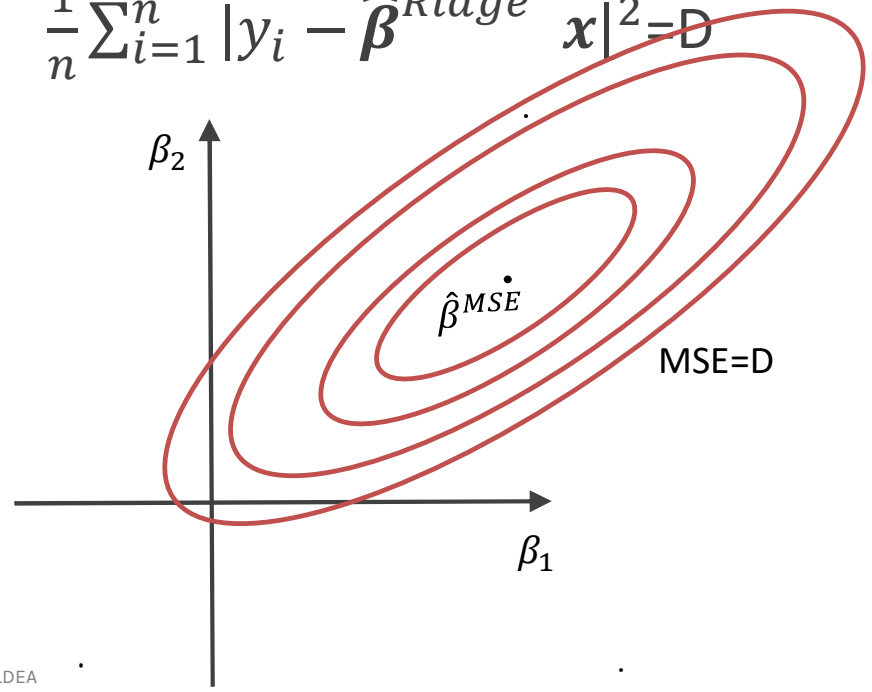
Geometria regularizării(Ridge)

$$L_{Ridge}(\boldsymbol{\beta}) = \frac{1}{n}\sum_{i=1}^{n} \left|y_i - \boldsymbol{\beta}^T \boldsymbol{x}\right|^2 + \lambda \sum_{j=1}^{J} \left(\beta_j\right)^2 \qquad \hat{\boldsymbol{\beta}}^{Ridge} = \operatorname{argmin} L_{Ridge}(\boldsymbol{\beta})$$

$$\lambda \sum_{j=1}^{J} \left|\hat{\beta}_j^{Ridge}\right|^2 = C$$



$$\frac{1}{n}\sum_{i=1}^{n} \left|y_i - \hat{\boldsymbol{\beta}}^{Ridge^T} \boldsymbol{x}\right|^2 = D$$



Ridge – Complexitate Computațională

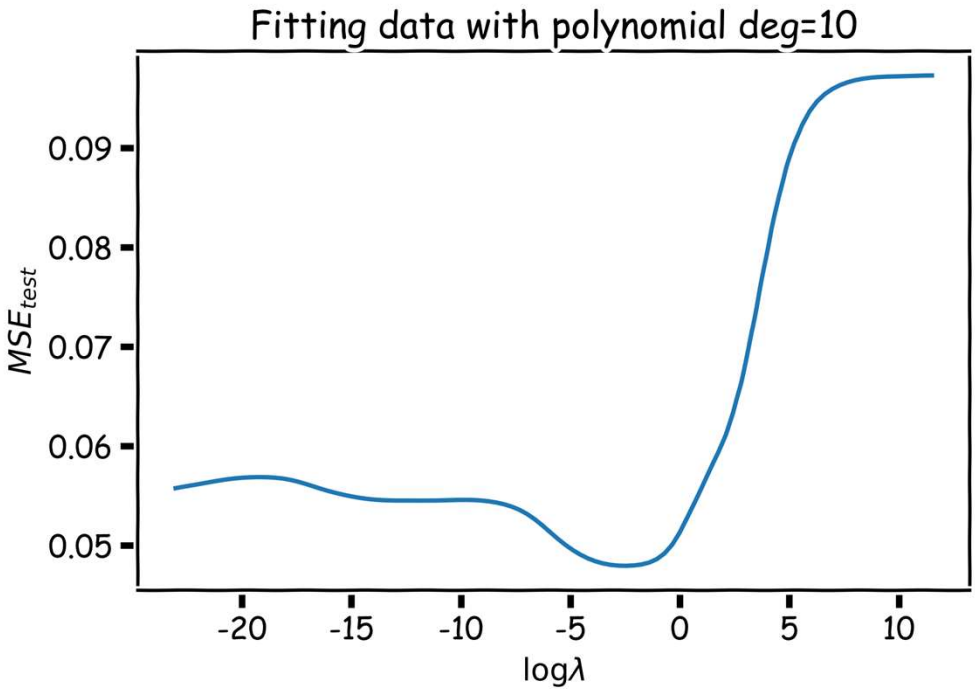
Soluția algebrică pentru regresia Ridge:

$$\beta = (X^T X + \lambda I)^{-1} X^T Y$$

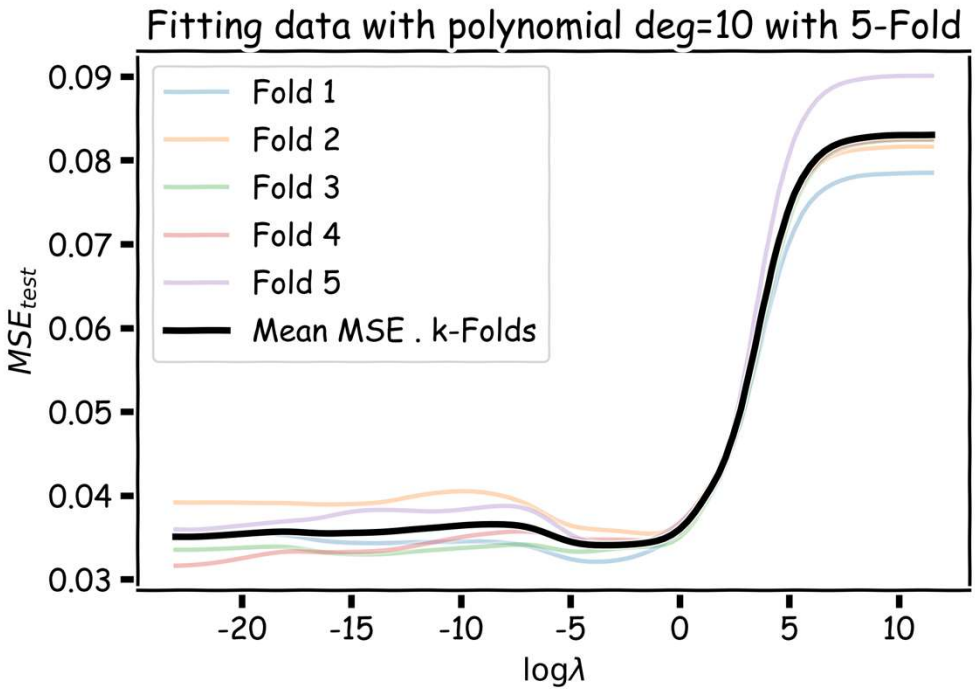
Soluția pentru regresia Ridge/Lasso presupune 3 pași

- Selectarea lui λ
- Găsirea minimului pentru funcția de pierdere ridge/Lasso regression (algebră liniară) și reținerea valorii R^2 **pe setul de date de test**.
- Găsirea acelui λ care ne dă cea mai mare valoare R^2

Ridge regularization with **validation** only: step by step



Regularizare Ridge cu **CV(Valid. Încr.)**: pas cu pas



Alegerea predictorilor prin regularizare

Deoarece regresia LASSO are tendința de a produce estimări zero pentru un număr de parametri ai modelului - spunem că soluțiile LASSO sunt rare - considerăm că **LASSO este o metodă pentru selecția predictorilor**.

Mulți preferă să utilizeze LASSO pentru selecția variabilă (precum și pentru suprimarea valorilor extreme ale parametrilor) în loc de selecție treptată, deoarece LASSO evită problemele statistice care apar în selecția treptată.

Întrebare:

Care sunt avantajele și dezavantajele celor două abordări?


Tableau
66.6K views
0:01 / 1:29