Codificarea numerică a variabilelor categoriale

- Modelele statistice nu procesează decât numere
- Orice atribut categorial – geografice, culori, caracteristici – trebuie codificat

Culoare mașină	Codificare 1	Codificare 2	Codifcare oareacare
Alb	0	1	7
Albastru	1	0	-1
Roșu	2	2	2013

- Cum alegem o codifcare nepărtinitoare și care să nu fie aleatoare?

Codificarea numerică a variabilelor categoriale

- ONE HOT ENCODING – codificare nepărtinitoare

Culoare mașină
Alb
Albastru
Roșu



Culoare_Alb	Culoare_Abastru	Culoare_Roșu
1	0	0
0	1	0
0	0	1

- Alb = (1,0,0), Albastru = (0,1,0), Roșu = (0,0,1)
- Dezavantaj: în loc de o coloană vom avea 3 (=numărul de valori distincte pentru culoare); în plus toate culorile noi vor avea vectorul (0,0,0) care nu apare la antrenament.
- Pentru un atribut cu *n* valori distincte vom construi *n* coloane
- ATENTIE: Numărul de coloane va crește rapid dacă sunt prezente mai multe variabile categoriale cu multe valori distincte fiecare

Atenție: codificarea fără scurgeri de informație

- Codificatorul învață din date lista categoriilor existente
- Împărțiți întâi train/test, apoi fit pe train și transform pe train și test
- O categorie care apare doar în test nu are coloană: OneHotEncoder(handle_unknown="ignore") o codifică cu (0,0,0)
- pd.get_dummies pe tot setul înainte de împărțire merge pentru explorare, dar nu pentru un model evaluat pe date noi
- Variabile cu multe niveluri: reduceți numărul de niveluri (grupați categoriile rare) înainte de codificare