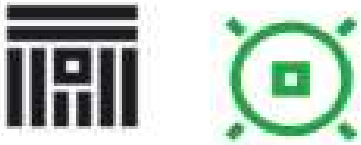
Curs 10: Mașini cu Suport Vectorial (SVMs)

Instructor: Conf. Dr. Teodor-Ștefan Bîldea
SIIPA, An I, Semestrul I



Cuprins

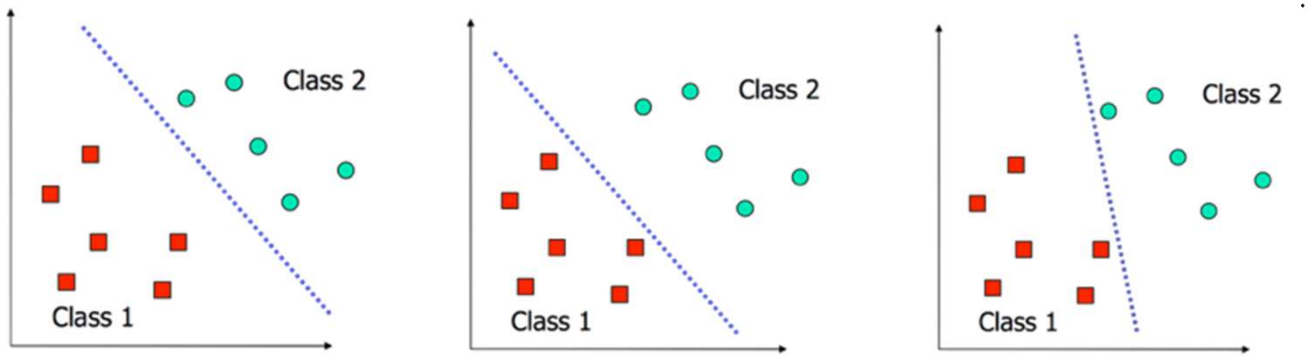
- Clasificarea datelor separabile liniar
- Clasificarea datelor care nu se pot separa liniar
- Kernel Trick

Recapitulare frontiera/limita deciziei

În regresia logistică, învățăm o ***limită de decizie*** care separă clasele din setul de antrenament folosind caracteristici (features/predictori).

Când datele pot fi perfect separate printr-o graniță liniară, numim datele ***separabile liniar***.

În acest caz, mai multe limite de decizie se pot potrivi cu datele. Cum alegem cea mai bună separatoare?



Recapitulare frontiera/limita deciziei (cont.)

Constrângeri la limita deciziei:

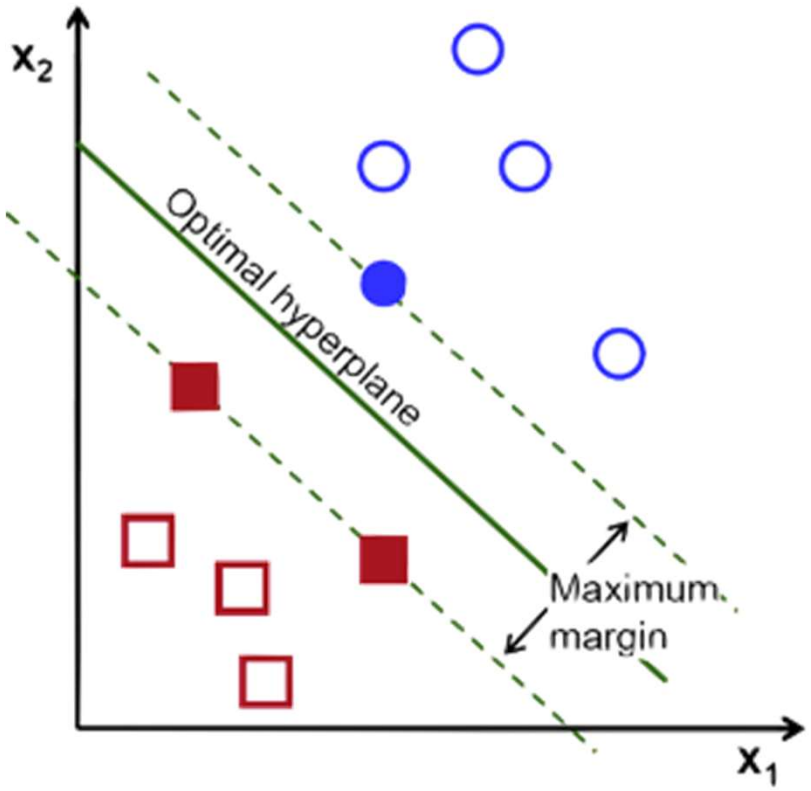
- În regresia logistică, învățăm de obicei un model regularizat $\ell 1$ sau $\ell 2$.
- Deci, atunci când datele sunt separabile liniar, alegem un model cu „cei mai mici coeficienți” care încă separă clasele.
- Scopul regularizării este de a preveni supraadaptarea.

Recapitulare frontiera/limita deciziei (cont.)

Constrângeri la limita deciziei:

- Putem lua în considerare constrângeri alternative care împiedică supraadaptarea.
- De exemplu, este posibil să preferăm o hotărâre care nu „favorizează” nicio clasă (în special atunci când clasele sunt aproximativ la fel de populate).
- Geometric, aceasta înseamnă alegerea unei limite care maximizează distanța sau marginea dintre limită și ambele clase.

Exemplu de separare de tip SVM

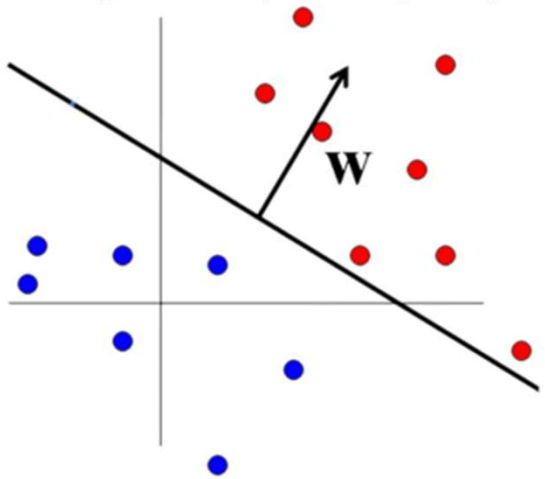


Geometria limitelor de decizie

Reamintim că granița deciziei este definită de o ecuație în termeni de predictori. O limită liniară este definită de:

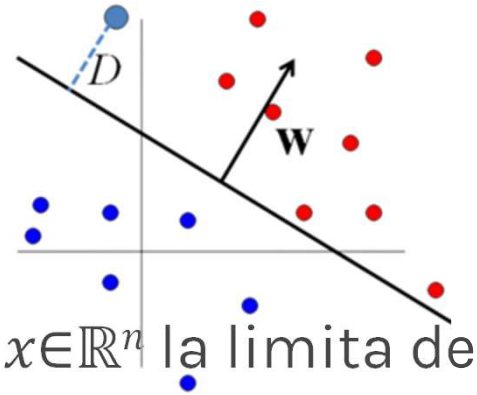
$$w^T x + b = 0$$ (Ecuația generală a unui hiperplan)

Amintiți-vă: coeficienții neconstanți, w, reprezintă un ***vector normal***, îndreptat ortogonal pe hiperplan



Geometria limitelor de decizie (cont.)

Acum, folosind puțină geometrie, putem calcula distanța oricărui punct până la limita deciziei folosind w și b.



Distanța de la un punct $x \in \mathbb{R}^n$ la limita deciziei este

$$D(x) = \frac{w^\top x + b}{\|w\|}$$

(Distanță Euclideană)

Maximizarea distanței între clase (Marja)

Acum ne putem formula obiectivul - să găsim o limită de decizie care să maximizeze distanța până la ambele clase - ca o problemă de optimizare:

$$\begin{cases} \max\limits_{w,b} M \\ \text{astfel încât } |D(x_n)| = \frac{y_i(w^\top x_n + b)}{\|w\|} \geq M,\ n = 1, \ldots, N \end{cases}$$

unde M este un număr real care reprezintă lățimea „marjei” și $y_i = \pm 1$. Inegalitățile $| D (x_n) | \geq M$ se numesc constrângeri.

Problema de optimizare constrânsă, prezentă aici, pare dificilă. Să o simplificăm cu o mică intuiție geometrică.

Maximizarea distanței între clase (Marja) (cont.)

Observați că maximizarea distanței ***tuturor punctelor*** până la limita deciziei este exact aceeași cu maximizarea distanței până la ***cele mai apropiate puncte***.

Punctele cele mai apropiate de limita deciziei se numesc ***vectori suport***.

Pentru orice plan, putem oricând scala ecuația:

$$w^T x + b = 0$$

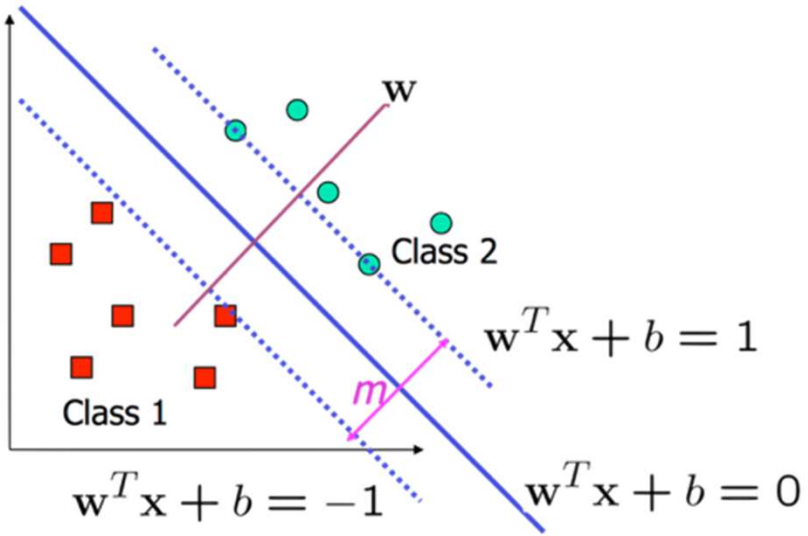
astfel încât vectorii suport să fie în (hiper)planurile:

$$w^T x + b = \pm 1,$$

în funcție de apartenența la clase.

Maximizarea distanței între clase (Marja) (cont.)

Pentru punctele de pe planele wTx + b = ± 1, distanța lor până la limita de decizie este de ± 1 / ‖w‖.
Deci putem defini ***marja*** unei limite de decizie ca distanța până la vectorii suport ai acesteia, m = 2 / ‖w‖.



Clasificare cu suport vectorial (SVC): marjă strictă

În cele din urmă, putem reformula problema noastră de optimizare - găsim o limită de decizie care maximizează distanța până la ambele clase - ca maximizarea marjei, m, ***menținând în același timp zero clasificări greșite,***

$$\begin{cases} \max\limits_{w,b} \dfrac{2}{\|w\|} \\ \text{astfel încât} \quad y_n(w^\top x_n + b) \geq 1, \; n = 1, \ldots, N \end{cases}$$

Clasificatorul instruit prin rezolvarea acestei probleme se numește ***hard margin support vector classification***.

Adesea clasificare SVC este prezentată ca o problemă de minimizare:

$$\begin{cases} \min\limits_{w,b} \|w\|^2 \\ \text{astfel încât} \quad y_n(w^\top x_n + b) \geq 1, \; n = 1, \ldots, N \end{cases}$$

SVC și optimizarea convexă

Ca o problemă de optimizare convexă, SVC a fost studiat pe larg și poate fi rezolvat printr-o varietate de algoritmi:

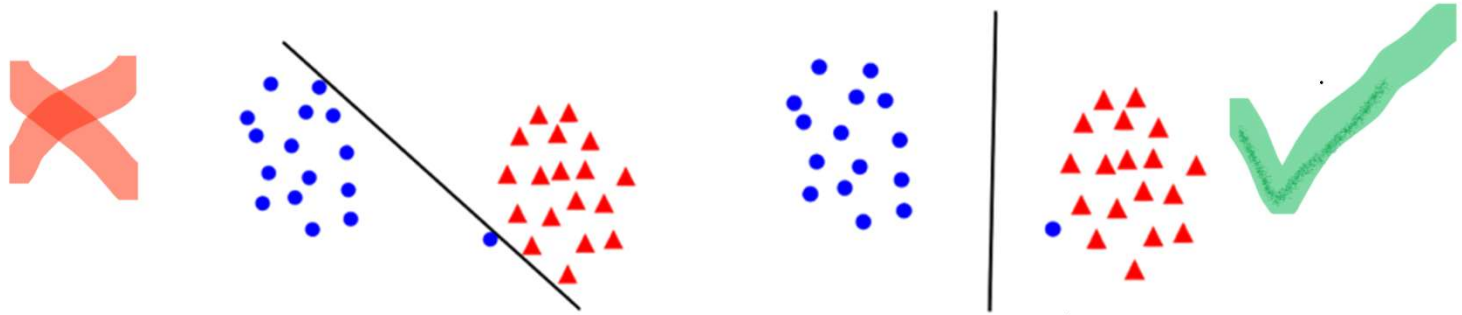
- **(Stochastic)** libLinear Convergență rapidă, cost de calcul moderat
- **(Greedy)** libSVM Convergență rapidă, cost de calcul moderat
- **(Stochastic)** Stochastic Gradient Descent Convergență lentă, cost de calcul redus pe iterație
- **(Greedy)** Metoda Quasi-Newton Convergență foarte rapidă, cost de calcul ridicat

Clasificarea Datelor care nu se pot separa linear – relaxarea constrângerilor

Geometria Datelor

Maximizarea marjei este o idee bună, atâta timp cât presupunem că clasele subiacente sunt separabile liniar și că datele sunt fără zgomot.

Dacă datele sunt zgomotoase, am putea sacrifica idee de generalitate pentru a minimiza eroarea de clasificare cu o marjă foarte îngustă:



Cu fiecare limită de decizie, există un compromis între maximizarea marjei și minimizarea erorii.

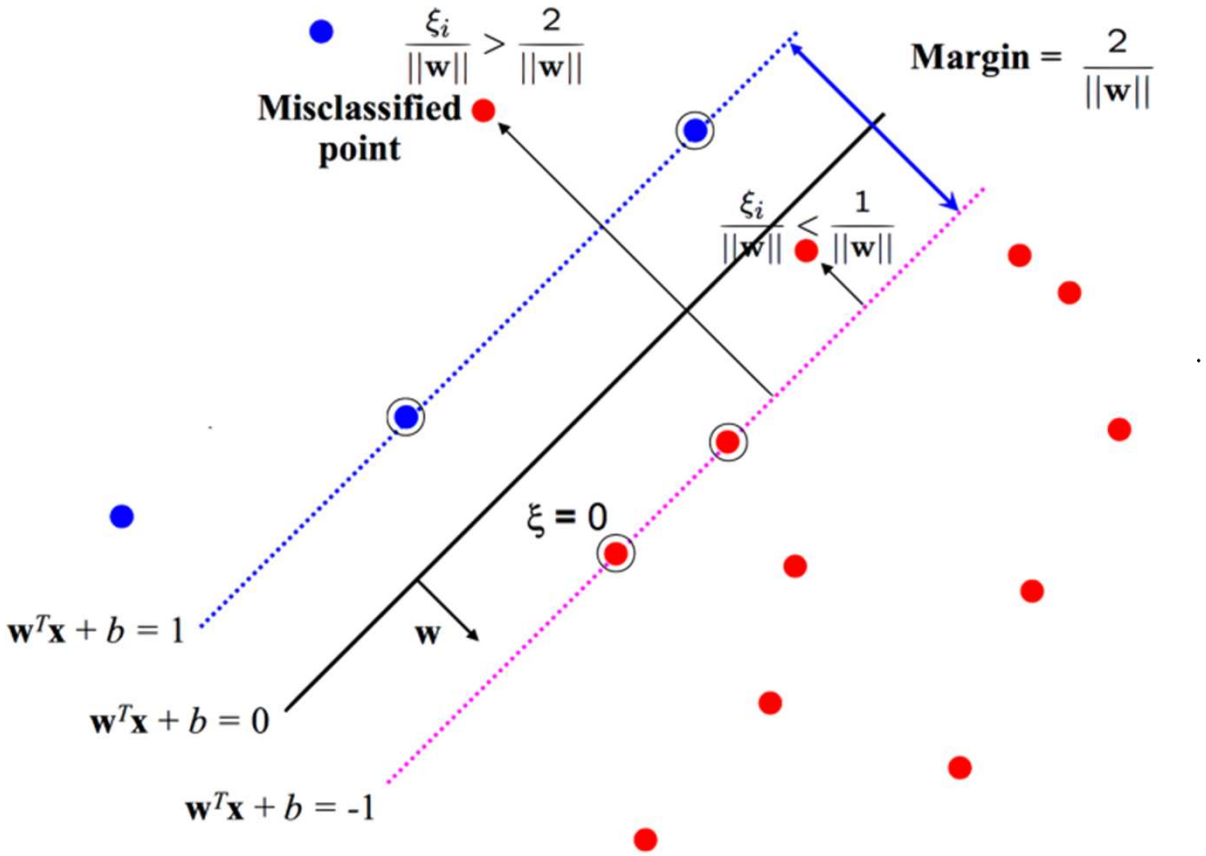
SVC: relaxarea constrângerilor

Vrem să exprimăm eroarea în funcție de distanța până la limita deciziei.

Amintiți-vă că vectorii suport au distanța 1 / ‖w‖ până la limita deciziei. Vrem să penalizăm două tipuri de „erori”

- ***(încălcare a marjei)*** puncte care se află pe partea corectă a limitei, dar se află în interiorul marginii. Au distanța ξ / ‖w‖, unde 0 <ξ <1.
- ***(clasificare greșită)*** puncte care se află pe partea greșită a graniței. Au distanță ξ / ‖w‖, unde ξ> 1.

SVC: relaxarea constrângerilor



SVC: relaxarea constrângerilor

Formal, încorporăm termenii de eroare ξ_n în problema de optimizare astfel:

$$\begin{cases} \min\limits_{\xi_n \in \mathbb{R}^+, w, b} \|w\|^2 + \lambda \sum\limits_{n=1}^{N} \xi_n \\ \text{astfel încât } y_n(w^\top x_n + b) \geq 1 - \xi_n, \ n = 1, \ldots, N \end{cases}$$

Soluția acestei probele este numită ***soft margin support vector classification*** sau, mai scurt, ***support vector classification (clasificare cu suport vectorial)***.

SVC: relaxarea constrângerilor - tuning

Alegerea diferitelor valori pentru λ în:

$$\begin{cases} \min\limits_{\xi_n \in \mathbb{R}^+, w, b} \|w\|^2 + \lambda \sum\limits_{n=1}^{N} \xi_n \\ \text{astfel încât } y_n(w^\top x_n + b) \geq 1 - \xi_n, \ n = 1, \ldots, N \end{cases}$$

ne va oferi diferiți clasificatori. În general,

- λ **mic** penalizează mai puțin erorile și, prin urmare, clasificatorul va avea o marjă mare de eroare
- λ **mare** penalizează mai mult erorile și, prin urmare, clasificatorul va accepta marje înguste pentru a îmbunătăți clasificarea
- setarea $\lambda = \infty$ produce soluția de marjă strictă

Extindere la frontiere de separare neliniare

Regresia polinomială: două perspective [1]

Având un set de antrenament:

$$\{(x_1, y_1), \ldots, (x_N, y_N)\}$$

cu un singur predictor cu valoare reală, putem privi modelarea cu polinom de gradul $w_0 + w_1 x + w_2 x^2$

ca proces de găsire a celei mai bune curbe pătratice care se potrivește cu datele.

Dar, în practică, extindem mai întâi dimensiunea caracteristică a setului d $x_n \mapsto (x_n^0, x_n^1, x_n^2)$

și instruim un model liniar pe datele extinse:

$$\{(x_1^0, x_1^1, x_1^2, y_1), \ldots, (x_N^0, x_N^1, x_N^2, y_N)\}$$

Transformarea Datelor

Observația cheie este că instruirea unui model polinomial este doar antrenarea unui model liniar pe date cu predictori transformați.

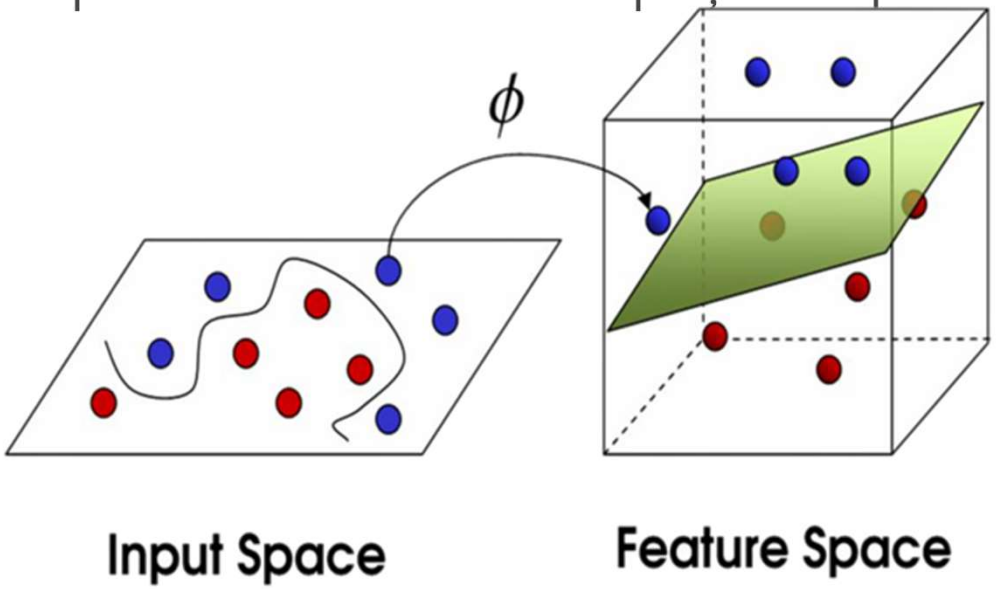
În exemplul nostru anterior, transformarea datelor pentru a se potrivi cu un model polinomial de gradul 2 necesită o mapare a datelor:

$$\phi : \mathbb{R} \to \mathbb{R}^3$$
$$\phi(x) = (x^0, x^1, x^2)$$

unde $\mathbb{R}$ e ***spațiul de intrare***, iar $\mathbb{R}^3$ este spațiul caracteristicilor, ***feature space***. Deși variabila răspuns poate să nu aibă o corelație liniară în spațiul de intrare $\mathbb{R}$, acesta poate avea una în spațiul caracteristicilor $\mathbb{R}^3$.

SVC cu limite de decizie neliniare

Aceeași perspectivă se aplică clasificării: în timp ce răspunsul poate să nu fie separabil liniar în spațiul de intrare, acesta poate deveni separabil într-un alt spațiu după o transformare ingenioasă:



SVC cu limite de decizie neliniare(cont.)

Motto: în loc să modificăm definiția SVC pentru a ne adapta la limite de deciziei neliniare, mapăm datele într-un spațiu caracteristic în care clasele sunt separabile liniar (sau aproape separabile):

Transformăm cu $\phi: \mathbb{R}^J \rightarrow \mathbb{R}^{J'}$ datele de antrenament

$$x_n \rightarrow \phi(x_n)$$

unde în mod uzual spațiul de sosire, de dimensiune J'(de exemplu 3) este mult mai mare decât cel de plecare, de dimensiune *J (de exemplu 2)*.

- Se antrenează un SVC pe datele transformate:

$$\{(\phi(x_1), y_1), (\phi(x_2), y_2), \ldots, (\phi(x_N), y_N)\}$$

Kernel Trick

În spațiile cu care lucrăm distanța se bazează pe produsul interior.

Produsul interior dintre doi vectori este o măsură a similarității celor doi vectori.

Transformarea $\phi: \mathbb{R}^J \rightarrow \mathbb{R}^{J'}$ definește un ***kernel***

$$K(x_n, x_m) = < \phi(x_n), \phi(x_m) >$$

Kernel Trick (cont.)

Cu alegerea nucleului K, antrenăm un SVC prin rezolvarea

$$\max_{\alpha_n \geq 0,\ \sum_n \alpha_n y_n = 0} \sum_n \alpha_n - \frac{1}{2} \sum_{n,m=1}^{N} y_n y_m \alpha_n \alpha_m K(x_n, x_m)$$

Calcularea $K(x_n, x_m)$ poate fi făcută fără a calcula separate valorile $\phi(x_n), \phi(x_m)$. Ne interesează doar produsul intern în spațiul de sosire - $\phi(x_n)^T \phi(x_m)$, care în practică se reduce la calcule elementare cu x_n, x_m

Acest mod de antrenare a unui SVC în spațiul de caracteristici fără a lucra în mod explicit cu maparea ϕ se numește ***kernel trick***.

Exemple de nuclee (kernel)

- **Nucleu Polinomial** (kernel='poly')

$$K(x_1, x_2) = (x_1^\top x_2 + 1)^d$$

  unde *d* este hiperparametru.

- **Nucleu (cu bază) Radial(ă)** (kernel='rbf')

$$K(x_1, x_2) = \exp\left\{-\frac{\|x_1 - x_2\|^2}{2\sigma^2}\right\}$$

  unde σ este hiperparametru.

- **Nucleu Sigmoid** (kernel='sigmoid')

$$K(x_1, x_2) = \tanh(\kappa x_1^\top x_2 + \theta)$$

  unde κ și θ sunt hiperparametrii.