Instructiuni Examen Partial SEED1

Analiza exploratorie a datelor

Instructor: conf. Dr. Teodor Ștefan Bîldea

Examen

• Veti incarca pe site-ul cursului la linkul Examen Partial atat prezentarea cat si notebookul cu codul prin care se pot reproduce numerele din prezentare.

• La cerere, sa fiti pregatiti sa rulati/explicati parti din notebook in timpul examenului – asta inseamna ca notebookul trebuie sa fie deschis si rulat.

Cerinte Prezentare Proiect

Recomandarea e ca numarul slide-urilor sa nu fie mai mare de 20, dar nici mai mic de 10.

I. Analiza exploratorie a datelor (40p)

1. Prezentarea cantitativa a datelor – 10p

a. Cate tabele, cate inregistrari

b. In cazul tabelelor multiple, cheile de legatura

c. Analiza datelor lipsa:

   i. Pe coloane, numarul de inregistrari lipsa (proportia de date lipsa la nivel de coloana)

   ii. Pe linii, numarul de inregistrari cu cel putin o valoare lipsa (proportia de inregistrari incomplete)

   iii. Decizii luate – inregistrari inlaturate/pastrate, atribute inlaturate/pastrate

Punctaj: a+b: 5p; c: 5p

2. Prezentarea calitativa a datelor – 10p

a. Prezentarea atributelor fiecare in parte:

   i. Tipurile de atribute (2p)

   ii. Distributia valorilor – reprezentari grafice (2p)

   iii. Statistici simple (2p)

   iv. Analiza valori extreme – daca exista la nivel de atribut: outliers – valori extreme care ar putea fi eliminate pentru o mai buna intelegere a problemei si a modelarii (2p)

   v. Analiza valori aberante/erori umane – de exemplu preturi negative, facturi negative sau date neconforme (e.g. programare la doctor in evul mediu) (2p)

3. Matricea de corelatie – 10p

a. Pentru variabile numerice, matricea de corelatie Pearson (2.5p)

b. Pentru variabile categoriale, dupa codificarea valorilor categoriale, matricea de corelatie Spearman (rank correlation), dupa ce in prealabil toate valorile categoriale au fost convertite in numerice (e.g. LabelEncoder/get_dummies()/OneHotEncoding in Python sau manual in Excel/Python) (2.5p)

c. Reprezentarea grafica a matricei de corelatie (2.5p)

d. Analiza componentelor principale:

   i. Gasirea componentelor principale (1.5p)

   ii. Determinarea acelor componente principale care impreuna explica 90% din variatia totala din date (1p)

4. Tendinte, trenduri, relatii intre variabile – 10p

Pentru clasificare este important sa aveti grafice cu distributii ale variabilei dependente pe clasele unor atribute discrete – pentru a determina:

a. Distributia atributelor pe clasele care trebuie prognozate
    i. Care atribute separa datele cel mai bine in clase?
b. Legaturi intre mai multe atribute si clase (e.g. grafic cu distributia in clase de client fidel/client dezertor grupate pe sex si vechime)

Grafice de tip scatter plot (imprastiere) pentru a observa eventuale corelatii/sabloane (eventual pornind de la numerele din matricea de corelatie).