Instructiuni Examen Final SEED1

Modelare clasificatori

Instructor: conf. Dr. Teodor Ștefan Bîldea

Examen

• Veti incarca pe site-ul cursului la linkul Examen Final atat prezentarea cat si notebookul cu codul prin care se pot reproduce numerele din prezentare.

• La cerere, sa fiti pregatiti sa rulati/explicati parti din notebook in timpul examenului – asta inseamna ca notebookul trebuie sa fie deschis si rulat.

Cerinte Prezentare Proiect

Recomandarea e ca numarul slide-urilor sa nu fie mai mare de 20, dar nici mai mic de 10.

II. Modelare clasificatori (40p)

1. Sumarul setului de date pentru modelare – 5p

Pentru setul de date care intra in modelare, o prezentare pe 1–2 slide-uri cu sumar agregat, in functie de setul de date:

a. Care este problema pe care o modelati → care este variabila raspuns

b. Atribute numerice

c. Alte atribute si codificarea lor

d. Atribute derivate (daca aveti)

e. Numar de inregistrari

2. Pasi de preprocesare a datelor (daca e cazul) – 1 slide – 5p

De exemplu scalare in intervalul [0,1] sau standardizare, sau ce altceva ati mai facut cu datele si nu a fost prins in cele de mai sus.

3. Descrierea modelelor – 20p

Descrierea pe rand a cel putin 3 modele cu care v-ati decis sa faceti modelarea (2–3 slide-uri pentru fiecare model).

1. Puteti alege din modelele prezentate la curs (daca vreti sa incercati si alte modele, e ok):
    a. Clasificare – modele prezentate la curs: LogisticRegression cu regularizare, kNN classifier, arbore de clasificare (DecisionTree for classification), padure aleatoare – clasificare (random forest classifier), masini cu suport vectorial pentru clasificare (svm.SVC), xgboost
2. Pentru fiecare model utilizat precizati:
    a. Ce parametri ati optimizat prin incercari (grid search) si ce inseamna ei
    b. Modul de antrenare: cum ati impartit datele, daca ati facut validare incrucisata si cum ati facut-o, daca ati folosit esantionare stratificata
    c. Metrica cu care ati cautat modelul/parametrii optimi
    d. Rezultatul antrenarii: cel mai bun model, rezultat de prognoza pe date nefolosite in antrenament

4. Concluzii – 1–2 slide-uri – 10p

Sumar cu modelele si rezultatele obtinute, de data aceasta folosind o singura spargere in train/test, antrenarea tuturor modelelor pe acelasi set de antrenament si evaluarea rezultatelor de modelare pe datele de test.

Concluzie cu cel mai bun model.